

Analítica de Datos

Clase 2 - Data Profiling y Visualizaciones

¿Qué vieron con Pablo?

Agenda

- Data Profiling & Visualization
- Notebook
- Kahoot

Dos conceptos

Entender y analizar bien los datos es demasiado importante (En cualquier situación)

Dos conceptos

Entender y analizar bien los datos es demasiado importante (En cualquier situación)

Podes visualizar bien, con buen concepto, es una herramienta que les va a dar mucho laburo

¿Qué es el data profiling?

¿Qué es el data profiling?

Técnica para entender los datos

¿Qué es el data profiling?

Técnica para entender los datos

- Entender la estructura de los datos

¿Qué es el data profiling?

Técnica para entender los datos

- Entender la estructura de los datos
- Evaluar la calidad del dataset

¿Qué es el data profiling?


Técnica para entender los datos


- Entender la estructura de los datos
- Evaluar la calidad del dataset
- Identificar problemas potenciales

¿Qué es el data profiling?


Técnica para entender los datos

- Entender la estructura de los datos
- Evaluar la calidad del dataset
- Identificar problemas potenciales
- Primer paso (Y usualmente el más difícil) en cualquier proyecto de analítica





Entender los datos



Entender las variables

Variables numéricas

Entender las variables

Variables numéricas

Dos tipos... ¿?

Entender las variables

Variables numéricas

Continuas: Valores enteros específicos

Discretas: Cualquier valor en un rango

Entender las variables

Variables numéricas

Continuas: Valores enteros específicos

Discretas: Cualquier valor en un rango

Variables categóricas

También dos tipos...

Entender las variables

Nominales

Ordinales

Entender las variables

Variables numéricas

Continuas: Valores enteros específicos

Discretas: Cualquier valor en un rango

Variables categóricas

Nominales: Sin un orden natural

Ordinales: Con un orden natural

Entender las variables

Variables numéricas

Continuas: Valores enteros específicos

Discretas: Cualquier valor en un rango

Variables categóricas

Nominales: Sin un orden natural

Ordinales: Con un orden natural

¿Otros tipos de variable?

Entender las variables

Variables numéricas

Continuas: Valores enteros específicos

Discretas: Cualquier valor en un rango

Variables categóricas

Nominales: Sin un orden natural

Ordinales: Con un orden natural

¿Otros tipos de variable?

Fechas: Momentos específicos

Variables compuestas: Distintos tipos de datos

1. Medidas de tendencia central

2. Medidas de dispersión

3. Datos faltantes

1. Medidas de tendencia central

2. Medidas de dispersión

4. Datos faltantes

Medidas de tendencia central

¿Donde se concentran los datos?

Media

Mediana

Moda

Medidas de tendencia central

¿Donde se concentran los datos?

Media: Promedio de todos los valores

Mediana

Moda

Medidas de tendencia central

¿Donde se concentran los datos?

1, 1, 2, 3, 4, 5, 6, 10, 100

Media: Promedio de todos los valores

Mediana

Moda

Medidas de tendencia central

¿Donde se concentran los datos?

1, 1, 2, 3, 4, 5, 6, 10, 100

Media: Promedio de todos los valores

Mediana

$$1 + 1 + 2 + 3 + 4 + 5 + 6 + 10 + 100 = 132$$

Moda

Medidas de tendencia central

¿Donde se concentran los datos?

1, 1, 2, 3, 4, 5, 6, 10, 100

Media: Promedio de todos los valores

Mediana

$$1 + 1 + 2 + 3 + 4 + 5 + 6 + 10 + 100 = 132$$

Moda

$$132/9 = 14.7$$

Medidas de tendencia central

¿Donde se concentran los datos?

1, 1, 2, 3, 4, 5, 6, 10, 100

Media: Promedio de todos los valores

Mediana

$$1 + 1 + 2 + 3 + 4 + 5 + 6 + 10 + 100 = 132$$

Moda

$$132/9 = 14.7$$

En promedio, la gente gana 14 millones por año...¿ ?

Medidas de tendencia central

¿Donde se concentran los datos?

Media: Promedio de todos los valores

Mediana: Valor central de la distribución

Moda

Medidas de tendencia central

¿Donde se concentran los datos?

1, 1, 2, 3, 4, 5, 6, 10, 100

Media: Promedio de todos los valores

Mediana: Valor central de la distribución

Moda

Medidas de tendencia central

¿Donde se concentran los datos?

1, 1, 2, 3, 4, 5, 6, 10, 100

Media: Promedio de todos los valores

Mediana: Valor central de la distribución **4**

Moda

Medidas de tendencia central

¿Donde se concentran los datos?

1, 1, 2, 3, 4, 5, 6, 10, 100

Media: Promedio de todos los valores

Mediana: Valor central de la distribución **4**

Moda

La gente gana 4 millones por año... Mucho mejor !

Medidas de tendencia central

¿Donde se concentran los datos?

Media: Promedio de todos los valores

Mediana: Valor central de la distribución

Moda: Valor más frecuente

Medidas de tendencia central

¿Donde se concentran los datos?

1, 1, 2, 3, 4, 5, 6, 10, 100

Media: Promedio de todos los valores

Mediana: Valor central de la distribución

Moda: Valor más frecuente

Medidas de tendencia central

¿Donde se concentran los datos?

1, 1, 2, 3, 4, 5, 6, 10, 100

Media: Promedio de todos los valores

Mediana: Valor central de la distribución **1**

Moda: Valor más frecuente

1. Medidas de tendencia central

2. Medidas de dispersión

3. Datos faltantes

Medidas de dispersión


Varianza: Promedio de desviaciones al cuadrado

Desviación Estandar: Raíz cuadrada de la varianza


Cuartil Q1, 2, 3 Y 4: Valor que divide un conjunto de datos ordenados en cuatro partes iguales

Rango Intercuartil (IQR): La diferencia entre el tercer cuartil (Q3) y el primer cuartil (Q1), y representa el 50 % central de los datos


Medidas de dispersión




Medidas de dispersión




Medidas de dispersión




Medidas de dispersión




Medidas de dispersión



Medidas de dispersión



Medidas de dispersión




La diferencia entre el tercer cuartil (Q3) y el primer cuartil (Q1), y representa el 50 % central de los datos


Media

Mediana


Medidas de dispersión




Medidas de dispersión




Medidas de dispersión




Medidas de dispersión



Medidas de dispersión



Medidas de dispersión



1. Medidas de tendencia central

2. Medidas de dispersión

3. Datos faltantes

Datos faltantes

Datos faltantes

MCAR: Missing Completely at Random

MAR: Missing at Random

MNAR: Missing not at Random

Datos faltantes - MCAR

Los datos faltantes **no están relacionados** *con ninguna variable observable*.
El patrón de faltantes es **completamente** aleatorio.

Datos faltantes - MCAR

Id	Edad	Rubro	Salario
1	29	Abogado/a	1.500.000
2	53	Null	430.000
3	21	Analista de datos	Null
4	34	Analista de marketing	1.000.000
5	Null	A. financiero/a	600.000
5	31	Asesor/a del congreso	700.000
6	48	Recepcionista	Null

Datos faltantes - MCAR

Id	Edad	Rubro	Salario
1	29	Abogado/a	1.500.000
2	53	Null	430.000
3	21	Analista de datos	Null
4	34	Analista de marketing	1.000.000
5	Null	A. financiero/a	600.000
5	31	Asesor/a del congreso	700.000
6	48	Recepcionista	Null

Los datos faltantes aparecen de forma aleatoria sin relación con ninguna variable observable.
Los participantes se olvidaron de responder preguntas al azar

Datos faltantes - MAR

Los datos faltantes **están relacionados** con variables **observables**, pero *no con el valor faltante mismo*.

Datos faltantes - MAR

Id	Edad	Rubro	Salario
1	29	Abogado	1.500.000
2	37	Profesora	430.000
3	53	Analista de datos	Null
4	34	Analista de marketing	1.000.000
5	23	A. financiera	600.000
5	31	Asesora del congreso	700.000
6	48	Recepcionista	Null

Datos faltantes - MAR

Id	Edad	Rubro	Salario
1	29	Abogado	1.500.000
2	37	Profesora	430.000
3	53	Analista de datos	Null
4	34	Analista de marketing	1.000.000
5	23	A. financiera	600.000
5	31	Asesora del congreso	700.000
6	48	Recepcionista	Null

La falta depende de los datos observados (la edad). Los entrevistados mayores de 40 años no se sienten cómodos de divulgar su salario.

Datos faltantes - MNAR

Los datos faltantes **están relacionados con el valor faltante mismo**

Datos faltantes - MNAR

Id	Edad	Rubro	Salario
1	45	Abogado	Null
2	52	Profesora	430.000
3	21	Analista de datos	Null
4	34	Analista de marketing	Null
5	23	A. financiera	600.000
5	31	Asesora del congreso	700.000
6	48	Recepcionista	770.000

Datos faltantes - MNAR


Id	Edad	Rubro	Salario
1	45	Abogado	Null
2	52	Profesora	430.000
3	21	Analista de datos	Null
4	34	Analista de marketing	Null
5	23	A. financiera	600.000
5	31	Asesora del congreso	700.000
6	48	Recepcionista	770.000

La falta depende del dato que no tengo. Las personas con salarios más altos tienden a evitar contestar la pregunta.

Datos faltantes

¿Qué significa que un dato falte?

Visualización de datos




Visualización de datos


Visualización de datos

- Hace visibles patrones e insights que no se detectan fácilmente solo con números (tendencias, outliers, relaciones)
- Facilita la comprensión rápida, reduciendo el esfuerzo cognitivo de la audiencia
- Mejora la toma de decisiones, porque comunica información clave de forma clara y directa
- Evita interpretaciones erróneas, si está bien diseñada (sin distorsiones ni ruido visual)
- Permite comunicar una historia con datos, haciendo el mensaje más persuasivo y memorable

Elegir el gráfico equivocado




Complejizar la información
sin sentido




No decir NADA


Frequency of exercise



Mal uso del color




Usar 3D (Sin razón)





Hablemos de esto...

Barras apiladas, gráfico




Hablemos de esto...

Barras apiladas, gráfico





Hablemos de esto...

Gráfico de tortas



Hablemos de esto...


Gráfico de tortas



¿Cómo sería una buena visualización?

Top 10 companies by market cap

\$bn




Excludes Venezuela companies inflated by official FX exchange rate
Source: Bloomberg


FT

Good vs Bad Data Visualization: Information Congestion

Good Visualization



Bad Visualization (Congested)





Argentina



63 / 116

Usage rank ⓘ

0.75x

Usage Index ⓘ



Expected: 1

0.75

Total # of observations: 6,088

Most frequent Most distinctive

The most common topics in Argentina.


[View more](#)

How people are using Claude

Click a tile to drill into more granular data


Group by job ☒ Group by category

Categorized using O*NET-SOC
codes




Percentages represent the share of Claude.ai conversations associated with each task or group of tasks. Graphic shows what people do with Claude, not their job titles. Percentages don't sum to 100% because we impose privacy filters.


Pensemos entre todos




Pensemos entre todos



Pensemos entre todos



Pensemos entre todos



Notebook

Kahoot