

Analítica de Datos

Clase 3 - Data Cleaning e Intro a Machine Learning

Agenda

- Data Cleaning
- Intro Machine Learning
- Regresión Lineal
- Notebooks
- Caso de aplicación
- Kahoot

Data Prepping / Cleaning

¿Qué es el data cleaning/prepping?

Data Prepping / Cleaning

¿Qué es el data cleaning/prepping?

El proceso de preparar y limpiar los datos antes de analizarlos

Data Prepping / Cleaning

¿Qué es el data cleaning/prepping?

El proceso de preparar y limpiar los datos antes de analizarlos

¿Por qué hacemos data prepping?

Data Prepping / Cleaning

¿Qué es el data cleaning/prepping?

El proceso de preparar y limpiar los datos antes de analizarlos

¿Por qué hacemos data prepping?

Preparamos los datos para que sean correctos, consistentes y útiles, así podemos confiar en lo que analizamos o modelamos.

Data Prepping / Cleaning

¿Qué es el data cleaning/prepping?

El proceso de preparar y limpiar los datos antes de analizarlos

¿Por qué hacemos data prepping?

Preparamos los datos para que sean correctos, consistentes y útiles, así podemos confiar en lo que analizamos o modelamos.

¿Qué pasa si no lo hacemos?

Data Prepping / Cleaning

¿Qué es el data cleaning/prepping?


El proceso de preparar y limpiar los datos antes de analizarlos

¿Por qué hacemos data prepping?

Preparamos los datos para que sean correctos, consistentes y útiles, así podemos confiar en lo que analizamos o modelamos.

¿Qué pasa si no lo hacemos?

Sin data prepping, es muy probable que obtengas malos modelos y decisiones poco confiables



No es casualidad que los únicos dos círculos que están de distinto color sean estos

**¿QUÉ ERRORES BUSCAMOS CUANDO
HACEMOS DATA PREPPING?**

¿y como los arreglamos?

ID	Edad	Ingreso Mensual	Ciudad
1	25	1200	Buenos Aires
2	30	null	Córdoba
3	null	950	Rosario
4	45	2000	null
5	38	1750	Mendoza
6	null	null	La Plata
7	29	1100	null
8	50	3000	Buenos Aires
9	null	800	Córdoba
10	33	null	Rosario

Datos nulos

¿Qué buscamos?

Datos nulos, Nan o que de alguna manera no haya información (###, ---, ., Etc)

¿Cómo los arreglamos?

Datos nulos

¿Qué buscamos?

Datos nulos, Nan o que de alguna manera no haya información (###, ---, ., Etc)

¿Cómo los arreglamos?

- Eliminar filas o columnas con muchos nulos

ID	Edad	Ingreso Mensual	Ciudad
1	25	1200	Buenos Aires
2	30	null	Córdoba
3	null	null	Córdoba
4	45	2000	null
5	38	1750	Mendoza
6	null	null	La Plata
7	29	1100	null
8	50	3000	Buenos Aires
9	null	800	Córdoba
10	33	null	Rosario

Datos nulos

¿Qué buscamos?

Datos nulos, Nan o que de alguna manera no haya información (###, ---, ., Etc)

¿Cómo los arreglamos?

- Eliminar filas o columnas con muchos nulos
- Imputar con media, mediana o moda

Datos nulos

¿Qué buscamos?

Datos nulos, Nan o que de alguna manera no haya información (###, ---, ., Etc)

¿Cómo los arreglamos?

- Eliminar filas o columnas con muchos nulos
- Imputar con media, mediana o moda
- Imputar por grupos (ej: promedio por ciudad)

Datos nulos

¿Qué buscamos?

Datos nulos, Nan o que de alguna manera no haya información (###, ---, ., Etc)

¿Cómo los arreglamos?

- Eliminar filas o columnas con muchos nulos
- Imputar con media, mediana o moda
- Imputar por grupos (ej: promedio por ciudad)
- *Crear categoría “Desconocido” para variables categóricas*
- *Usar métodos avanzados (KNN, MICE, modelos predictivos)*

ID	Edad	Ingreso Mensual	Ciudad
1	25	1200	Buenos Aires
2	30	1500	bs as
3	28	mil	Córdoba
4	cuarenta	2000	ROSARIO
5	35	1800	Mendoza
6	29 años	1700	Cordoba
7	41	\$2,500	Bs As
8	33	1600	buenos aires
9	27	1.4	Mendoza
10	-50	3000	MENDOZA

Inconsistencias

¿Qué buscamos?

Datos sin sentido, o que deberían ser iguales pero se diferencian por un mal ingreso de dato o mala manipulación de la base

¿Cómo los arreglamos?

Inconsistencias

¿Qué buscamos?

Datos sin sentido, o que deberían ser iguales pero se diferencian por un mal ingreso de dato o mala manipulación de la base

¿Cómo los arreglamos?

De guapo, con código



Inconsistencias

¿Qué buscamos?

Datos sin sentido, o que deberían ser iguales pero se diferencian por un mal ingreso de dato o mala manipulación de la base

¿Cómo los arreglamos?

De guapo, con código 

No sin antes hacer un buen EDA y encontrar donde está la falla !

df.unique() para categorías

ID	Edad	Ingreso Mensual	Ciudad
1	25	1200	Buenos Aires
2	30	1500	bs as
3	28	mil	Córdoba
4	cuarenta	2000	ROSARIO
5	35	1800	Mendoza
6	29 años	1700	Cordoba
7	41	\$2,500	Bs As
8	33	1600	buenos aires
9	27	1.4	Mendoza
10	-50	3000	MENDOZA

Ok

Nulos

Inconsistencias

¿Qué más?

ID	Edad	Ingreso Mensual	Ciudad
1	25	1200	Buenos Aires
2	30	1500	Buenos Aires
3	28	1300	Rosario
4	35	1800	Mendoza
5	40	2000	La Plata
6	29	1700	Córdoba
7	31	1600	Buenos Aires
8	27	1400	Rosario
9	104	1900	Mendoza
10	33	150000	Buenos Aires

Outliers

¿Qué buscamos?

Datos por fuera del IQR, O que simplemente estén en lados muy extremos de la distribución

¿Cómo los arreglamos?

Outliers

¿Qué buscamos?

Datos por fuera del IQR, O que simplemente estén en lados muy extremos de la distribución

¿Cómo los arreglamos?

Eliminar outliers si son errores

Mantener si sirve la información

Hay que analizar los casos particulares y revisar si tiene sentido mantener la info en el dataset

Outliers

¿Qué buscamos?

Datos por fuera del IQR, O que simplemente estén en lados muy extremos de la distribución

¿Cómo los arreglamos?

Eliminar outliers si son errores

Mantener si sirve la información

Hay que analizar los casos particulares y revisar si tiene sentido mantener la info en el dataset

Disclaimer: Hay modelos que manejan muy bien los outliers, y otros que si no los tratás te arruinan la carrera

ID	Edad	Ingreso Mensual	Ciudad
1	25	1200	Buenos Aires
2	30	1500	Córdoba
3	30	1500	Córdoba
4	35	1800	Mendoza
5	40	2000	La Plata
6	30	1500	Córdoba
7	31	1600	Buenos Aires
8	28	1300	Rosario
9	27	1400	Mendoza
10	25	1200	Buenos Aires

ID	Edad	Ingreso Mensual	Ciudad
1	25	1200	Buenos Aires
2	30	1500	Córdoba
3	30	1500	Córdoba
4	35	1800	Mendoza
5	40	2000	La Plata
6	30	1500	Córdoba
7	31	1600	Buenos Aires
8	28	1300	Rosario
9	27	1400	Mendoza
10	25	1200	Buenos Aires

Duplicados

¿Qué buscamos?

Datos con los mismos valores en todas las columnas

¿Cómo los arreglamos?

Duplicados

¿Qué buscamos?

Datos con los mismos valores en todas las columnas

¿Cómo los arreglamos?

Primero, chequeo si tengo duplicados, y despues los elimino

```
df.drop_duplicates()
```


ID	Edad	Ingreso Mensual	Ciudad
1	25	1200	Buenos Aires
2	30	1500	Córdoba
3	30	1500	Córdoba
4	35	1800	Mendoza
5	40	2000	La Plata
6	30	1500	Córdoba
7	31	1600	Buenos Aires
8	28	1300	Rosario
9	27	1400	Mendoza
10	25	1200	Buenos Aires

ID	Edad	Ingreso Mensual	Ciudad
1	25	1200	Buenos Aires
2	30	1500	Córdoba
3	30	1500	Córdoba
4	35	1800	Mendoza
5	40	2000	La Plata
6	30	1500	Córdoba
7	31	1600	Buenos Aires
8	28	1300	Rosario
9	27	1400	Mendoza
10	25	1200	Buenos Aires

ID	Edad	Ingreso Mensual	Ciudad
1	25	1200	Buenos Aires
2	30	1500	Córdoba
2	30	1500	Córdoba
4	35	1800	Mendoza
5	40	2000	La Plata
6	30	1500	Córdoba
7	31	1600	Buenos Aires
8	28	1300	Rosario
9	27	1400	Mendoza
10	25	1200	Buenos Aires

Otros ejemplos

- Datos irrelevantes (columnas que no aportan valor)
- Datos mal representados (feature engineering pobre)
- Desbalance de clases
- Data leakage (información del futuro o del target)
- Datos desactualizados
- Problemas de integración (múltiples fuentes inconsistentes)
- Granularidad inconsistente (distintos niveles de detalle)



Data Engineering

Es el proceso de **obtener, transformar, combinar y organizar datos** para que puedan ser utilizados de manera confiable por analistas, dashboards o modelos.

Data Engineering

Es el proceso de **obtener, transformar, combinar y organizar datos** para que puedan ser utilizados de manera confiable por analistas, dashboards o modelos.

Datos crudos → Datos útiles

Data Engineering

Es el proceso de **obtener, transformar, combinar y organizar datos** para que puedan ser utilizados de manera confiable por analistas, dashboards o modelos.

Datos crudos → Datos útiles

Construir el dataset que necesito

Data Engineering

- Feature engineering: transformar datos existentes en nuevas variables que representen mejor el fenómeno que queremos analizar.
 - *¿Qué información describe mejor el comportamiento que quiero entender?*

Data Engineering

- Feature engineering: transformar datos existentes en nuevas variables que representen mejor el fenómeno que queremos analizar.
 - *¿Qué información describe mejor el comportamiento que quiero entender?*

Ejemplo:

Fecha última compra = 15/07/2026

puede ser menos útil que:

Días desde última compra = 47

La información es prácticamente la misma, pero la segunda representación es mucho más fácil de utilizar.

Data Engineering

Ejemplo de Feature engineering: **Ausentismo**.

Data Engineering

¿Qué variables nuevas podemos crear?

Cálculo → Ingresos, Gastos → % ingreso gastado

Tiempo → Fecha última compra → Días desde última compra

Agregación → Todas las compras → Compras últimos 90 días

Indicador → Reclamos → Tuvo reclamos: Sí/No

Interacción → Ingreso / integrantes del hogar → Ingreso per cápita

Data Engineering

¿Qué variables nuevas podemos crear?

Cálculo → Ingresos, Gastos → % ingreso gastado

Tiempo → Fecha última compra → Días desde última compra

Agregación → Todas las compras → Compras últimos 90 días

Indicador → Reclamos → Tuvo reclamos: Sí/No

Interacción → Ingreso / integrantes del hogar → Ingreso per cápita

También podemos buscar variables en una API (Interfaz de Programación de Aplicaciones) !!!

Data Engineering

¿Qué variables nuevas podemos crear?

Cálculo → Ingresos, Gastos → % ingreso gastado

Tiempo → Fecha última compra → Días desde última compra

Agregación → Todas las compras → Compras últimos 90 días

Indicador → Reclamos → Tuvo reclamos: Sí/No

Interacción → Ingreso / integrantes del hogar → Ingreso per cápita

También podemos buscar variables en una API (Interfaz de Programación de Aplicaciones) !!!


Util cuando estamos trabajando con clima

Notebook 10 Minutos

Programa

	Modulo
1	Analítica de Datos y las organizaciones 
2	Aprendizaje Automático Supervisado
3	Aprendizaje Automático No Supervisado
4	Deep Learning (!!!)

Muy bueno,
MaCHINE learning



Machine Learning


¿Qué es el Machine Learning?

Machine Learning

¿Qué es el Machine Learning?


Rama que permite a las computadoras aprender patrones a partir de datos y hacer predicciones o decisiones sin ser programadas explícitamente para cada caso.

¿Qué tipos de Modelos de Machine Learning existen?



Programa

	Modulo
1	Analítica de Datos y las organizaciones
2	Aprendizaje Automático Supervisado
3	Aprendizaje Automático No Supervisado
4	Deep Learning (!!!)



Machine Learning

¿Qué es el Machine Learning?

Rama que permite a las computadoras aprender patrones a partir de datos y hacer predicciones o decisiones sin ser programadas explícitamente para cada caso.

¿Qué tipos de Modelos de Machine Learning existen?

Supervisados: los datos tienen una variable **TARGET** que funciona para predecir

No supervisados: los datos no tienen una variable **TARGET**

Machine Learning

Ejercicio, ¿Estos casos son supervisados o no supervisado?

- Un modelo que usa datos históricos de casas con su precio para predecir cuánto vale una casa nueva
- Un algoritmo que agrupa clientes según su comportamiento de compra
- Un sistema que aprende a clasificar emails como “spam” o “no spam” usando ejemplos etiquetados
- Un modelo que analiza transacciones y detecta patrones raros sin saber previamente cuáles son fraude

Machine Learning

Ejercicio, ¿Estos casos son supervisados o no supervisado?

- Un modelo que usa datos históricos de casas con su precio para predecir cuánto vale una casa nueva **SUPERVISADO**
- Un algoritmo que agrupa clientes según su comportamiento de compra
- Un sistema que aprende a clasificar emails como “spam” o “no spam” usando ejemplos etiquetados
- Un modelo que analiza transacciones y detecta patrones raros sin saber previamente cuáles son fraude

Machine Learning

Ejercicio, ¿Estos casos son supervisados o no supervisado?

- Un modelo que usa datos históricos de casas con su precio para predecir cuánto vale una casa nueva **SUPERVISADO**
- Un algoritmo que agrupa clientes según su comportamiento de compra **NO SUPERVISADO**
- Un sistema que aprende a clasificar emails como “spam” o “no spam” usando ejemplos etiquetados
- Un modelo que analiza transacciones y detecta patrones raros sin saber previamente cuáles son fraude

Machine Learning

Ejercicio, ¿Estos casos son supervisados o no supervisado?

- Un modelo que usa datos históricos de casas con su precio para predecir cuánto vale una casa nueva **SUPERVISADO**
- Un algoritmo que agrupa clientes según su comportamiento de compra **NO SUPERVISADO**
- Un sistema que aprende a clasificar emails como “spam” o “no spam” usando ejemplos etiquetados **SUPERVISADO**
- Un modelo que analiza transacciones y detecta patrones raros sin saber previamente cuáles son fraude

Machine Learning

Ejercicio, ¿Estos casos son supervisados o no supervisado?


- Un modelo que usa datos históricos de casas con su precio para predecir cuánto vale una casa nueva **SUPERVISADO**
- Un algoritmo que agrupa clientes según su comportamiento de compra **NO SUPERVISADO**
- Un sistema que aprende a clasificar emails como “spam” o “no spam” usando ejemplos etiquetados **SUPERVISADO**
- Un modelo que analiza transacciones y detecta patrones raros sin saber previamente cuáles son fraude **NO SUPERVISADO**

Machine Learning

¿Qué es un modelo?

Un modelo es una función que aprende patrones de los datos para hacer predicciones.

¿Qué tipos de modelos supervisados hay?



Machine Learning

¿Qué es un modelo?

Machine Learning

¿Qué es un modelo?

Un modelo es una función que aprende patrones de los datos para hacer predicciones.

¿Qué tipos de modelos supervisados hay?

Machine Learning

¿Qué es un modelo?

Un modelo es una función que aprende patrones de los datos para hacer predicciones.

¿Qué tipos de modelos supervisados hay?

Clasificación: Buscan predecir una categoría

Regresión: Buscan predecir un número

Machine Learning

Ejercicio, ¿Estos casos son clasificación o regresión?

- Predecir el precio de una casa en función de sus características
- Determinar si un email es “spam” o “no spam”
- Estimar la cantidad de ventas de un producto el próximo mes
- Predecir si un cliente va a abandonar, mantener o mejorar un servicio

Machine Learning

Ejercicio, ¿Estos casos son clasificación o regresión?

- Predecir el precio de una casa en función de sus características **REGRESIÓN**
- Determinar si un email es “spam” o “no spam”
- Estimar la cantidad de ventas de un producto el próximo mes
- Predecir si un cliente va a abandonar, mantener o mejorar un servicio

Machine Learning

Ejercicio, ¿Estos casos son clasificación o regresión?

- Predecir el precio de una casa en función de sus características **REGRESIÓN**
- Determinar si un email es “spam” o “no spam” **CLASIFICACIÓN**
- Estimar la cantidad de ventas de un producto el próximo mes
- Predecir si un cliente va a abandonar, mantener o mejorar un servicio

Machine Learning

Ejercicio, ¿Estos casos son clasificación o regresión?

- Predecir el precio de una casa en función de sus características **REGRESIÓN**
- Determinar si un email es “spam” o “no spam” **CLASIFICACIÓN**
- Estimar la cantidad de ventas de un producto el próximo mes **REGRESIÓN**
- Predecir si un cliente va a abandonar, mantener o mejorar un servicio

Machine Learning

Ejercicio, ¿Estos casos son clasificación o regresión?

- Predecir el precio de una casa en función de sus características **REGRESIÓN**
- Determinar si un email es “spam” o “no spam” **CLASIFICACIÓN**
- Estimar la cantidad de ventas de un producto el próximo mes **REGRESIÓN**
- Predecir si un cliente va a abandonar, mantener o mejorar un servicio **CLASIFICACIÓN**

Machine Learning

¿Qué aprendimos?

¿Qué es **Machine Learning**?

¿Cual es la diferencia entre **supervisado** y no **supervisado**?

¿Qué es un **modelo**?

¿Cual es la diferencia entre **regresión** y **clasificación**?

Machine Learning

¿Qué aprendimos?

¿Qué es **Machine Learning**?

¿Cual es la diferencia entre **supervisado** y no **supervisado**?

¿Qué es un **modelo**?

¿Cual es la diferencia entre **regresión** y **clasificación**?

Una cosa más y pasamos a nuestro primer modelo, **regresión lineal**

Machine Learning | Overfitting vs Underfitting

Nosotros somos un área de IA de un hospital, y desarrollamos un modelo de predicción para predecir ausentismo en turnos médicos.

Usamos datos de Enero a Marzo para entrenar el modelo y vemos que funciona excelente, acierta el 80% de las veces.

Pero despues volvimos a testear el modelo en Agosto, y el mismo modelo funcionó muy mal, acertando el 60% de las veces.

¿Por qué pasa esto?

Machine Learning | Overfitting vs Underfitting

Overfitting: El modelo aprende demasiado los datos de entrenamiento, incluyendo ruido y detalles irrelevantes.

Resultado: No generaliza

- Muy buen rendimiento en entrenamiento
- Mal rendimiento en datos nuevos

Underfitting: El modelo aprende muy poco y no captura los patrones importantes.

Resultado: Es demasiado simple


- Mal rendimiento en entrenamiento
- Mal rendimiento en datos nuevos

Machine Learning | Overfitting vs Underfitting


Overfitting: Aprende demasiado

Underfitting: Aprende muy poco


El objetivo es encontrar un equilibrio



Underfitted
(High bias error)



Good Fit/Robust
(Balance between
bias and variance)



Overfitted
(High variance error)

Machine Learning

¿Qué aprendimos?

¿Qué es **Machine Learning**?


¿Cual es la diferencia entre **supervisado** y no **supervisado**?

¿Qué es un **modelo**?

¿Cual es la diferencia entre **regresión** y **clasificación**?

¿Qué es el **overfitting** y **underfitting**?

Machine Learning



Machine Learning

