

Analítica de Datos


Clase 6 - CART


Hola


¿Qué piensan del parcial?


Agenda


- CART
- Notebook
- No hay Kahoot




















Árboles de decisión

Árboles de decisión

Classification and Regression Trees

Árboles de decisión

Classification and Regression Trees - CART

CART

Un árbol de decisión que intenta imitar una serie de preguntas simples para llegar a una predicción.

CART - Ejemplo

Soy un administrativo del centro de Becas de San Andres y tengo que decidir a quien le voy a dar una beca el año que viene

Un grupo de 5 ingresantes a una carrera nueva, y quiero decidir si les doy una beca de **estudiante federal**



Un grupo de 5 ingresantes a una carrera nueva, y quiero decidir si les doy una beca de **estudiante federal**



¿El ingresante es del interior?



¿El ingresante es del interior?


No




¿El ingresante es del interior?


Si


No





Ahora que se quienes son del interior, tengo que darle beca a quienes tenga mérito académico















Entonces...


Si un ingresante es del interior Y tiene más de 9 de promedio en el colegio, **recibe la beca**



Entonces...

Si un ingresante es del interior Y tiene más de 9 de promedio en el colegio, **recibe la beca**

¿Que sería recibir la beca?
Pista: Concepto teórico de la primera parte de la materia



Entonces...

Si un ingresante es del interior Y tiene más de 9 de promedio en el colegio, **recibe la beca**

¿De donde salen las preguntas?

Pista: No hay pista es una pavada la pregunta, pero piensenla

CART

Un árbol de decisión que intenta imitar una serie de preguntas simples para llegar a una predicción.

Sirve para dos tipos de problemas:

Regresión

Clasificación

CART

Un árbol de decisión que intenta imitar una serie de preguntas simples para llegar a una predicción.

Sirve para dos tipos de problemas:

Regresión

Clasificación

La idea clave: CART divide los datos en grupos homogéneos

CART

Se lo considera un algoritmo **voraz** (greedy)

Porque toma la mejor decisión local en cada paso, sin considerar cómo esa decisión afectará a la estructura final del árbol en el futuro

CART

Y... ¿Cómo se que preguntar primero?

¿Es lo mismo si pregunto Quien es del interior o quien tiene más de 9 de promedio primero?

CART

Y... ¿Cómo se que preguntar primero?

¿Es lo mismo si pregunto Quien es del interior o quien tiene más de 9 de promedio primero?

NO,

Y para eso se usa algo que se llama el **índice de Gini**

CART

Y... ¿Cómo se que preguntar primero?

¿Es lo mismo si pregunto Quien es del interior o quien tiene más de 9 de promedio primero?

NO,

Y para eso se usa algo que se llama el **índice de Gini**

Y también **entropía**


desorden o aleatoriedad de un sistema

CART - Gini

La pureza de un nodo indica qué tan “mezcladas” están las clases dentro de ese nodo.

CART - Gini

La pureza de un nodo indica qué tan “mezcladas” están las clases dentro de ese nodo.



En este nodo,
hay 2 de clase No Beca,
y 1 de clase Beca

CART - Gini

La pureza de un nodo indica qué tan “mezcladas” están las clases dentro de ese nodo.

Gini = 0 → Nodo puro, todos los datos son de la misma clase, **baja entropía**

Gini = 0.5 → Nodo totalmente impuro, hay la misma cantidad de datos de Clase 1 que de Clase 2, **alta entropía**

CART - Gini

La pureza de un nodo indica qué tan “mezcladas” están las clases dentro de ese nodo.

Gini = 0 → Nodo puro, todos los datos son de la misma clase

Gini = 0.5 → Nodo totalmente impuro, hay la misma cantidad de datos de Clase 1 que de Clase 2

$$\text{Gini} = 1 - \sum_{k=1}^K p_k^2$$

CART - Gini

La pureza de un nodo indica qué tan “mezcladas” están las clases dentro de ese nodo.

Gini = 0 → Nodo puro, todos los datos son de la misma clase

Gini = 0.5 → Nodo totalmente impuro, hay la misma cantidad de datos de Clase 1 que de Clase 2

$$\text{Gini} = 1 - \sum_{k=1}^K p_k^2$$

El Gini es 1 menos la suma de las probabilidades al cuadrado de cada clase.

CART - Gini

La pureza de un nodo indica qué tan “mezcladas” están las clases dentro de ese nodo.

El Gini mide probabilidad de equivocarse si clasifico al azar dentro del nodo.

CART - Gini

Buscamos predecir si una persona aprueba o no para darle un crédito bancario

Edad	Ingreso	Historial	Deuda Actual	Aprobado
25	3.5	Bueno	10	Sí
40	5.0	Malo	20	No
30	4.2	Bueno	30	Sí
22	2.8	Malo	40	No
35	6.1	Bueno	15	Sí

CART - Gini

¿Cual es nuestro benchmark? ¿O nuestra “Tirar una moneda el cielo”?

Edad	Ingreso	Historial	Deuda Actual	Aprobado
25	3.5	Bueno	10	Sí
40	5.0	Malo	20	No
30	4.2	Bueno	30	Sí
22	2.8	Malo	40	No
35	6.1	Bueno	15	Sí

CART - Gini

¿Cual es nuestro benchmark? ¿O nuestra “Tirar una moneda el cielo”?

$$\text{Gini}_{\text{Aprobado}} = 1 - \left[\left(\frac{3}{5} \right)^2 + \left(\frac{2}{5} \right)^2 \right] = 0,48$$

Edad	Ingreso	Historial	Deuda Actual	Aprobado
25	3.5	Bueno	10	Sí
40	5.0	Malo	20	No
30	4.2	Bueno	30	Sí
22	2.8	Malo	40	No
35	6.1	Bueno	15	Sí

1 - (Probabilidad que sea aprobado $[\text{3aprobados} / \text{5totales}]^2$ + Probabilidad que sea no aprobado $[\text{2noaprobados} / \text{5totales}]^2$)

CART - Gini

Probemos dividir por edad... a ver qué pasa

Edad	Ingreso	Historial	Deuda Actual	Aprobado
25	3.5	Bueno	10	Sí
40	5.0	Malo	20	No
30	4.2	Bueno	30	Sí
22	2.8	Malo	40	No
35	6.1	Bueno	15	Sí

CART - Gini

Para variables **continuas**, hay que calcular el gini en cada punto de corte, ya que siempre son DOS ramas.

No puede haber un nodo que sea **mayor a 22 Y menor a 35**

Edad	Aprobado
22	No
25	Sí
30	Sí
35	Sí
40	No

CART - Gini

Elijamos un punto de corte

Por ejemplo, **Edad < 23 y Edad > 23**

Edad	Aprobado
22	No
25	Sí
30	Sí
35	Sí
40	No

CART - Gini

Elijamos un punto de corte

Por ejemplo, **Edad < 23 y Edad > 23**

Edad $\leq$ 23: 1 instancia (0 aprobados, 1 no aprobado)

Edad > 23: 4 instancias (3 aprobados, 1 no aprobado)

Edad	Aprobado
22	No
25	Sí
30	Sí
35	Sí
40	No

CART - Gini

Elijamos un punto de corte

Por ejemplo, **Edad < 23 y Edad > 23**

Edad ≤ 23 : 1 instancia (0 aprobados, 1 no aprobado)

Edad > 23: 4 instancias (3 aprobados, 1 no aprobado)

$$\begin{aligned} \text{Gini}_{\leq 23,5} &= 1 - \left[\left(\frac{0}{1} \right)^2 + \left(\frac{1}{1} \right)^2 \right] = 0 \\ \text{Gini}_{> 23,5} &= 1 - \left[\left(\frac{3}{4} \right)^2 + \left(\frac{1}{4} \right)^2 \right] = 0,375 \\ \text{Gini}_{\text{Edad}, 23.5} &= \frac{1}{5} \times 0 + \frac{4}{5} \times 0,375 = 0,3 \end{aligned}$$

Edad	Aprobado
22	No
25	Sí
30	Sí
35	Sí
40	No

CART - Gini

Elijamos otro punto de corte,
Por ejemplo, **Edad < 27 y Edad > 27**

Edad	Aprobado
22	No
25	Sí
30	Sí
35	Sí
40	No

CART - Gini

Elijamos otro punto de corte,
Por ejemplo, **Edad < 27 y Edad > 27**

Edad $\leq$ 27: 2 instancias (1 aprobado, 1 no aprobado)

Edad > 27: 3 instancias (2 aprobados, 1 no aprobado)

Edad	Aprobado
22	No
25	Sí
30	Sí
35	Sí
40	No

CART - Gini

Elijamos otro punto de corte,
Por ejemplo, **Edad < 27 y Edad > 27**

Edad ≤ 27 : 2 instancias (1 aprobado, 1 no aprobado)

Edad > 27: 3 instancias (2 aprobados, 1 no aprobado)

$$\text{Gini}_{\leq 27,5} = 1 - \left[\left(\frac{1}{2}\right)^2 + \left(\frac{1}{2}\right)^2 \right] = 0,5$$

$$\text{Gini}_{> 27,5} = 1 - \left[\left(\frac{2}{3}\right)^2 + \left(\frac{1}{3}\right)^2 \right] = 0,444$$

$$\text{Gini}_{\text{Edad}, 27.5} = \frac{2}{5} \times 0,5 + \frac{3}{5} \times 0,444 = 0,467$$

Edad	Aprobado
22	No
25	Sí
30	Sí
35	Sí
40	No

CART - Gini

La idea es hacer eso para todos los puntos de corte

Punto de Corte	Gini
23.5	0.3
27.5	0.467
32.5	0.467
37.5	0.3

Edad	Aprobado
22	No
25	Sí
30	Sí
35	Sí
40	No

CART - Gini

La idea es hacer eso para todos los puntos de corte

Punto de Corte	Gini
23.5	0.3
27.5	0.467
32.5	0.467
37.5	0.3

Edad	Aprobado
22	No
25	Sí
30	Sí
35	Sí
40	No

¿Cual es el mejor punto de corte en este caso?

CART - Gini

¿Por qué variable les parece que estaría bueno dividir?

Edad	Ingreso	Historial	Deuda Actual	Aprobado
25	3.5	Bueno	10	Sí
40	5.0	Malo	20	No
30	4.2	Bueno	30	Sí
22	2.8	Malo	40	No
35	6.1	Bueno	15	Sí

CART - Gini

Probemos con historial

Historial	Aprobado
Bueno	Sí
Malo	No
Bueno	Sí
Malo	No
Bueno	Sí

CART - Gini

Probemos con historial

¿Ya se ve un **patrón** no?

Historial	Aprobado
Bueno	Sí
Malo	No
Bueno	Sí
Malo	No
Bueno	Sí

CART - Gini

Probemos con historial

¿Ya se ve un **patrón** no?

Igualmente, calculemos el índice de Gini

Historial	Aprobado
Bueno	Sí
Malo	No
Bueno	Sí
Malo	No
Bueno	Sí

CART - Gini

Historial = Bueno: 3 instancias (3 aprobados, 0 no aprobados)

Historial = Malo: 2 instancias (0 aprobados, 2 no aprobados)

Historial	Aprobado
Bueno	Sí
Malo	No
Bueno	Sí
Malo	No
Bueno	Sí

CART - Gini

Historial = Bueno: 3 instancias (3 aprobados, 0 no aprobados)

Historial = Malo: 2 instancias (0 aprobados, 2 no aprobados)

$$\text{Gini}_{\text{Bueno}} = 1 - \left[\left(\frac{3}{3} \right)^2 + \left(\frac{0}{3} \right)^2 \right] = 0$$

$$\text{Gini}_{\text{Malo}} = 1 - \left[\left(\frac{0}{2} \right)^2 + \left(\frac{2}{2} \right)^2 \right] = 0$$

$$\text{Gini}_{\text{Historial}} = \frac{3}{5} \times 0 + \frac{2}{5} \times 0 = 0$$

Historial	Aprobado
Bueno	Sí
Malo	No
Bueno	Sí
Malo	No
Bueno	Sí

CART - Gini

Historial = Bueno: 3 instancias (3 aprobados, 0 no aprobados)

Historial = Malo: 2 instancias (0 aprobados, 2 no aprobados)

$$\begin{aligned} \text{Gini}_{\text{Bueno}} &= 1 - \left[\left(\frac{3}{3}\right)^2 + \left(\frac{0}{3}\right)^2 \right] = 0 \\ \text{Gini}_{\text{Malo}} &= 1 - \left[\left(\frac{0}{2}\right)^2 + \left(\frac{2}{2}\right)^2 \right] = 0 \\ \text{Gini}_{\text{Historial}} &= \frac{3}{5} \times 0 + \frac{2}{5} \times 0 = 0 \end{aligned}$$

Historial	Aprobado
Bueno	Sí
Malo	No
Bueno	Sí
Malo	No
Bueno	Sí


Gini = 0, División perfecta!!!!!!!

CART - Gini

¿Cómo quedaría nuestro árbol?


CART - Gini

¿Cómo quedaría nuestro árbol?



CART - Gini

¿Cómo quedaría nuestro árbol?



CART - Gini

Hagamos un ejemplo más difícil

CART - Gini

Hagamos un ejemplo más difícil

Queremos identificar si una persona va a recibir un bono, de acuerdo con el departameno, su antigüedad y su cumplimiento de objetivos

Depto.	Antigüedad	Cumpl. de Obj.	Recibe Bono
Ventas	2	80	No
Soporte	5	60	No
Logística	3	75	Sí
Ventas	1	50	No
Soporte	4	85	Sí
Logística	6	70	No

CART - Gini

¿Como hacemos las ramas si tenemos variables categóricas **no binarias**?

Depto.	Antigüedad	Cumpl. de Obj.	Recibe Bono
Ventas	2	80	No
Soporte	5	60	No
Logística	3	75	Sí
Ventas	1	50	No
Soporte	4	85	Sí
Logística	6	70	No

CART - Gini

¿Como hacemos las ramas si tenemos variables categóricas **no binarias**?

Las convertimos en binarias

Depto.	Antigüedad	Cumpl. de Obj.	Recibe Bono
Ventas	2	80	No
Soporte	5	60	No
Logística	3	75	Sí
Ventas	1	50	No
Soporte	4	85	Sí
Logística	6	70	No

CART - Gini

Trabajemos con **Ventas vs el resto**

Ventas: 2 observaciones (0 Si, 2 No)

Soporte y Logística: 4 observaciones (2 Si, 2 No)

Depto.	Recibe Bono
Ventas	No
Soporte	No
Logística	Sí
Ventas	No
Soporte	Sí
Logística	No

CART - Gini

Trabajemos con **Ventas vs el resto**

Ventas: 2 observaciones (0 Si, 2 No)

Soporte y Logística: 4 observaciones (2 Si, 2 No)

$$\text{Gini}_{\text{Ventas}} = 1 - \left[\left(\frac{0}{2} \right)^2 + \left(\frac{2}{2} \right)^2 \right] = 0$$

$$\text{Gini}_{\text{Soporte y Logística}} = 1 - \left[\left(\frac{2}{4} \right)^2 + \left(\frac{2}{4} \right)^2 \right] = 0,5$$

$$\text{Gini}_{\text{Departamento, Ventas}} = \frac{2}{6} \times 0 + \frac{4}{6} \times 0,5 = 0,333$$

Depto.	Recibe Bono
Ventas	No
Soporte	No
Logística	Sí
Ventas	No
Soporte	Sí
Logística	No

CART - Gini

Ahora, **soporte vs el resto**

Soporte: 2 observaciones (1 Sí, 1 No)

Logística y Ventas: 4 observaciones (1 Sí, 3 No)

Depto.	Recibe Bono
Ventas	No
Soporte	No
Logística	Sí
Ventas	No
Soporte	Sí
Logística	No

CART - Gini

Ahora, **soporte vs el resto**

Soporte: 2 observaciones (1 Sí, 1 No)

Logística y Ventas: 4 observaciones (1 Sí, 3 No)

$$\text{Gini}_{\text{Soporte}} = 1 - \left[\left(\frac{1}{2} \right)^2 + \left(\frac{1}{2} \right)^2 \right] = 0,5$$

$$\text{Gini}_{\text{Logística y Ventas}} = 1 - \left[\left(\frac{1}{4} \right)^2 + \left(\frac{3}{4} \right)^2 \right] = 0,375$$

$$\text{Gini}_{\text{Departamento, Soporte}} = \frac{2}{6} \times 0,5 + \frac{4}{6} \times 0,375 = 0,4167$$

Depto.	Recibe Bono
Ventas	No
Soporte	No
Logística	Sí
Ventas	No
Soporte	Sí
Logística	No

CART - Gini

y, ¿logística vs el resto?

Soporte: 2 observaciones (1 Sí, 1 No)

Logística y Ventas: 4 observaciones (1 Sí, 3 No)

$$\text{Gini}_{\text{Logística}} = 1 - \left[\left(\frac{1}{2} \right)^2 + \left(\frac{1}{2} \right)^2 \right] = 0,5$$

$$\text{Gini}_{\text{Soporte y Ventas}} = 1 - \left[\left(\frac{1}{4} \right)^2 + \left(\frac{3}{4} \right)^2 \right] = 0,375$$

$$\text{Gini}_{\text{Departamento, Logística}} = \frac{2}{6} \times 0,5 + \frac{4}{6} \times 0,375 = 0,4167$$

Depto.	Recibe Bono
Ventas	No
Soporte	No
Logística	Sí
Ventas	No
Soporte	Sí
Logística	No

CART - Gini

El objetivo de esto, es ir armando una **tabla de Gini's**

Depto.	Antigüedad	Cumpl. de Obj.	Recibe Bono
Ventas	2	80	No
Soporte	5	60	No
Logística	3	75	Sí
Ventas	1	50	No
Soporte	4	85	Sí
Logística	6	70	No

CART - Gini

El objetivo de esto, es ir armando una **tabla de Gini's**, donde ya tenemos los de la variable Departamento

Entonces, seguimos con antigüedad y probamos tooodos los puntos de corte

Y lo mismo con Cumpl. de Objetivos

Depto.	Antigüedad	Cumpl. de Obj.	Recibe Bono
Ventas	2	80	No
Soporte	5	60	No
Logística	3	75	Sí
Ventas	1	50	No
Soporte	4	85	Sí
Logística	6	70	No

CART - Gini

El objetivo de esto, es ir armando una **tabla de Gini's**, donde ya tenemos los de la variable Departamento

Entonces, seguimos con antigüedad y probamos tooodos los puntos de corte

Y lo mismo con Cumpl. de Objetivos

Hagamos uno de cada para practicar

Depto.	Antigüedad	Cumpl. de Obj.	Recibe Bono
Ventas	2	80	No
Soporte	5	60	No
Logística	3	75	Sí
Ventas	1	50	No
Soporte	4	85	Sí
Logística	6	70	No

CART - Gini

Elijamos un punto de corte!



Antigüedad	Recibe Bono
2	No
5	No
3	Sí
1	No
4	Sí
6	No

CART - Gini

Elijamos un punto de corte!



Cumpl. de Obj.	Recibe Bono
80	No
60	No
75	Sí
50	No
85	Sí
70	No

CART - Gini

El objetivo de esto, es ir armando una **tabla de Gini's**

Variable	Partición	Gini
Cumplimiento de Objetivos	72.5	0.222
Antigüedad	3.5	0.222
Departamento	Ventas	0.333
Antigüedad	2.5	0.333
Antigüedad	4.5	0.333
Cumplimiento de Objetivos	65	0.333
Antigüedad	1.5	0.4
Antigüedad	5.5	0.4
Cumplimiento de Objetivos	55	0.4
Cumplimiento de Objetivos	82.5	0.4
Departamento	Soporte	0.4167
Departamento	Logística	0.4167
Cumplimiento de Objetivos	77.5	0.417

CART - Gini

El objetivo de esto, es ir armando una **tabla de Gini's**

¿Que vemos de distinto con la otra tabla? (Del otro ejemplo)

Variable	Partición	Gini
Cumplimiento de Objetivos	72.5	0.222
Antigüedad	3.5	0.222
Departamento	Ventas	0.333
Antigüedad	2.5	0.333
Antigüedad	4.5	0.333
Cumplimiento de Objetivos	65	0.333
Antigüedad	1.5	0.4
Antigüedad	5.5	0.4
Cumplimiento de Objetivos	55	0.4
Cumplimiento de Objetivos	82.5	0.4
Departamento	Soporte	0.4167
Departamento	Logística	0.4167
Cumplimiento de Objetivos	77.5	0.417

CART - Gini

El objetivo de esto, es ir armando una **tabla de Gini's**

¿Que vemos de distinto con la otra tabla? (Del otro ejemplo)


Tenemos que repetir! Pero primero, veamos como queda nuestro arbol

Variable	Partición	Gini
Cumplimiento de Objetivos	72.5	0.222
Antigüedad	3.5	0.222
Departamento	Ventas	0.333
Antigüedad	2.5	0.333
Antigüedad	4.5	0.333
Cumplimiento de Objetivos	65	0.333
Antigüedad	1.5	0.4
Antigüedad	5.5	0.4
Cumplimiento de Objetivos	55	0.4
Cumplimiento de Objetivos	82.5	0.4
Departamento	Soporte	0.4167
Departamento	Logística	0.4167
Cumplimiento de Objetivos	77.5	0.417


CART - Gini




CART - Gini




CART - Gini



CART - Gini



CART - Gini



Tenemos que *iterar* para resolver la impureza

CART - Gini

Nos quedan estos datos sin clasificar, todos los que cumplimiento de objetivos es > 72.5

Depto.	Antigüedad	Cumpl. de Obj.	Recibe Bono
Ventas	2	80	No
Logística	3	75	Sí
Soporte	4	85	Sí

CART - Gini

Nos quedan estos datos sin clasificar, todos los que cumplimiento de objetivos es > 72.5

Depto.	Antigüedad	Cumpl. de Obj.	Recibe Bono
Ventas	2	80	No
Logística	3	75	Sí
Soporte	4	85	Sí

¿Con qué se les ocurre que podemos dividir?

CART - Gini

Chequemos antigüedad > 2.5

Depto.	Antigüedad	Cumpl. de Obj.	Recibe Bono
Ventas	2	80	No
Logística	3	75	Sí
Soporte	4	85	Sí

CART - Gini

Chequemos antigüedad > 2.5

Antigüedad ≤ 2.5 : 1 instancia (0 Sí, 1 No)

Antigüedad > 2.5: 2 instancias (2 Sí, 0 No)

Depto.	Antigüedad	Cumpl. de Obj.	Recibe Bono
Ventas	2	80	No
Logística	3	75	Sí
Soporte	4	85	Sí

CART - Gini

Chequemos antigüedad > 2.5

Antigüedad ≤ 2.5 : 1 instancia (0 Sí, 1 No)

Antigüedad > 2.5: 2 instancias (2 Sí, 0 No)

$$\text{Gini}_{\leq 2.5} = 1 - \left[\left(\frac{0}{1} \right)^2 + \left(\frac{1}{1} \right)^2 \right] = 0$$

$$\text{Gini}_{> 2.5} = 1 - \left[\left(\frac{2}{2} \right)^2 + \left(\frac{0}{2} \right)^2 \right] = 0$$

$$\text{Gini}_{\text{Antigüedad}, 2.5} = \frac{1}{3} \times 0 + \frac{2}{3} \times 0 = 0$$

Depto.	Antigüedad	Cumpl. de Obj.	Recibe Bono
Ventas	2	80	No
Logística	3	75	Sí
Soporte	4	85	Sí

CART - Gini

Si hacemos tooodos los puntos de corte,
armamos la tablita V2

CART - Gini

Si hacemos tooodos los puntos de corte, armamos la tablita V2

Variable	Partición	Gini
Antigüedad	2.5	0
Departamento	Ventas	0
Cumplimiento de Objetivos	82.5	0.167
Departamento	Soporte	0.333
Departamento	Logística	0.333
Antigüedad	3.5	0.333
Cumplimiento de Objetivos	77.5	0.333


CART - Gini

Si hacemos tooodos los puntos de corte,
armamos la tablita V2


Y ya podemos construir nuestro árbol

Variable	Partición	Gini
Antigüedad	2.5	0
Departamento	Ventas	0
Cumplimiento de Objetivos	82.5	0.167
Departamento	Soporte	0.333
Departamento	Logística	0.333
Antigüedad	3.5	0.333
Cumplimiento de Objetivos	77.5	0.333


CART - Gini




CART - Gini




CART - Gini




CART - Gini



CART - Gini



CART - Gini




CART

Que si viene un empleado nuevo a preguntar si va a recibir un bono o no, yo puedo, de acuerdo con sus características (Años de antigüedad, Cumplimiento de objetivos y departamento), **predecirlo**

CART

¿Cómo se ve esto en Python?



CART - Regresión

Para regresión divide los datos en regiones donde los valores numéricos sean lo más parecidos posible.
Luego, cada hoja predice el promedio de los casos que contiene.

Nodo final	Predicción
Edad < 30	1100
Edad ≥ 30	5100

CART - Características importantes

Algoritmo greedy: Toma la mejor decisión local en cada paso

División binaria: Cada nodo se divide en exactamente dos ramas

Índice de Gini: Minimiza la impureza en cada division

Árbol optimo: CART garantiza el árbol con menos nodos

CART - Características importantes

Algoritmo greedy: Toma la mejor decisión local en cada paso

División binaria: Cada nodo se divide en exactamente dos ramas

Índice de Gini: Minimiza la impureza en cada division

Árbol optimo: CART garantiza el árbol con menos nodos

CART - Ventajas

- Fácil de interpretar y visualizar
- Maneja variables categóricas y numéricas
- No requiere normalización de datos
- Maneja valores faltantes automáticamente
- No es sensible a valores atípicos

CART - Desventajas

- **Propenso al sobreajuste (overfitting)**
- Inestable con pequeños cambios en los datos
- No funciona bien con relaciones no lineales complejas
- Algoritmo greedy puede no encontrar la solución óptima global

CART - Desventajas

Propenso al sobreajuste (overfitting)

CART tiene una lógica de separar los datos hasta que queden grupos homogéneos

De esta manera, aprende *el ruido* de los datos

“si puedo seguir dividiendo y mejorar aunque sea un poco, sigo dividiendo”

Eso genera árboles muy complejos.

CART - Desventajas

Propenso al sobreajuste (overfitting)

Si yo no le pongo límites a la cantidad de hojas en el árbol, termina haciendo divisiones super específicas

CART - Desventajas

Propenso al sobreajuste (overfitting)

Si yo no le pongo límites a la cantidad de hojas en el árbol, termina haciendo divisiones super específicas

El árbol empieza bien:

¿Estudió más de 3 horas?

¿Asistió a clase?

Pero si lo dejás crecer demasiado, termina haciendo cosas absurdamente específicas:

¿Estudió 3.7 horas?

¿Tiene exactamente 22 años?

¿Vive a menos de 4 km?

CART - Desventajas

Propenso al sobreajuste (overfitting)

Si yo no le pongo límites a la cantidad de hojas en el árbol, termina haciendo divisiones super específicas

El árbol empieza bien:

¿Estudió más de 3 horas?

¿Asistió a clase?

Pero si lo dejás crecer demasiado, termina haciendo cosas absurdamente específicas:


¿Estudió 3.7 horas?

¿Tiene exactamente 22 años?

¿Vive a menos de 4 km?

CART - Desventajas


Propenso al sobreajuste (overfitting)



CART - Desventajas

Propenso al sobreajuste (overfitting)

Si yo le tiro un dato nuevo, que se salga un poquito del patrón, la predicción va a ser mala



CART - Soluciones

Pruning: Técnica para reducir el sobreajuste eliminando ramas poco importantes

Validación cruzada: Para evaluar el rendimiento real del modelo

Ensemble methods: Combinar múltiples árboles (Random Forest, Gradient Boosting) para mejorar el rendimiento

Balance de clases: Considerar técnicas de balanceo cuando las clases están desbalanceadas

Selección de hiperparámetros: Ajustar parámetros como profundidad máxima y número mínimo de muestras por hoja

CART - Soluciones

Conclusión

Nunca CART va a ser el mejor modelo, pero si les va a servir como un benchmark base para identificar puntos de mejora de un modelo de predicción

Conceptos importantes

Antes de pasar al notebook, hay 2 conceptos importantes que tengo que mencionar y se van a reiterar a lo largo de la segunda parte de la materia

Conceptos importantes

1. **Feature importance**
2. **Encoders**

Feature Importance

Feature importance es una medida de qué tan importante fue cada variable para construir el modelo.

Feature Importance

Feature importance es una medida de qué tan importante fue cada variable para construir el modelo.

¿Qué variables ayudaron más a reducir la impureza (Gini o entropía) a lo largo del árbol?


Feature Importance

Feature importance es una medida de qué tan importante fue cada variable para construir el modelo.

¿Qué variables ayudaron más a reducir la impureza (Gini o entropía) a lo largo del árbol?


¿Por qué esto es importante a nivel negocio?

Feature Importance



Feature Importance

¿Cómo se ve en Python?



Encoder

Un encoder es una técnica para transformar variables categóricas en números para que los modelos de machine learning puedan trabajar con ellas.

Encoder

Un encoder es una técnica para transformar variables categóricas en números para que los modelos de machine learning puedan trabajar con ellas.

Label Encoding
One Hot Encoding
Ordinal Encoding
Target Encoding
Frequency Encoding
Binary Encoding
Hash Encoding
Mean Encoding
Count Encoding
Leave-One-Out Encoding
CatBoost Encoding
Helmert Encoding
Backward Difference Encoding
Sum Encoding
Polynomial Encoding
Base-N Encoding
Weight of Evidence (WoE) Encoding
Dummy Encoding
Feature Hashing
Embedding Encoding (deep learning)

Encoder

Encoding	Definición	Cuándo usarlo
Label Encoding	Asigna un número a cada categoría. Ej: Rojo=0, Azul=1	Cuando las categorías tienen orden (bajo, medio, alto)
One Hot Encoding	Crea una columna binaria por categoría.	Cuando las categorías NO tienen orden (país, color, profesión)
Target Encoding	Reemplaza cada categoría por el promedio del target.	Cuando hay muchas categorías y datasets grandes

Encoder

Encoding	Definición	Cuándo usarlo
Label Encoding	Asigna un número a cada categoría. Ej: Rojo=0, Azul=1	Cuando las categorías tienen orden (bajo, medio, alto)
One Hot Encoding	Crea una columna binaria por categoría.	Cuando las categorías NO tienen orden (país, color, profesión)
Target Encoding	Reemplaza cada categoría por el promedio del target.	Cuando hay muchas categorías y datasets grandes

NOTEBOOK