

Analítica de Datos


Clase 7 - Random Forest y Boosting


¿Dudas de la clase pasada?

O de la teórica

Agenda

- Métodos de ensamble
- Random Forest
- Caso de aplicación
- Kahoot





Árboles de decisión

CART

Un árbol de decisión que intenta imitar una serie de preguntas simples para llegar a una predicción.

Sirve para dos tipos de problemas: Clasificación y regresión

La idea clave: CART divide los datos en grupos homogéneos

Usamos el índice de Gini para construir el árbol que prediga con mayor exactitud

CART

Un árbol de decisión que intenta imitar una serie de preguntas simples para llegar a una predicción.

Sirve para dos tipos de problemas: Clasificación y regresión

La idea clave: CART divide los datos en grupos homogéneos

Usamos el índice de Gini para construir el árbol que prediga con mayor exactitud

¿Cuál era el problema con CART?

CART - Desventajas

Propenso al sobreajuste (overfitting)

CART tiene una lógica de separar los datos hasta que queden grupos homogéneos

De esta manera, aprende *el ruido* de los datos de entrenamiento, y si le damos nuevos datos de testeo que varían un poco, probablemente los prediga mal

¿Qué técnica se usaba para reducir este overfitting? Pista: palabra en inglés

CART - Desventajas

Propenso al sobreajuste (overfitting)

CART tiene una lógica de separar los datos hasta que queden grupos homogéneos

De esta manera, aprende *el ruido* de los datos de entrenamiento, y si le damos nuevos datos de testeo que varían un poco, probablemente los prediga mal

¿Qué técnica se usaba para reducir este overfitting? Pista: palabra en inglés

Pruning

Métodos de ensamble

¿Qué significa para ustedes ensamblar modelos?

Métodos de ensamble

Técnicas de machine learning que combinan varios modelos para obtener una predicción mejor que la de un solo modelo.

Métodos de ensamble

Técnicas de machine learning que combinan varios modelos para obtener una predicción mejor que la de un solo modelo.

En vez de confiar en un solo modelo, hago muchos modelitos y promedio los resultados

Métodos de ensamble

Técnicas de machine learning que combinan varios modelos para obtener una predicción mejor que la de un solo modelo.

En vez de confiar en un solo modelo, hago muchos modelitos y promedio los resultados

Porque los modelos individuales pueden equivocarse, pero si sus errores son distintos, al combinarlos se puede obtener una predicción más estable y precisa.

Random Forest

Random Forest

Concepto básico: Un montón de árboles de decisión trabajando juntos

Cada árbol tiene una decisión final

Se promedian los resultados y gana la clase mayoritaria

Random Forest

¿Por qué funcionan bien?

Cada árbol ve los datos de manera diferente

Si hay errores, probablemente se cancelen entre sí, entonces el resultado es más robusto y estable

Random Forest

¿Por qué funcionan bien?

Cada árbol ve los datos de manera diferente

Si hay errores, probablemente se cancelen entre sí, entonces el resultado es más robusto y estable

Random Forest - Bootstrapping

Bootstrapping es una técnica para crear nuevas muestras a partir de un dataset original, tomando observaciones con reemplazo.

“Con reemplazo” significa que, después de elegir una observación, esta vuelve a estar disponible para ser elegida otra vez.

Por eso una misma fila puede aparecer varias veces en la muestra, y otra puede no aparecer.

Un bolillero, pero que devuelvo la bolilla despues de sacar un número

Datos normales

ID		Estudiante	Horas de estudio		Asistencia (%)	Nota final	
1		Ana	2		70	58	
2		Bruno	4		80	65	
3		Carla	6		85	72	
4		Diego	3		75	60	
5		Elena	8		90	85	
6		Fabio	5		82	68	

Datos bootstrapeados

ID	Estudiante	Horas de estudio	Asistencia (%)	Nota final
1	Ana	2	70	58
2	Bruno	4	80	65
2	Bruno	4	80	65
4	Diego	3	75	60
5	Elena	8	90	85
1	Ana	2	70	58

Datos bootstrapeados

ID	Estudiante	Horas de estudio	Asistencia (%)	Nota final
1	Ana	2	70	58
2	Bruno	4	80	65
2	Bruno	4	80	65
4	Diego	3	75	60
5	Elena	8	90	85
1	Ana	2	70	58

Bootstrapping es crear muchas versiones distintas de los datos usando muestreo con reemplazo.

Random Forest

¿Por qué funcionan bien?

Cada árbol ve los datos de manera diferente

Si hay errores, probablemente se cancelen entre sí, entonces el resultado es más robusto y estable

Random Forest

¿Por qué funcionan bien?

Cada árbol ve los datos de manera diferente

Si hay errores, probablemente se cancelen entre sí, entonces el resultado es más robusto y estable

Bootstrapping + Selección de variables

Random Forest - Selección de variables

Cada nodo usa un subconjunto de variables para decidir como dividir

Cada decisión individual se toma mirando solo algunas variables candidatas.

Datos bootstrapeados

ID	Estudiante	Horas de estudio	Asistencia (%)	Trabajos entregados	Nota final
1	Ana	2	70	3	58
2	Bruno	4	80	5	65
2	Bruno	4	80	5	65
4	Diego	3	75	4	60
5	Elena	8	90	9	85
1	Ana	2	70	3	58

Datos bootstrapeados

ID	Horas de estudio	Asistencia (%)	Nota final
1	2	70	58
2	4	80	65
2	4	80	65
4	3	75	60
5	8	90	85
1	2	70	58

Datos bootstrapeados

ID	Estudiante	Horas de estudio	Asistencia (%)	Trabajos entregados	Nota final
2	Bruno	4	80	5	65
2	Bruno	4	80	5	65
5	Elena	8	90	9	85

Datos bootstrapeados

ID	Asistencia (%)	Trabajos entregados	Nota final
2	80	5	65
2	80	5	65
5	90	9	85

Random Forest

Random Forest = Bootstrapping + selección aleatoria de variables

Random Forest

Random Forest = Bootstrapping + selección aleatoria de variables

Random Forest → Utiliza Bagging

Bagging significa **Bootstrap Aggregating**.

Es un método de ensamble que consiste en entrenar muchos modelos parecidos, pero usando distintas muestras de los datos, y luego combinar sus predicciones.

Random Forest

¿Cómo funciona?


1. Se generan muestras bootstrap del dataset.
2. Para cada muestra se entrena un árbol.
3. En cada división del árbol, no se consideran todas las variables, sino un subconjunto aleatorio.
4. Se repite muchas veces, por ejemplo 100 a 1000 árboles.
5. La predicción final se decide por votación o promedio.

Random Forest

¿Cómo funciona?


1. Se generan muestras bootstrap del dataset.
2. Para cada muestra se entrena un árbol.
3. En cada división del árbol, no se consideran todas las variables, sino un subconjunto aleatorio.
4. Se repite muchas veces, por ejemplo 100 a 1000 árboles.
5. La predicción final se decide por votación o promedio.

Random Forest




83% Accuracy

Random Forest




83% Accuracy





79% Accuracy

Random Forest



83% Accuracy



79% Accuracy



Random Forest - Características principales

- **Reduce el overfitting:** Al combinar muchos árboles, evita depender de un solo árbol demasiado ajustado a los datos.
- **Maneja variables numéricas y categóricas:** Puede trabajar con distintos tipos de variables.
- **Es robusto a outliers:** Los valores extremos afectan menos porque la decisión final sale de muchos árboles
- **Proporciona importancia de variables:** Permite ver qué variables aportan más a la predicción.
- **No necesita mucho preprocesamiento:** Suele funcionar bien sin escalar variables ni hacer transformaciones complejas
- **Es rápido / paralelizable:** Los árboles pueden entrenarse en paralelo, porque son relativamente independientes.

Random Forest - Parámetros

¿Qué era un parámetro?

`n_estimators`: Cantidad de árboles a entrenar.

`max_features`: Cantidad de variables consideradas en cada división del árbol.

`max_depth`: Profundidad máxima de cada árbol.

`min_samples_split`: Mínimo de muestras necesarias para dividir un nodo.

`min_samples_leaf`: Mínimo de muestras que debe haber en una hoja.

Random Forest - Parámetros

¿Qué era un parámetro?

```
RandomForestClassifier(  
    n_estimators=100,  
    max_features="sqrt",  
    max_depth = 5  
)
```

¿Qué otro método de ensamble podemos usar?

Random Forest & Boosting

Random forest construye muchos árboles de manera paralela, y los combina entre sí

Random Forest & Boosting

Random forest construye muchos árboles de manera **paralela**, y los combina entre sí

Boosting construye un árbol, y lo va mejorando **secuencialmente** aprendiendo de los errores anteriores


Boosting

Boosting es una técnica de ensamble que combina múltiples modelos “débiles” para crear un modelo “fuerte”

A diferencia de Random Forest, que construye árboles independientes en paralelo, Boosting construye modelos secuencialmente.

Boosting

A diferencia de Random Forest, que construye árboles independientes en paralelo, Boosting construye modelos secuencialmente.



Caso de aplicación

Caso de aplicación

¿Cómo traducimos en palabras fáciles todo lo que vimos en la materia...

a alguien que no le importa para nada como funciona el machine learning?

83 %




Maria Rosa, **Pilarense**

Para reservar su turno...

Caminó 42 minutos

desde su casa, en Derqui, hasta
el Centro de Atención Primario
de Salud más cercano



Pasaron los 15 días y Maria Rosa



Pasaron los 15 días y Maria Rosa

No tuvo más síntomas



Pasaron los 15 días y Maria Rosa

No tuvo más síntomas
Se olvidó de su turno



Pasaron los 15 días y Maria Rosa

No tuvo más síntomas

Se olvidó de su turno

No quiso caminar esa distancia



Pasaron los 15 días y Maria Rosa

No tuvo más síntomas

Se olvidó de su turno

No quiso caminar esa distancia

El turno no fue cancelado

Y la paciente se ausentó.



AUSENTISMO EN TURNOS MÉDICOS

Una implementación de técnicas de
aprendizaje automático

JUAN COSTA



CONTEXTO

2022 - HOY



INTRODUCCIÓN



1. SALUD PÚBLICA

El manejo de recursos en el sistema de salud público en Argentina es un tema crucial dada la calidad, disponibilidad y eficacia del servicio.

2. AUSENTISMO

Puede conducir a una distribución ineficiente de recursos, problemas de financiación, capacidad, y continuidad en el sector de salud primario (DuMontier, 2013).

INTRODUCCIÓN




3. CONSECUENCIAS

Impacto directo en la salud de los pacientes, distribución ineficiente de recursos médicos en clínicas y tiempo ocioso tanto para los médicos como para los consultorios (Liu, 2022; Méndez & Pérez, 2020).

4. SOLUCIONES PREVIAS

Estrategias de llamadas manuales, sistemas de respuesta interactiva (IVR) y recordatorios por SMS (Parikh et al., 2010; Légaré et al., 2008; Guy et al., 2012).




MACHINE LEARNING



APRENDIZAJE AUTOMÁTICO

IMPLEMENTACIÓN EN EL SISTEMA DE SALUD MUNDIAL

Algoritmos de clasificación basados en **árboles de decisión**
a partir del desempeño competitivo y mayor transparencia



Construir un modelo de predicción de machine learning que pueda prever con que probabilidad una persona va a estar ausente a un turno programado en los CAPS

OBJETIVO

Plantear una intervención estratégica en base a las predicciones del modelo para mitigar la problemática




UNIVERSIDAD DE SAN ANDRÉS

PROPUESTA DE VALOR



Maria Rosa tiene un **79% de probabilidad** de ausentarse a su turno de clínica médica en el Centro de Atención de la Salud Primaria Toro, el día Martes 11 de noviembre a las 14hs



UNIVERSIDAD DE SAN ANDRÉS

METODOLOGÍA



METODOLOGÍA CUANTITATIVA

Implementación de Python y SQL para la construcción del modelo predictivo, utilizando el paquete scikit-learn

METODOLOGÍA

VARIABLES INDEPENDIENTES

N= 17

CARACTERÍSTICAS DEL **TURNO**

Días de espera hasta el turno, centro de salud (CAPS), fecha en que se reservó el turno, especialidad, horario del turno, mes del año del turno, día de la semana del turno, y estación del año del turno

CARACTERÍSTICAS DEL **PACIENTE**

Edad del paciente, sexo del paciente, distancia del domicilio del paciente al centro de salud, código postal, obra social, cantidad de ausencias previas y cantidad de turnos previos


FACTORES **CONTEXTUALES**

Temperatura promedio del día y presencia de lluvia

METODOLOGÍA

**VARIABLE
DEPENDIENTE**





METODOLOGÍA



FEATURE ENGINEERING

Se analizan los días de espera hasta el turno, turnos previos y ausencias previas, y la distancia del domicilio del paciente hasta el centro de salud

Se aplica *target encoding* a las variables categóricas

MANEJO DE OUTLIERS

Se detectan valores atípicos en turnos previos y ausencias previas, por lo que solo se conservaron los registros por debajo del percentil 95.

Se eliminan turnos con días de espera negativos o mayores a 90 días y se filtra Edad por $0 < \text{Edad} < 99$.

RESULTADOS 

RESULTADOS

DESCRIPTIVO

N = 1.077.201 turnos médicos

Perfil de **pacientes** |

La muestra analizada presenta una edad promedio de 26 años (DE = 18.7, rango 0–99). El 70% de los pacientes son mujeres y el 30% varones, reflejando una mayor participación femenina en la demanda de turnos.

Características de los **turnos** |

El tiempo de espera promedio entre la reserva y la atención es de 16.6 días (DE = 14.9). Las áreas con mayor volumen de turnos son pediatría (14.9%), medicina general/familiar/clínica (18.8%) y obstetricia (6.6%). Los CAPS con mayor actividad son Monterrey (8.9%), Villa Verde (7.9%) y Toro (6.6%).



RESULTADOS

DESCRIPTIVO

N = 1.077.201 turnos médicos

Comportamiento de **uso del sistema** |

La mediana de turnos previos es de 3 (IQR = 1–7) y la de ausencias previas es de 1 (IQR = 0–2), lo que sugiere una frecuencia moderada de uso con antecedentes de inasistencias ocasionales

Factores **contextuales** |

La temperatura media el día del turno fue de 17.3 °C y la precipitación promedio de 2.4 mm.




RESULTADOS

DESCRIPTIVO



Se observa que la mayor proporción de turnos (62,2%) se concentra en el rango comprendido entre 0.01 y 1.45 kilómetros, mientras que la frecuencia disminuye progresivamente a medida que aumenta la distancia.

La distancia promedio que recorren los pacientes es de 1.88 km (DE = 2.63, rango = 0.01–24.01)




RESULTADOS

DESCRIPTIVO



Se puede destacar un pico de 32.7% en el rango 25-29. A su vez, se observa un punto alto en el rango etario 95-99, que está asociado a una baja cantidad de turnos (16 ausentes sobre 56 turnos).



RESULTADOS

¿QUÉ DÍA TUVO LA **MAYOR TASA DE AUSENTISMO**
DESDE ENERO DE 2022 HASTA HOY?


UNA PISTA:   

RESULTADOS




**EL 19 DE DICIEMBRE DE 2022 HUBO
51.83% DE AUSENTISMO EN PILAR**

DESCRIPTIVO




RESULTADOS

DESCRIPTIVO



Se puede observar una disminución del ausentismo cuando hay pocos días de espera hasta el turno (0-2), pero se estabiliza en 30% luego de los 3 días.

Tasa de ausentismo por *bin* de día de espera



RESULTADOS


MODELO PREDICTIVO

RESULTADOS

MODELO PREDICTIVO

5-FOLD CV 80|20

RANDOM FOREST CLASSIFIER



RESULTADOS

PROBLEMA DE ALTO RECALL

El objetivo principal del modelo es **identificar la mayor cantidad posible de casos positivos reales**, aunque eso implique cometer algunos falsos positivos

Se busca detectar a todos los pacientes que probablemente falten (aun si algunos que sí asistirán son clasificados erróneamente como ausentes), ya que el **costo** de no anticipar una ausencia es mayor que el de realizar un contacto preventivo innecesario


MÉTRICAS

Métricas del modelo; N = 140,643		
Métrica	Modelo Accuracy	Modelo Recall
Accuracy	0.65	0.61
AUC	0.732	0.721
Recall	0.72	0.83
Especificidad	0.60	0.48
Precisión	0.52	0.48
F1-score	0.60	0.61


RESULTADOS
MATRIZ DE CONFUSIÓN

		PREDICCIÓN	
		PRESENTE	AUSENTE
REALIDAD	PRESENTE		
	AUSENTE		

RESULTADOS
MATRIZ DE CONFUSIÓN

		PREDICCIÓN	
		PRESENTE	AUSENTE
REALIDAD	PRESENTE		
	AUSENTE		

RESULTADOS
MATRIZ DE CONFUSIÓN

		PREDICCIÓN	
		PRESENTE	AUSENTE
REALIDAD	PRESENTE		
	AUSENTE		

RESULTADOS
MATRIZ DE CONFUSIÓN

		PREDICCIÓN	
		PRESENTE	AUSENTE
REALIDAD	PRESENTE		
	AUSENTE		

RESULTADOS

PROBLEMA DE ALTO RECALL

El objetivo principal del modelo es **identificar la mayor cantidad posible de casos positivos reales**, aunque eso implique cometer algunos falsos positivos


Se busca detectar a todos los pacientes que probablemente falten (aun si algunos que sí asistirán son clasificados erróneamente como ausentes), ya que el **costo** de no anticipar una ausencia es mayor que el de realizar un contacto preventivo innecesario

MÉTRICAS

Métricas del modelo; N = 140,643		
Métrica	Modelo Accuracy	Modelo Recall
Accuracy	0.65	0.61
AUC	0.732	0.721
Recall	0.72	0.83
Especificidad	0.60	0.48
Precisión	0.52	0.48
F1-score	0.60	0.61

RESULTADOS
MODELO PREDICTIVO

IMPORTANCIA
DE VARIABLES



INTERVENCIÓN




INTERVENCIÓN

OBJETIVO SMART

- * **ESPECÍFICO** | REDUCIR EL AUSENTISMO EN LA ESPECIALIDAD DE CLÍNICA MÉDICA EN CAPS
- * **MEDIBLE** | SE COMPARARÁ LA TASA DE AUSENTISMO Y CANCELACIÓN EN UN GRUPO CONTROL Y UN GRUPO TRATAMIENTO
- * **ALCANZABLE** | TÉCNICAS DE APRENDIZAJE AUTOMÁTICO E ESTRATEGIAS ESPECIALIZADAS
- * **RELEVANTE** | CLÍNICA MÉDICA ES UNA ESPECIALIDAD CON MÁS DE 20% DE AUSENTISMO
- * **CON PLAZO** | SE REALIZARÁN ANÁLISIS MENSUALES

INTERVENCIÓN

SEMAFORIZACIÓN DE LOS TURNOS




INTERVENCIÓN

1. SEMAFORIZACIÓN MODELO

SEMAFORIZACIÓN MODELO PREDICTIVO


La población se divide en **3 grupos**

Verdes los que el modelo predijo cómo no ausente
Rojos y **amarillos** los que fueron predichos cómo ausentes, divididos en partes iguales



INTERVENCIÓN

2. SEMAFORIZACIÓN COMPORTAMIENTO



SEMAFORIZACIÓN COMPORTAMIENTO

Cómo ausencias_previas no tiene tanta importancia en el modelo predictivo, se incorpora una **semaforización complementaria**

Se construye la **tabla de comportamiento individual** en donde cada paciente tiene asignado, por año, su respectiva cantidad de atenciones, ausencias y cancelaciones, y sus tasas en proporción con el total de turnos.

INTERVENCIÓN

2.SEMAFORIZACIÓN COMPORTAMIENTO



id_paciente	Año	total_turnos	cant_AU	%AU	cant_CA	%CA	cant_AT	%AT
XXXXXXXX	2022	14	1	7.14	0	0.0	13	92.86
XXXXXXXX	2023	19	3	15.0	0	0.0	16	80.0
XXXXXXXX	2024	25	5	18.52	0	0.0	20	74.07
XXXXXXXX	2025	6	2	33.33	0	0.0	4	66.67

- * **A_{ai}** = PORCENTAJE DEL AÑO A_i (POR EJEMPLO, 2022, 2023, ETC.)
- * **N_i** = AÑO ACTUAL – A_i
- * **C** = CANTIDAD DE AÑOS ANALIZADOS

$$DCP = \frac{1}{c} \sum_{i=1}^c \left(\%A_{a_i} \times (1 - (n_i \times 0.1)) \right)$$

INTERVENCIÓN

2. SEMAFORIZACIÓN COMPORTAMIENTO

DCP < 30%

VERDE

30% < DCP < 40%

AMARILLO

40% < DCP


ROJO

El objetivo de este proceso es perfeccionar la **precisión de la predicción**, agregando un peso sustancial al comportamiento específico de cada paciente, que se complementa con la predicción del modelo



INTERVENCIÓN
2.SEMAFORIZACIÓN FINAL

<i>Color Modelo</i>	<i>Color DCP</i>	<i>Color Turno</i>
Rojo	Rojo	Rojo
Rojo	Amarillo	Rojo
Rojo	Verde	Amarillo
Amarillo	Rojo	Rojo
Amarillo	Amarillo	Amarillo
Amarillo	Verde	Verde
Verde	Rojo	Rojo
Verde	Amarillo	Amarillo
Verde	Verde	Verde



INTERVENCIÓN



OPERACIONALIZACIÓN

PREDICCIÓN Y RELEVAMIENTO **SEMANAL** DE LOS TURNOS
LLAMADOS ESPECIALIZADOS A TRAVÉS DE UN CALL CENTER

Entender a la disminución de la tasa de ausentismo cómo un **aumento de atenciones** así cómo un **aumento de cancelaciones**

Queríamos consultarte si vas a poder estar presente. De no ser así, queríamos ofrecerte la posibilidad de cancelar o reprogramar.

Necesitamos confirmar tu presencia. Si no vas a poder asistir, tenés la posibilidad de cancelar o reprogramar.

Necesitamos confirmar tu presencia.
Para nosotros es importante la confirmación para poder seguir ofreciendo este servicio a otras personas que lo necesitan.

INTERVENCIÓN

PARTICIPANTES



Pacientes de **CAPS** en clínica médica

Aproximadamente **5.200** turnos mensuales

Muestreo aleatorio estratificado por color de turno | 20% - 80%



INTERVENCIÓN

EVALUACIÓN

PERÍODO DE OBSERVACIÓN | 3 A 6 MESES

ENFOQUE CUANTITATIVO

Tasa de ausentismo y cancelación, contactos efectivos, número de intentos hasta el contacto, cumplimiento del compromiso

ENFOQUE CUALITATIVO

Codificación de motivos de cancelación y patrones de respuesta, reportes regulares de observaciones relevantes y evaluación de diferencias según color del grupo

INTERVENCIÓN

RENDIMIENTO

OCTUBRE 2025

INTERVENCIÓN
RESULTADOS



RENDIMIENTO
OCTUBRE



TASA DE **AUSENTISMO** DE TURNOS **ROJOS**
OCTUBRE 2025

GRUPO **CONTROL**

29%

GRUPO **TRATAMIENTO SIN CE***

29%

***CE** = Contacto efectivo; Un paciente que fue llamado y contestó confirmando o cancelando el turno

TASA DE **AUSENTISMO** DE TURNOS **ROJOS**
OCTUBRE 2025

GRUPO **CONTROL**

29%

GRUPO **TRATAMIENTO SIN CE***

29%

GRUPO **TRATAMIENTO CON CE***

18%

***CE** = Contacto efectivo; Un paciente que fue llamado y contestó confirmando o cancelando el turno

DISCUSIÓN ↖




DISCUSIÓN

PRINCIPALES HALLAZGOS


- * La variable más explicativa del ausentismo es el número de **días de espera** entre la reserva y la cita
- * Se utiliza un modelo basado en **árboles de decisión** (Random Forest) (Salazar et al., 2021)
- * La **intervención** se diseña combinando *machine learning* + técnicas de modificación de conducta, apoyada en evidencia previa sobre la efectividad de mensajes recordatorios (Guy et al., 2012)
- * Se prioriza un enfoque de **alto recall**, maximizando la detección de pacientes con alto riesgo de inasistencia (Gupta et al., 2021)

DISCUSIÓN

LIMITACIONES



ANTIGÜEDAD LIMITADA DE LOS DATOS



AUSENCIA DE VARIABLES SOCIODEMOGRÁFICAS



PROBLEMAS EN LA CALIDAD DE LOS DATOS Y EN LA TRAZABILIDAD



FACTORES SOCIOCULTURALES ESTRUCTURALES DEL AUSENTISMO



FALTA DE COMPONENTE CUALITATIVO COMPLEMENTARIO

CONCLUSIÓN





Universidad de
SanAndrés



JUAN COSTA

83 %




Maria Rosa, **Pilarense**

Para reservar su turno...

Caminó 42 minutos

desde su casa, en Derqui, hasta
el Centro de Atención Primario
de Salud más cercano



Pasaron los 15 días y Maria Rosa



Pasaron los 15 días y Maria Rosa

No tuvo más síntomas



Pasaron los 15 días y Maria Rosa

No tuvo más síntomas
Se olvidó de su turno



Pasaron los 15 días y Maria Rosa

No tuvo más síntomas

Se olvidó de su turno

No quiso caminar esa distancia



Pasaron los 15 días y Maria Rosa

No tuvo más síntomas

Se olvidó de su turno

No quiso caminar esa distancia

El turno no fue cancelado

Y la paciente se ausentó.



AUSENTISMO EN TURNOS MÉDICOS

Una implementación de técnicas de
aprendizaje automático

JUAN COSTA



CONTEXTO

2022 - HOY



INTRODUCCIÓN



1. SALUD PÚBLICA

El manejo de recursos en el sistema de salud público en Argentina es un tema crucial dada la calidad, disponibilidad y eficacia del servicio.

2. AUSENTISMO

Puede conducir a una distribución ineficiente de recursos, problemas de financiación, capacidad, y continuidad en el sector de salud primario (DuMontier, 2013).

INTRODUCCIÓN




3. CONSECUENCIAS

Impacto directo en la salud de los pacientes, distribución ineficiente de recursos médicos en clínicas y tiempo ocioso tanto para los médicos como para los consultorios (Liu, 2022; Méndez & Pérez, 2020).

4. SOLUCIONES PREVIAS

Estrategias de llamadas manuales, sistemas de respuesta interactiva (IVR) y recordatorios por SMS (Parikh et al., 2010; Légaré et al., 2008; Guy et al., 2012).




MACHINE LEARNING



APRENDIZAJE AUTOMÁTICO

IMPLEMENTACIÓN EN EL SISTEMA DE SALUD MUNDIAL

Algoritmos de clasificación basados en **árboles de decisión**
a partir del desempeño competitivo y mayor transparencia



Construir un modelo de predicción de machine learning que pueda prever con que probabilidad una persona va a estar ausente a un turno programado en los CAPS

OBJETIVO

Plantear una intervención estratégica en base a las predicciones del modelo para mitigar la problemática




UNIVERSIDAD DE SAN ANDRÉS

PROPUESTA DE VALOR



Maria Rosa tiene un **79% de probabilidad** de ausentarse a su turno de clínica médica en el Centro de Atención de la Salud Primaria Toro, el día Martes 11 de noviembre a las 14hs



UNIVERSIDAD DE SAN ANDRÉS

METODOLOGÍA



METODOLOGÍA CUANTITATIVA

Implementación de Python y SQL para la construcción del modelo predictivo, utilizando el paquete scikit-learn

METODOLOGÍA

VARIABLES INDEPENDIENTES

N= 17

CARACTERÍSTICAS DEL **TURNO**

Días de espera hasta el turno, centro de salud (CAPS), fecha en que se reservó el turno, especialidad, horario del turno, mes del año del turno, día de la semana del turno, y estación del año del turno

CARACTERÍSTICAS DEL **PACIENTE**

Edad del paciente, sexo del paciente, distancia del domicilio del paciente al centro de salud, código postal, obra social, cantidad de ausencias previas y cantidad de turnos previos


FACTORES **CONTEXTUALES**

Temperatura promedio del día y presencia de lluvia

METODOLOGÍA

**VARIABLE
DEPENDIENTE**





METODOLOGÍA



FEATURE ENGINEERING

Se analizan los días de espera hasta el turno, turnos previos y ausencias previas, y la distancia del domicilio del paciente hasta el centro de salud

Se aplica *target encoding* a las variables categóricas

MANEJO DE OUTLIERS

Se detectan valores atípicos en turnos previos y ausencias previas, por lo que solo se conservaron los registros por debajo del percentil 95.

Se eliminan turnos con días de espera negativos o mayores a 90 días y se filtra Edad por $0 < \text{Edad} < 99$.

RESULTADOS

RESULTADOS

DESCRIPTIVO

N = 1.077.201 turnos médicos

Perfil de **pacientes** |

La muestra analizada presenta una edad promedio de 26 años (DE = 18.7, rango 0–99). El 70% de los pacientes son mujeres y el 30% varones, reflejando una mayor participación femenina en la demanda de turnos.

Características de los **turnos** |

El tiempo de espera promedio entre la reserva y la atención es de 16.6 días (DE = 14.9). Las áreas con mayor volumen de turnos son pediatría (14.9%), medicina general/familiar/clínica (18.8%) y obstetricia (6.6%). Los CAPS con mayor actividad son Monterrey (8.9%), Villa Verde (7.9%) y Toro (6.6%).



RESULTADOS

DESCRIPTIVO

N = 1.077.201 turnos médicos

Comportamiento de **uso del sistema** |

La mediana de turnos previos es de 3 (IQR = 1–7) y la de ausencias previas es de 1 (IQR = 0–2), lo que sugiere una frecuencia moderada de uso con antecedentes de inasistencias ocasionales

Factores **contextuales** |

La temperatura media el día del turno fue de 17.3 °C y la precipitación promedio de 2.4 mm.




RESULTADOS

DESCRIPTIVO



Se observa que la mayor proporción de turnos (62,2%) se concentra en el rango comprendido entre 0.01 y 1.45 kilómetros, mientras que la frecuencia disminuye progresivamente a medida que aumenta la distancia.

La distancia promedio que recorren los pacientes es de 1.88 km (DE = 2.63, rango = 0.01–24.01)




RESULTADOS

DESCRIPTIVO



Se puede destacar un pico de 32.7% en el rango 25-29. A su vez, se observa un punto alto en el rango etario 95-99, que está asociado a una baja cantidad de turnos (16 ausentes sobre 56 turnos).



RESULTADOS

¿QUÉ DÍA TUVO LA **MAYOR TASA DE AUSENTISMO**
DESDE ENERO DE 2022 HASTA HOY?


UNA PISTA:   

RESULTADOS




**EL 19 DE DICIEMBRE DE 2022 HUBO
51.83% DE AUSENTISMO EN PILAR**

DESCRIPTIVO




RESULTADOS

DESCRIPTIVO



Se puede observar una disminución del ausentismo cuando hay pocos días de espera hasta el turno (0-2), pero se estabiliza en 30% luego de los 3 días.

Tasa de ausentismo por *bin* de día de espera



RESULTADOS


MODELO PREDICTIVO

RESULTADOS

MODELO PREDICTIVO

5-FOLD CV 80|20

RANDOM FOREST CLASSIFIER



RESULTADOS

PROBLEMA DE ALTO RECALL

El objetivo principal del modelo es **identificar la mayor cantidad posible de casos positivos reales**, aunque eso implique cometer algunos falsos positivos

Se busca detectar a todos los pacientes que probablemente falten (aun si algunos que sí asistirán son clasificados erróneamente como ausentes), ya que el **costo** de no anticipar una ausencia es mayor que el de realizar un contacto preventivo innecesario


MÉTRICAS

Métricas del modelo; N = 140,643		
Métrica	Modelo Accuracy	Modelo Recall
Accuracy	0.65	0.61
AUC	0.732	0.721
Recall	0.72	0.83
Especificidad	0.60	0.48
Precisión	0.52	0.48
F1-score	0.60	0.61


RESULTADOS
MATRIZ DE CONFUSIÓN

		PREDICCIÓN	
		PRESENTE	AUSENTE
REALIDAD	PRESENTE		
	AUSENTE		

RESULTADOS
MATRIZ DE CONFUSIÓN

		PREDICCIÓN	
		PRESENTE	AUSENTE
REALIDAD	PRESENTE		
	AUSENTE		

RESULTADOS
MATRIZ DE CONFUSIÓN

		PREDICCIÓN	
		PRESENTE	AUSENTE
REALIDAD	PRESENTE		
	AUSENTE		

RESULTADOS
MATRIZ DE CONFUSIÓN

		PREDICCIÓN	
		PRESENTE	AUSENTE
REALIDAD	PRESENTE		
	AUSENTE		

RESULTADOS

PROBLEMA DE ALTO RECALL

El objetivo principal del modelo es **identificar la mayor cantidad posible de casos positivos reales**, aunque eso implique cometer algunos falsos positivos


Se busca detectar a todos los pacientes que probablemente falten (aun si algunos que sí asistirán son clasificados erróneamente como ausentes), ya que el **costo** de no anticipar una ausencia es mayor que el de realizar un contacto preventivo innecesario

MÉTRICAS

Métricas del modelo; N = 140,643		
Métrica	Modelo Accuracy	Modelo Recall
Accuracy	0.65	0.61
AUC	0.732	0.721
Recall	0.72	0.83
Especificidad	0.60	0.48
Precisión	0.52	0.48
F1-score	0.60	0.61

RESULTADOS
MODELO PREDICTIVO

IMPORTANCIA
DE VARIABLES



INTERVENCIÓN




INTERVENCIÓN

OBJETIVO SMART

- * **ESPECÍFICO** | REDUCIR EL AUSENTISMO EN LA ESPECIALIDAD DE CLÍNICA MÉDICA EN CAPS
- * **MEDIBLE** | SE COMPARARÁ LA TASA DE AUSENTISMO Y CANCELACIÓN EN UN GRUPO CONTROL Y UN GRUPO TRATAMIENTO
- * **ALCANZABLE** | TÉCNICAS DE APRENDIZAJE AUTOMÁTICO E ESTRATEGIAS ESPECIALIZADAS
- * **RELEVANTE** | CLÍNICA MÉDICA ES UNA ESPECIALIDAD CON MÁS DE 20% DE AUSENTISMO
- * **CON PLAZO** | SE REALIZARÁN ANÁLISIS MENSUALES

INTERVENCIÓN

SEMAFORIZACIÓN DE LOS TURNOS




INTERVENCIÓN

1. SEMAFORIZACIÓN MODELO

SEMAFORIZACIÓN MODELO PREDICTIVO


La población se divide en **3 grupos**

Verdes los que el modelo predijo cómo no ausente
Rojos y **amarillos** los que fueron predichos cómo ausentes, divididos en partes iguales



INTERVENCIÓN

2. SEMAFORIZACIÓN COMPORTAMIENTO



SEMAFORIZACIÓN COMPORTAMIENTO

Cómo ausencias_previas no tiene tanta importancia en el modelo predictivo, se incorpora una **semaforización complementaria**

Se construye la **tabla de comportamiento individual** en donde cada paciente tiene asignado, por año, su respectiva cantidad de atenciones, ausencias y cancelaciones, y sus tasas en proporción con el total de turnos.

INTERVENCIÓN

2.SEMAFORIZACIÓN COMPORTAMIENTO



id_paciente	Año	total_turnos	cant_AU	%AU	cant_CA	%CA	cant_AT	%AT
XXXXXXXX	2022	14	1	7.14	0	0.0	13	92.86
XXXXXXXX	2023	19	3	15.0	0	0.0	16	80.0
XXXXXXXX	2024	25	5	18.52	0	0.0	20	74.07
XXXXXXXX	2025	6	2	33.33	0	0.0	4	66.67

- * **A_{ai}** = PORCENTAJE DEL AÑO A_i (POR EJEMPLO, 2022, 2023, ETC.)
- * **N_i** = AÑO ACTUAL – A_i
- * **C** = CANTIDAD DE AÑOS ANALIZADOS

$$DCP = \frac{1}{c} \sum_{i=1}^c \left(\%A_{a_i} \times (1 - (n_i \times 0.1)) \right)$$

INTERVENCIÓN

2. SEMAFORIZACIÓN COMPORTAMIENTO

DCP < 30%

VERDE

30% < DCP < 40%

AMARILLO

40% < DCP

ROJO

El objetivo de este proceso es perfeccionar la **precisión de la predicción**, agregando un peso sustancial al comportamiento específico de cada paciente, que se complementa con la predicción del modelo



INTERVENCIÓN

2.SEMAFORIZACIÓN FINAL

<i>Color Modelo</i>	<i>Color DCP</i>	<i>Color Turno</i>
Rojo	Rojo	Rojo
Rojo	Amarillo	Rojo
Rojo	Verde	Amarillo
Amarillo	Rojo	Rojo
Amarillo	Amarillo	Amarillo
Amarillo	Verde	Verde
Verde	Rojo	Rojo
Verde	Amarillo	Amarillo
Verde	Verde	Verde



INTERVENCIÓN



OPERACIONALIZACIÓN

PREDICCIÓN Y RELEVAMIENTO **SEMANAL** DE LOS TURNOS
LLAMADOS ESPECIALIZADOS A TRAVÉS DE UN CALL CENTER

Entender a la disminución de la tasa de ausentismo cómo un **aumento de atenciones** así cómo un **aumento de cancelaciones**

Queríamos consultarte si vas a poder estar presente. De no ser así, queríamos ofrecerte la posibilidad de cancelar o reprogramar.

Necesitamos confirmar tu presencia. Si no vas a poder asistir, tenés la posibilidad de cancelar o reprogramar.

Necesitamos confirmar tu presencia.
Para nosotros es importante la confirmación para poder seguir ofreciendo este servicio a otras personas que lo necesitan.

INTERVENCIÓN

PARTICIPANTES



Pacientes de **CAPS** en clínica médica

Aproximadamente **5.200** turnos mensuales

Muestreo aleatorio estratificado por color de turno | 20% - 80%



INTERVENCIÓN

EVALUACIÓN

PERÍODO DE OBSERVACIÓN | 3 A 6 MESES

ENFOQUE CUANTITATIVO

Tasa de ausentismo y cancelación, contactos efectivos, número de intentos hasta el contacto, cumplimiento del compromiso

ENFOQUE CUALITATIVO

Codificación de motivos de cancelación y patrones de respuesta, reportes regulares de observaciones relevantes y evaluación de diferencias según color del grupo

INTERVENCIÓN

RENDIMIENTO

OCTUBRE 2025

INTERVENCIÓN
RESULTADOS



RENDIMIENTO
OCTUBRE



TASA DE **AUSENTISMO** DE TURNOS **ROJOS**
OCTUBRE 2025

GRUPO **CONTROL**

29%

GRUPO **TRATAMIENTO SIN CE***

29%

***CE** = Contacto efectivo; Un paciente que fue llamado y contestó confirmando o cancelando el turno

TASA DE **AUSENTISMO** DE TURNOS **ROJOS**
OCTUBRE 2025

GRUPO **CONTROL**

29%

GRUPO **TRATAMIENTO SIN CE***

29%

GRUPO **TRATAMIENTO CON CE***

18%

***CE** = Contacto efectivo; Un paciente que fue llamado y contestó confirmando o cancelando el turno

DISCUSIÓN ↖




DISCUSIÓN

PRINCIPALES HALLAZGOS


- * La variable más explicativa del ausentismo es el número de **días de espera** entre la reserva y la cita
- * Se utiliza un modelo basado en **árboles de decisión** (Random Forest) (Salazar et al., 2021)
- * La **intervención** se diseña combinando *machine learning* + técnicas de modificación de conducta, apoyada en evidencia previa sobre la efectividad de mensajes recordatorios (Guy et al., 2012)
- * Se prioriza un enfoque de **alto recall**, maximizando la detección de pacientes con alto riesgo de inasistencia (Gupta et al., 2021)

DISCUSIÓN

LIMITACIONES



ANTIGÜEDAD LIMITADA DE LOS DATOS



AUSENCIA DE VARIABLES SOCIODEMOGRÁFICAS



PROBLEMAS EN LA CALIDAD DE LOS DATOS Y EN LA TRAZABILIDAD



FACTORES SOCIOCULTURALES ESTRUCTURALES DEL AUSENTISMO



FALTA DE COMPONENTE CUALITATIVO COMPLEMENTARIO



CONCLUSIÓN



Universidad de
SanAndrés



JUAN COSTA