

Analítica de Datos

Clase 10 - Naive Bayes

Hola
¿Qué onda el parcial?

Agenda

- TP de Pablo
- Repaso del Examen
- Naive Bayes
- Ejercicios de Final

Examen

Naive Bayes

Algoritmo de ML basado en el teorema de Bayes

Naive Bayes

Algoritmo de ML basado en el teorema de Bayes

Asume independencia condicional entre características

Naive Bayes

Algoritmo de ML basado en el teorema de Bayes

Asume independencia condicional entre características

¿Pasa esto en la vida real?

Naive Bayes

Algoritmo de ML basado en el teorema de Bayes

Asume independencia condicional entre características

¿Pasa esto en la vida real?

Naive Bayes

Naive Bayes

Asume independencia condicional entre características

Un solicitante de préstamo es deseable o no dependiendo de

- sus ingresos
- historial de préstamos
- transacciones anteriores
- edad
- ubicación.

Incluso si estas características son interdependientes, estas características se consideran de forma independiente.


Teorema de Bayes

$$P(Y|X) = \frac{P(X|Y)P(Y)}{P(X)}$$

Naive Bayes

Asume que las características son **independientes**

$$P(Y|X) = \frac{P(X|Y)P(Y)}{P(X)}$$



$$P(X | Y) = P(X_1 | Y) \times P(X_2 | Y) \times \dots \times P(X_n | Y)$$

Naive Bayes

Asume que las características son independientes

$$P(Y|X) = \frac{P(X|Y)P(Y)}{P(X)}$$

$$P(X | Y) = P(X_1 | Y) \times P(X_2 | Y) \times \cdots \times P(X_n | Y)$$

¿Cómo se traduce esto?

Naive Bayes

- **BernoulliNB**: para variables binarias (presencia/ausencia de una característica).
- **CategoricalNB**: para datos categóricos o discretos.
- **MultinomialNB**: para conteos y frecuencias (por ejemplo, clasificación de texto).
- **ComplementNB**: para situaciones con clases desbalanceadas.
- **GaussianNB**: para variables continuas (asume distribución normal).

Naive Bayes

- **BernoulliNB**: para variables binarias (presencia/ausencia de una característica).
- **CategoricalNB**: para datos categóricos o discretos. 
- **MultinomialNB**: para conteos y frecuencias (por ejemplo, clasificación de texto).
- **ComplementNB**: para situaciones con clases desbalanceadas.
- **GaussianNB**: para variables continuas (asume distribución normal).

Tiempo de estudio	Método de estudio	Puntuación	Resultado
Bajo	Lectura	Bajo	Desaprobó
Bajo	Práctica	Alta	Aprobó
Moderado	L y P	Promedio	Aprobó
Alto	L y P	Alta	Aprobó
Alto	Lectura	Alta	Desaprobó
Bajo	L y P	Baja	Desaprobó
Alto	Práctica	Alta	Aprobó
Moderado	Lectura	Alta	Aprobó
Moderado	L y P	Promedio	Aprobó
Moderado	Práctica	Bajo	Desaprobó

Naive Bayes

Dadas una serie de características X1 (Tiempo de estudio), X2 (Método de estudio), y X3 (Puntuación), ¿Cual es la probabilidad de Y (Resultado)?

Tiempo de estudio	Método de estudio	Puntuación	Resultado
Bajo	Lectura	Bajo	Desaprobó
Bajo	Práctica	Alta	Aprobó
Moderado	L y P	Promedio	Aprobó
Alto	L y P	Alta	Aprobó
Alto	Lectura	Alta	Desaprobó
Bajo	L y P	Baja	Desaprobó
Alto	Práctica	Alta	Aprobó
Moderado	Lectura	Alta	Aprobó
Moderado	L y P	Promedio	Aprobó
Moderado	Práctica	Bajo	Desaprobó

Naive Bayes

Dadas una serie de características X1 (Tiempo de estudio), X2 (Método de estudio), y X3 (Puntuación), ¿Cual es la probabilidad de Y (Resultado)?

$$P(X | Y) = P(X_1 | Y) \times P(X_2 | Y) \times \dots \times P(X_n | Y)$$

Tiempo de estudio	Método de estudio	Puntuación	Resultado
Bajo	Lectura	Bajo	Desaprobó
Bajo	Práctica	Alta	Aprobó
Moderado	L y P	Promedio	Aprobó
Alto	L y P	Alta	Aprobó
Alto	Lectura	Alta	Desaprobó
Bajo	L y P	Baja	Desaprobó
Alto	Práctica	Alta	Aprobó
Moderado	Lectura	Alta	Aprobó
Moderado	L y P	Promedio	Aprobó
Moderado	Práctica	Bajo	Desaprobó

Naive Bayes

¿Cómo funciona Naive Bayes?

*¿Y qué van a tener que hacer en el final
hipermegaconfirmado por Pablo?*

Tiempo de estudio	Método de estudio	Puntuación	Resultado
Bajo	Lectura	Bajo	Desaprobó
Bajo	Práctica	Alta	Aprobó
Moderado	L y P	Promedio	Aprobó
Alto	L y P	Alta	Aprobó
Alto	Lectura	Alta	Desaprobó
Bajo	L y P	Baja	Desaprobó
Alto	Práctica	Alta	Aprobó
Moderado	Lectura	Alta	Aprobó
Moderado	L y P	Promedio	Aprobó
Moderado	Práctica	Bajo	Desaprobó

Naive Bayes

Lo que van a tener que hacer es tablas de frecuencia

Tiempo de estudio	Método de estudio	Puntuación	Resultado
Bajo	Lectura	Bajo	Desaprobó
Bajo	Práctica	Alta	Aprobó
Moderado	L y P	Promedio	Aprobó
Alto	L y P	Alta	Aprobó
Alto	Lectura	Alta	Desaprobó
Bajo	L y P	Baja	Desaprobó
Alto	Práctica	Alta	Aprobó
Moderado	Lectura	Alta	Aprobó
Moderado	L y P	Promedio	Aprobó
Moderado	Práctica	Bajo	Desaprobó

Naive Bayes

Lo que van a tener que hacer es tablas de frecuencia

Tiempo de estudio

Tiempo	Aprobó	Desaprobó
Bajo	1	2
Moderado	3	1
Alto	2	1
Total	6	4

Tiempo de estudio	Método de estudio	Puntuación	Resultado
Bajo	Lectura	Bajo	Desaprobó
Bajo	Práctica	Alta	Aprobó
Moderado	L y P	Promedio	Aprobó
Alto	L y P	Alta	Aprobó
Alto	Lectura	Alta	Desaprobó
Bajo	L y P	Baja	Desaprobó
Alto	Práctica	Alta	Aprobó
Moderado	Lectura	Alta	Aprobó
Moderado	L y P	Promedio	Aprobó
Moderado	Práctica	Bajo	Desaprobó

Naive Bayes

Lo que van a tener que hacer es tablas de frecuencia

Método de estudio

Método	Aprobó	Desaprobó
Lectura	1	2
Práctica	2	1
L y P	3	1
Total	6	4

Tiempo de estudio	Método de estudio	Puntuación	Resultado
Bajo	Lectura	Bajo	Desaprobó
Bajo	Práctica	Alta	Aprobó
Moderado	L y P	Promedio	Aprobó
Alto	L y P	Alta	Aprobó
Alto	Lectura	Alta	Desaprobó
Bajo	L y P	Baja	Desaprobó
Alto	Práctica	Alta	Aprobó
Moderado	Lectura	Alta	Aprobó
Moderado	L y P	Promedio	Aprobó
Moderado	Práctica	Bajo	Desaprobó

Naive Bayes

Lo que van a tener que hacer es tablas de frecuencia

Puntuación en exámenes anteriores

Puntuación	Aprobó	Desaprobó
Bajo	0	3
Promedio	2	0
Alto	4	1
Total	6	4

Tiempo de estudio	Método de estudio	Puntuación	Resultado
Bajo	Lectura	Bajo	Desaprobó
Bajo	Práctica	Alta	Aprobó
Moderado	L y P	Promedio	Aprobó
Alto	L y P	Alta	Aprobó
Alto	Lectura	Alta	Desaprobó
Bajo	L y P	Baja	Desaprobó
Alto	Práctica	Alta	Aprobó
Moderado	Lectura	Alta	Aprobó
Moderado	L y P	Promedio	Aprobó
Moderado	Práctica	Bajo	Desaprobó

Método	Aprobó	Desaprobó
Lectura	1	2
Práctica	2	1
L y P	3	1
Total	6	4

Ahora que ya hicimos la tabla de frecuencia, calculamos las probabilidades y las multiplicamos (Porque las características son independientes)

Puntuación	Aprobó	Desaprobó
Bajo	0	3
Promedio	2	0
Alto	4	1
Total	6	4

Tiempo	Aprobó	Desaprobó
Bajo	1	2
Moderado	3	1
Alto	2	1
Total	6	4

Método	Aprobó	Desaprobó
Lectura	1	2
Práctica	2	1
L y P	3	1
Total	6	4

Ahora que ya hicimos la tabla de frecuencia, calculamos las probabilidades y las multiplicamos (Porque las características son independientes)

Puntuación	Aprobó	Desaprobó
Bajo	0	3
Promedio	2	0
Alto	4	1
Total	6	4

Calcular la probabilidad apriori, y la probabilidad de cada una de las características

Tiempo	Aprobó	Desaprobó
Bajo	1	2
Moderado	3	1
Alto	2	1
Total	6	4

Método	Aprobó	Desaprobó
Lectura	1	2
Práctica	2	1
L y P	3	1
Total	6	4

Ahora que ya hicimos la tabla de frecuencia, calculamos las probabilidades y las multiplicamos (Porque las características son independientes)

Puntuación	Aprobó	Desaprobó
Bajo	0	3
Promedio	2	0
Alto	4	1
Total	6	4

Calcular la probabilidad apriori, y la probabilidad de cada una de las características

Nos fijamos cual de las clases tiene más probabilidad

Tiempo	Aprobó	Desaprobó
Bajo	1	2
Moderado	3	1
Alto	2	1
Total	6	4

Método	Aprobó	Desaprobó
Lectura	1	2
Práctica	2	1
L y P	3	1
Total	6	4

Ahora que ya hicimos la tabla de frecuencia, calculamos las probabilidades y las multiplicamos (Porque las características son independientes)

Puntuación	Aprobó	Desaprobó
Bajo	0	3
Promedio	2	0
Alto	4	1
Total	6	4

Calcular la probabilidad apriori, y la probabilidad de cada una de las características

Nos fijamos cual de las clases tiene más probabilidad

Tiempo	Aprobó	Desaprobó
Bajo	1	2
Moderado	3	1
Alto	2	1
Total	6	4

Categorizamos

Método	Aprobó	Desaprobó
Lectura	1	2
Práctica	2	1
L y P	3	1
Total	6	4

Probabilidades a priori:

$$P(Aprobó) = \frac{6}{10} = 0,6$$

$$P(Desaprobó) = \frac{4}{10} = 0,4$$

Puntuación	Aprobó	Desaprobó
Bajo	0	3
Promedio	2	0
Alto	4	1
Total	6	4

Tiempo	Aprobó	Desaprobó
Bajo	1	2
Moderado	3	1
Alto	2	1
Total	6	4

Método	Aprobó	Desaprobó
Lectura	1	2
Práctica	2	1
L y P	3	1
Total	6	4

Probabilidades a priori:

$$P(Aprobó) = \frac{6}{10} = 0,6$$

$$P(Desaprobó) = \frac{4}{10} = 0,4$$

Puntuación	Aprobó	Desaprobó
Bajo	0	3
Promedio	2	0
Alto	4	1
Total	6	4

Nuevo caso: Alto tiempo, L y P método, Alta puntuación

Tiempo	Aprobó	Desaprobó
Bajo	1	2
Moderado	3	1
Alto	2	1
Total	6	4

Método	Aprobó	Desaprobó
Lectura	1	2
Práctica	2	1
L y P	3	1
Total	6	4

Puntuación	Aprobó	Desaprobó
Bajo	0	3
Promedio	2	0
Alto	4	1
Total	6	4

Tiempo	Aprobó	Desaprobó
Bajo	1	2
Moderado	3	1
Alto	2	1
Total	6	4

Probabilidades a priori:

$$P(Aprobó) = \frac{6}{10} = 0,6$$

$$P(Desaprobó) = \frac{4}{10} = 0,4$$

Nuevo caso: Alto tiempo, L y P método, Alta puntuación

$$P(Aprobó|X) = 0,6 \times \frac{2}{6} \times \frac{3}{6} \times \frac{4}{6} = 0,13$$

Método	Aprobó	Desaprobó
Lectura	1	2
Práctica	2	1
L y P	3	1
Total	6	4

Puntuación	Aprobó	Desaprobó
Bajo	0	3
Promedio	2	0
Alto	4	1
Total	6	4

Tiempo	Aprobó	Desaprobó
Bajo	1	2
Moderado	3	1
Alto	2	1
Total	6	4

Probabilidades a priori:

$$P(Aprobó) = \frac{6}{10} = 0,6$$

$$P(Desaprobó) = \frac{4}{10} = 0,4$$

Nuevo caso: Alto tiempo, L y P método, Alta puntuación

$$P(Aprobó|X) = 0,6 \times \frac{2}{6} \times \frac{3}{6} \times \frac{4}{6} = 0,13$$

$$P(Desaprobó|X) = 0,4 \times \frac{1}{4} \times \frac{1}{4} \times \frac{1}{4} = 0,006$$

Método	Aprobó	Desaprobó
Lectura	1	2
Práctica	2	1
L y P	3	1
Total	6	4

Puntuación	Aprobó	Desaprobó
Bajo	0	3
Promedio	2	0
Alto	4	1
Total	6	4

Tiempo	Aprobó	Desaprobó
Bajo	1	2
Moderado	3	1
Alto	2	1
Total	6	4

Probabilidades a priori:

$$P(Aprobó) = \frac{6}{10} = 0,6$$

$$P(Desaprobó) = \frac{4}{10} = 0,4$$

Nuevo caso: Alto tiempo, L y P método, Alta puntuación

$$P(Aprobó|X) = 0,6 \times \frac{2}{6} \times \frac{3}{6} \times \frac{4}{6} = 0,13$$

$$P(Desaprobó|X) = 0,4 \times \frac{1}{4} \times \frac{1}{4} \times \frac{1}{4} = 0,006$$

Predicción: Aprobó ($0.13 > 0.006$)

Método	Aprobó	Desaprobó
Lectura	1	2
Práctica	2	1
L y P	3	1
Total	6	4

Puntuación	Aprobó	Desaprobó
Bajo	0	3
Promedio	2	0
Alto	4	1
Total	6	4

Tiempo	Aprobó	Desaprobó
Bajo	1	2
Moderado	3	1
Alto	2	1
Total	6	4

¡Llegó un alumno nuevo! Práctico para el examen, Tiene un puntaje Promedio en exámenes anteriores y Tiene un tiempo bajo de estudio. ¿Va a aprobar o no?

Método	Aprobó	Desaprobó
Lectura	1	2
Práctica	2	1
L y P	3	1
Total	6	4

¡Llegó un alumno nuevo! Práctico para el examen, Tiene un puntaje Promedio en exámenes anteriores y Tiene un tiempo bajo de estudio. ¿Va a aprobar o no?

Para **Aprobó**:

$$P(Bajo|Aprobó)$$

Puntuación	Aprobó	Desaprobó
Bajo	0	3
Promedio	2	0
Alto	4	1
Total	6	4

Tiempo	Aprobó	Desaprobó
Bajo	1	2
Moderado	3	1
Alto	2	1
Total	6	4

Método	Aprobó	Desaprobó
Lectura	1	2
Práctica	2	1
L y P	3	1
Total	6	4

¡Llegó un alumno nuevo! Práctico para el examen, Tiene un puntaje Promedio en exámenes anteriores y Tiene un tiempo bajo de estudio. ¿Va a aprobar o no?

Para **Aprobó**:

$$P(Bajo|Aprobó) = \frac{1}{6}$$

Puntuación	Aprobó	Desaprobó
Bajo	0	3
Promedio	2	0
Alto	4	1
Total	6	4

Tiempo	Aprobó	Desaprobó
Bajo	1	2
Moderado	3	1
Alto	2	1
Total	6	4

Método	Aprobó	Desaprobó
Lectura	1	2
Práctica	2	1
L y P	3	1
Total	6	4

Puntuación	Aprobó	Desaprobó
Bajo	0	3
Promedio	2	0
Alto	4	1
Total	6	4

Tiempo	Aprobó	Desaprobó
Bajo	1	2
Moderado	3	1
Alto	2	1
Total	6	4

¡Llegó un alumno nuevo! Práctico para el examen, Tiene un puntaje Promedio en exámenes anteriores y Tiene un tiempo bajo de estudio. ¿Va a aprobar o no?

Para **Aprobó**:

$$P(Bajo|Aprobó) = \frac{1}{6}$$

$$P(Práctica|Aprobó) =$$

Método	Aprobó	Desaprobó
Lectura	1	2
Práctica	2	1
L y P	3	1
Total	6	4

Puntuación	Aprobó	Desaprobó
Bajo	0	3
Promedio	2	0
Alto	4	1
Total	6	4

Tiempo	Aprobó	Desaprobó
Bajo	1	2
Moderado	3	1
Alto	2	1
Total	6	4

¡Llegó un alumno nuevo! Práctico para el examen, Tiene un puntaje Promedio en exámenes anteriores y Tiene un tiempo bajo de estudio. ¿Va a aprobar o no?

Para **Aprobó**:

$$P(Bajo|Aprobó) = \frac{1}{6}$$

$$P(Práctica|Aprobó) = \frac{2}{6}$$

Método	Aprobó	Desaprobó
Lectura	1	2
Práctica	2	1
L y P	3	1
Total	6	4

Puntuación	Aprobó	Desaprobó
Bajo	0	3
Promedio	2	0
Alto	4	1
Total	6	4

Tiempo	Aprobó	Desaprobó
Bajo	1	2
Moderado	3	1
Alto	2	1
Total	6	4

¡Llegó un alumno nuevo! Práctico para el examen, Tiene un puntaje Promedio en exámenes anteriores y Tiene un tiempo bajo de estudio. ¿Va a aprobar o no?

Para **Aprobó**:

$$P(Bajo|Aprobó) = \frac{1}{6}$$

$$P(Práctica|Aprobó) = \frac{2}{6}$$

$$P(Promedio|Aprobó)$$

Método	Aprobó	Desaprobó
Lectura	1	2
Práctica	2	1
L y P	3	1
Total	6	4

Puntuación	Aprobó	Desaprobó
Bajo	0	3
Promedio	2	0
Alto	4	1
Total	6	4

Tiempo	Aprobó	Desaprobó
Bajo	1	2
Moderado	3	1
Alto	2	1
Total	6	4

¡Llegó un alumno nuevo! Práctico para el examen, Tiene un puntaje Promedio en exámenes anteriores y Tiene un tiempo bajo de estudio. ¿Va a aprobar o no?

Para **Aprobó**:

$$P(Bajo|Aprobó) = \frac{1}{6}$$

$$P(Práctica|Aprobó) = \frac{2}{6}$$

$$P(Promedio|Aprobó) = \frac{2}{6}$$

Entonces:

Método	Aprobó	Desaprobó
Lectura	1	2
Práctica	2	1
L y P	3	1
Total	6	4

Puntuación	Aprobó	Desaprobó
Bajo	0	3
Promedio	2	0
Alto	4	1
Total	6	4

Tiempo	Aprobó	Desaprobó
Bajo	1	2
Moderado	3	1
Alto	2	1
Total	6	4

¡Llegó un alumno nuevo! Práctico para el examen, Tiene un puntaje Promedio en exámenes anteriores y Tiene un tiempo bajo de estudio. ¿Va a aprobar o no?

Para **Aprobó**:

$$P(Bajo|Aprobó) = \frac{1}{6}$$

$$P(Práctica|Aprobó) = \frac{2}{6}$$

$$P(Promedio|Aprobó) = \frac{2}{6}$$

Entonces:

$$P(Aprobó|X) = 0,6 \times \frac{1}{6} \times \frac{2}{6} \times \frac{2}{6}$$

$$P(Aprobó|X) = 0,0056$$

Método	Aprobó	Desaprobó
Lectura	1	2
Práctica	2	1
L y P	3	1
Total	6	4

¡Llegó un alumno nuevo! Práctico para el examen, Tiene un puntaje Promedio en exámenes anteriores y Tiene un tiempo bajo de estudio. ¿Va a aprobar o no?

Para **Desaprobó**:

$$P(Bajo|Desaprobó)$$

Puntuación	Aprobó	Desaprobó
Bajo	0	3
Promedio	2	0
Alto	4	1
Total	6	4

Tiempo	Aprobó	Desaprobó
Bajo	1	2
Moderado	3	1
Alto	2	1
Total	6	4

Método	Aprobó	Desaprobó
Lectura	1	2
Práctica	2	1
L y P	3	1
Total	6	4

¡Llegó un alumno nuevo! Práctico para el examen, Tiene un puntaje Promedio en exámenes anteriores y Tiene un tiempo bajo de estudio. ¿Va a aprobar o no?

Para **Desaprobó**:

$$P(Bajo|Desaprobó) = \frac{2}{4}$$

Puntuación	Aprobó	Desaprobó
Bajo	0	3
Promedio	2	0
Alto	4	1
Total	6	4

Tiempo	Aprobó	Desaprobó
Bajo	1	2
Moderado	3	1
Alto	2	1
Total	6	4

Método	Aprobó	Desaprobó
Lectura	1	2
Práctica	2	1
L y P	3	1
Total	6	4

¡Llegó un alumno nuevo! Práctico para el examen, Tiene un puntaje Promedio en exámenes anteriores y Tiene un tiempo bajo de estudio. ¿Va a aprobar o no?

Para **Desaprobó**:

$$P(Bajo|Desaprobó) = \frac{2}{4}$$

$$P(Práctica|Desaprobó) =$$

Puntuación	Aprobó	Desaprobó
Bajo	0	3
Promedio	2	0
Alto	4	1
Total	6	4

Tiempo	Aprobó	Desaprobó
Bajo	1	2
Moderado	3	1
Alto	2	1
Total	6	4

Método	Aprobó	Desaprobó
Lectura	1	2
Práctica	2	1
L y P	3	1
Total	6	4

Puntuación	Aprobó	Desaprobó
Bajo	0	3
Promedio	2	0
Alto	4	1
Total	6	4

Tiempo	Aprobó	Desaprobó
Bajo	1	2
Moderado	3	1
Alto	2	1
Total	6	4

¡Llegó un alumno nuevo! Práctico para el examen, Tiene un puntaje Promedio en exámenes anteriores y Tiene un tiempo bajo de estudio. ¿Va a aprobar o no?

Para **Desaprobó**:

$$P(Bajo|Desaprobó) = \frac{2}{4}$$

$$P(Práctica|Desaprobó) = \frac{1}{4}$$

Método	Aprobó	Desaprobó
Lectura	1	2
Práctica	2	1
L y P	3	1
Total	6	4

¡Llegó un alumno nuevo! Práctico para el examen, Tiene un puntaje Promedio en exámenes anteriores y Tiene un tiempo bajo de estudio. ¿Va a aprobar o no?

Para **Desaprobó**:

$$P(Bajo|Desaprobó) = \frac{2}{4}$$

$$P(Práctica|Desaprobó) = \frac{1}{4}$$

$$P(Promedio|Desaprobó)$$

Puntuación	Aprobó	Desaprobó
Bajo	0	3
Promedio	2	0
Alto	4	1
Total	6	4

Tiempo	Aprobó	Desaprobó
Bajo	1	2
Moderado	3	1
Alto	2	1
Total	6	4

Método	Aprobó	Desaprobó
Lectura	1	2
Práctica	2	1
L y P	3	1
Total	6	4

Puntuación	Aprobó	Desaprobó
Bajo	0	3
Promedio	2	0
Alto	4	1
Total	6	4

Tiempo	Aprobó	Desaprobó
Bajo	1	2
Moderado	3	1
Alto	2	1
Total	6	4

¡Llegó un alumno nuevo! Práctico para el examen, Tiene un puntaje Promedio en exámenes anteriores y Tiene un tiempo bajo de estudio. ¿Va a aprobar o no?

Para **Desaprobó**:

$$P(Bajo|Desaprobó) = \frac{2}{4}$$

$$P(Práctica|Desaprobó) = \frac{1}{4}$$

$$P(Promedio|Desaprobó) = \frac{0}{4}$$

Método	Aprobó	Desaprobó
Lectura	1	2
Práctica	2	1
L y P	3	1
Total	6	4

Puntuación	Aprobó	Desaprobó
Bajo	0	3
Promedio	2	0
Alto	4	1
Total	6	4

Tiempo	Aprobó	Desaprobó
Bajo	1	2
Moderado	3	1
Alto	2	1
Total	6	4

¡Llegó un alumno nuevo! Práctico para el examen, Tiene un puntaje Promedio en exámenes anteriores y Tiene un tiempo bajo de estudio. ¿Va a aprobar o no?

Para **Desaprobó**:

$$P(Bajo|Desaprobó) = \frac{2}{4}$$

$$P(Práctica|Desaprobó) = \frac{1}{4}$$

$$P(Promedio|Desaprobó) = \frac{0}{4}$$

Entonces:

Método	Aprobó	Desaprobó
Lectura	1	2
Práctica	2	1
L y P	3	1
Total	6	4

Puntuación	Aprobó	Desaprobó
Bajo	0	3
Promedio	2	0
Alto	4	1
Total	6	4

Tiempo	Aprobó	Desaprobó
Bajo	1	2
Moderado	3	1
Alto	2	1
Total	6	4

¡Llegó un alumno nuevo! Práctico para el examen, Tiene un puntaje Promedio en exámenes anteriores y Tiene un tiempo bajo de estudio. ¿Va a aprobar o no?

Para **Desaprobó**:

$$P(Bajo|Desaprobó) = \frac{2}{4}$$

$$P(Práctica|Desaprobó) = \frac{1}{4}$$

$$P(Promedio|Desaprobó) = \frac{0}{4}$$

Entonces:

$$P(Desaprobó|X) = 0,4 \times \frac{2}{4} \times \frac{1}{4} \times \frac{0}{4}$$

$$P(Desaprobó|X) = 0$$

Naive Bayes

¿Existe algo que tiene probabilidad 0 de que pase?

Naive Bayes

¿Existe algo que tiene probabilidad 0 de que pase?

Para solucionar este problema, está el **Suavizado de Laplace**

Naive Bayes

¿Existe algo que tiene probabilidad 0 de que pase?

Para solucionar este problema, está el **Suavizado de Laplace**

El suavizado de Laplace sirve para evitar que Naive Bayes asigne probabilidad cero a una clase solo porque una combinación no apareció en los datos de entrenamiento.

Naive Bayes

¿Cómo se compone el suavizado de laplace?

$$P(x_i|y) = \frac{\text{count}(x_i, y) + \alpha}{\text{count}(y) + \alpha \times n}$$

Donde:

- $\text{count}(x_i, y)$: cuántas veces aparece ese valor dentro de esa clase.
- $\text{count}(y)$: cuántos casos hay de esa clase.
- n : cantidad de valores posibles de esa variable.
- α : valor de suavizado, usualmente 1.

Naive Bayes

Calculemos el valor del ejercicio anterior con el suavizado de laplace

$$P(x_i|y) = \frac{\text{count}(x_i, y) + \alpha}{\text{count}(y) + \alpha \times n}$$

Donde:

- $\text{count}(x_i, y)$: cuántas veces aparece ese valor dentro de esa clase.
- $\text{count}(y)$: cuántos casos hay de esa clase.
- n : cantidad de valores posibles de esa variable.
- α : valor de suavizado, usualmente 1.

Puntuación	Aprobó	Desaprobó
Bajo	0	3
Promedio	2	0
Alto	4	1
Total	6	4

$$P(\text{Promedio}|\text{Desaprobó}) = \frac{0 + 1}{4 + 3} = \frac{1}{7}$$

Naive Bayes

Calculemos el valor del ejercicio anterior con el suavizado de laplace

$$P(x_i|y) = \frac{\text{count}(x_i, y) + \alpha}{\text{count}(y) + \alpha \times n}$$

Donde:

- $\text{count}(x_i, y)$: cuántas veces aparece ese valor dentro de esa clase.
- $\text{count}(y)$: cuántos casos hay de esa clase.
- n : cantidad de valores posibles de esa variable.
- α : valor de suavizado, usualmente 1.

Puntuación	Aprobó	Desaprobó
Bajo	0	3
Promedio	2	0
Alto	4	1
Total	6	4

$$P(\text{Promedio}|\text{Desaprobó}) = \frac{0 + 1}{4 + 3} = \frac{1}{7}$$

El suavizado hay que aplicarlo a todas las probabilidades

Naive Bayes

¿Qué pasa si tenemos una variable numérica?

Edad	Peso	Horas de sueño	Hace Ejercicio
22	65	7.5	Sí
25	70	8.0	Sí
23	68	7.0	Sí
28	72	7.5	Sí
24	66	8.5	Sí
26	69	7.8	Sí
45	85	6.0	No
50	90	5.5	No
48	88	6.2	No
52	92	5.8	No
49	87	6.5	No
47	86	5.9	No

Naive Bayes

¿Qué pasa si tenemos una variable numérica?

Calculamos μ y σ de cada variable:

Edad	Peso	Horas de sueño	Hace Ejercicio
22	65	7.5	Sí
25	70	8.0	Sí
23	68	7.0	Sí
28	72	7.5	Sí
24	66	8.5	Sí
26	69	7.8	Sí
45	85	6.0	No
50	90	5.5	No
48	88	6.2	No
52	92	5.8	No
49	87	6.5	No
47	86	5.9	No

Naive Bayes

¿Qué pasa si tenemos una variable numérica?

Calculamos μ y σ de cada variable:

Característica	Clase	μ	σ
Edad	Sí	24.67	1.97
Edad	No	48.5	2.22
Peso	Sí	68.33	2.36
Peso	No	88.0	2.38
Sueño	Sí	7.72	0.47
Sueño	No	5.98	0.31

Edad	Peso	Horas de sueño	Hace Ejercicio
22	65	7.5	Sí
25	70	8.0	Sí
23	68	7.0	Sí
28	72	7.5	Sí
24	66	8.5	Sí
26	69	7.8	Sí
45	85	6.0	No
50	90	5.5	No
48	88	6.2	No
52	92	5.8	No
49	87	6.5	No
47	86	5.9	No

Naive Bayes

Si tenemos un dato nuevo, remplazamos en la **formula gaussiana** y obtenemos las probabilidad

Edad	Peso	Horas de sueño	Hace Ejercicio
22	65	7.5	Sí
25	70	8.0	Sí
23	68	7.0	Sí
28	72	7.5	Sí
24	66	8.5	Sí
26	69	7.8	Sí
45	85	6.0	No
50	90	5.5	No
48	88	6.2	No
52	92	5.8	No
49	87	6.5	No
47	86	5.9	No

Naive Bayes

Si tenemos un dato nuevo, remplazamos en la **formula gaussiana** y obtenemos las probabilidad

Aplicando la fórmula gaussiana:

$$P(x|y) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x - \mu)^2}{2\sigma^2}\right)$$

Edad	Peso	Horas de sueño	Hace Ejercicio
22	65	7.5	Sí
25	70	8.0	Sí
23	68	7.0	Sí
28	72	7.5	Sí
24	66	8.5	Sí
26	69	7.8	Sí
45	85	6.0	No
50	90	5.5	No
48	88	6.2	No
52	92	5.8	No
49	87	6.5	No
47	86	5.9	No

Naive Bayes

Aplicando la fórmula gaussiana:

$$P(x|y) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$$

Probabilidad	Valor
$P(30 \text{Sí})$	0.0053
$P(75 \text{Sí})$	0.0031
$P(7 \text{Sí})$	0.261
$P(\text{Sí} X)$	0.0000021

Edad	Peso	Horas de sueño	Hace Ejercicio
22	65	7.5	Sí
25	70	8.0	Sí
23	68	7.0	Sí
28	72	7.5	Sí
24	66	8.5	Sí
26	69	7.8	Sí
45	85	6.0	No
50	90	5.5	No
48	88	6.2	No
52	92	5.8	No
49	87	6.5	No
47	86	5.9	No

Naive Bayes

Despues, comparamos clases y clasificamos

Clase	Probabilidad Posterior
Hace ejercicio: Sí	0.0000021 ← Mayor
Hace ejercicio: No	$2,25 \times 10^{-16}$

Edad	Peso	Horas de sueño	Hace Ejercicio
22	65	7.5	Sí
25	70	8.0	Sí
23	68	7.0	Sí
28	72	7.5	Sí
24	66	8.5	Sí
26	69	7.8	Sí
45	85	6.0	No
50	90	5.5	No
48	88	6.2	No
52	92	5.8	No
49	87	6.5	No
47	86	5.9	No

Naive Bayes

Ventajas:

- Simple y rápido de entrenar.
- Funciona bien con datos pequeños.
- Maneja datos faltantes.
- Fácil de interpretar.

Desventajas:

- Supone independencia entre las características.
- Es sensible a características irrelevantes.
- No captura relaciones complejas.
- Puede tener problemas con probabilidades cero.

Naive Bayes

Si bien no es un algoritmo de clasificación perfecto, Naive Bayes es útil en muchas aplicaciones prácticas como por ejemplo:

- Filtrado de correos spam.
- Análisis de sentimientos y opiniones.
- Diagnóstico médico automático.
- Detección de fraude.
- Clasificación de malware.

Hagamos ejercicios que van entrar en el final

Dolor en pecho	Dificultad para respirar	Mareo	Urgente
Sí	Sí	Sí	Sí
Sí	Sí	No	Sí
Sí	No	Sí	Sí
No	Sí	Sí	Sí
Sí	No	No	No
Medio	Sí	No	Sí
No	No	Sí	No
Medio	No	No	No

Pasos para CART

- 1. Definir la variable objetivo: Urgente: Sí / No.
- 2. Calcular el Gini inicial del dataset completo.
- 3. Probar posibles divisiones, por ejemplo:
 - a. Dificultad para respirar = Sí / No.
 - b. Mareo = Sí / No.
 - c. Dolor en pecho = Sí / No / Medio.
- 4. Calcular el Gini ponderado de cada división.
- 5. Elegir la división con menor Gini.
- 6. Repetir el proceso en las ramas que no sean puras.
- 7. Clasificar el caso nuevo siguiendo las preguntas del árbol.

Dolor en pecho	Dificultad para respirar	Mareo	Urgente
Sí	Sí	Sí	Sí
Sí	Sí	No	Sí
Sí	No	Sí	Sí
No	Sí	Sí	Sí
Sí	No	No	No
Medio	Sí	No	Sí
No	No	Sí	No
Medio	No	No	No

Dolor en pecho	Dificultad para respirar	Mareo	Urgente
Sí	Sí	Sí	Sí
Sí	Sí	No	Sí
Sí	No	Sí	Sí
No	Sí	Sí	Sí
Sí	No	No	No
Medio	Sí	No	Sí
No	No	Sí	No
Medio	No	No	No

Pasos para Naive Bayes

- 1. Definir cuál es el caso nuevo que queremos clasificar.
- 2. Identificar la variable objetivo, en este caso: Urgente: Sí o No.
- 3. Contar cuántos casos hay de cada clase: cuántos son urgentes y cuántos no.
- 4. Calcular qué tan frecuente es cada clase en el dataset.
- 5. Para cada clase, contar cuántas veces aparece cada característica del caso nuevo.
- 6. Revisar si alguna característica no apareció nunca dentro de una clase.
- 7. Si aparece una frecuencia cero, aplicar suavizado de Laplace para evitar que toda la probabilidad quede en cero.
- 8. Combinar la información de todas las características para cada clase.
- 9. Comparar el resultado de Urgente = Sí contra Urgente = No.
- 10. Elegir la clase con mayor valor como predicción final.

Dolor en pecho	Dificultad para respirar	Mareo	Urgente
Sí	Sí	Sí	Sí
Sí	Sí	No	Sí
Sí	No	Sí	Sí
No	Sí	Sí	Sí
Sí	No	No	No
Medio	Sí	No	Sí
No	No	Sí	No
Medio	No	No	No

Dolor en pecho	Dificultad para respirar	Mareo	Urgente
Sí	Sí	Sí	Sí
Sí	Sí	No	Sí
Sí	No	Sí	Sí
No	Sí	Sí	Sí
Sí	No	No	No
Medio	Sí	No	Sí
No	No	Sí	No
Medio	No	No	No

$$P(x_i|y) = \frac{\text{count}(x_i, y) + \alpha}{\text{count}(y) + \alpha \times n}$$

Donde:

- $\text{count}(x_i, y)$: cuántas veces aparece ese valor dentro de esa clase.
- $\text{count}(y)$: cuántos casos hay de esa clase.
- n : cantidad de valores posibles de esa variable.
- α : valor de suavizado, usualmente 1.