

Analítica de Datos


Clase 11 - Clustering


Hola

Agenda

- Clustering
- Ejercicio Nacho

Clustering





Clustering

Dividir los datos en grupos donde

Clustering

Dividir los datos en grupos donde

- Los datos dentro de cada grupo son **similares**
- Los datos entre grupos son **distintos**

Clustering

¿Por qué Clustering?

Clustering

¿Por qué Clustering?

Caso de Aplicación: Clientes de un E-commerce

Clustering

¿Por qué Clustering?

Caso de Aplicación: Clientes de un E-commerce

Todos los clientes se comportan de manera distinta...

Clustering

¿Por qué Clustering?

Caso de Aplicación: Clientes de un E-commerce

Todos los clientes se comportan de manera distinta...

La pregunta clave: ¿Podemos agrupar automáticamente a clientes con comportamientos similares?

Clustering

¿Por qué Clustering?

Caso de Aplicación: Clientes de un E-commerce

Todos los clientes se comportan de manera distinta...

La pregunta clave: ¿Podemos agrupar automáticamente a clientes con comportamientos similares?

Beneficios

- Asignar recursos eficientemente
- Entender bien que tipo de clientes tenemos
- Personalizar campañas de marketing

Clustering

Dividir los datos en grupos donde

- Los datos dentro de cada grupo son **similares**
- Los datos entre grupos son **distintos**

No necesitamos etiquetas previas, solo necesitamos datos para encontrar similitudes

La estructura oculta de los datos

Clustering

¿Cómo funciona? *Intuitivamente*

Clustering

¿Cómo funciona? *Intuitivamente*

1. Elijo un “k” (Cuantos grupos quiero)

Clustering

¿Cómo funciona? *Intuitivamente*

1. Elijo un “k” (Cuantos grupos quiero)
2. El algoritmo coloca K centroides aleatoriamente

Clustering

¿Cómo funciona? *Intuitivamente*

1. Elijo un “k” (Cuantos grupos quiero)
2. El algoritmo coloca K centroides aleatoriamente
3. Cada observación se asigna al centroide más cercano

Clustering

¿Cómo funciona? *Intuitivamente*

1. Elijo un “k” (Cuántos grupos quiero)
2. El algoritmo coloca K centroides aleatoriamente
3. Cada observación se asigna al centroide más cercano
4. Se recalcula el centroide como el promedio de sus puntos

Clustering

¿Cómo funciona? *Intuitivamente*

1. Elijo un “k” (Cuantos grupos quiero)
2. El algoritmo coloca K centroides aleatoriamente
3. Cada observación se asigna al centroide más cercano
4. Se recalcula el centroide como el promedio de sus puntos
5. Se repite hasta que los centroides dejen de moverse

Clustering

¿Cómo funciona? *Intuitivamente*

1. Elijo un “k” (Cuantos grupos quiero)
2. El algoritmo coloca K centroides aleatoriamente
3. Cada observación se asigna al centroide más cercano
4. Se recalcula el centroide como el promedio de sus puntos
5. Se repite hasta que los centroides dejen de moverse

La analogía: Los K son imanes que atraen puntos y se van posicionando

Clustering

¿Cómo funciona? El algoritmo (Esto ES importante)



Clustering

¿Cómo funciona? El algoritmo

1. **Inicialización:** Elegir K centroides al azar en un espacio

Clustering

¿Cómo funciona? El algoritmo

1. **Inicialización:** Elegir K centroides al azar en un espacio
2. **Asignación:** Para cada observación x , asignarla al cluster cuyo centroide esté más cerca

Clustering

¿Cómo funciona? El algoritmo

1. **Inicialización:** Elegir K centroides al azar en un espacio
2. **Asignación:** Para cada observación x , asignarla al cluster cuyo centroide esté más cerca
3. **Actualización:** Recalcular cada centroide como el promedio de sus observaciones

Clustering

¿Cómo funciona? El algoritmo

1. **Inicialización:** Elegir K centroides al azar en un espacio
2. **Asignación:** Para cada observación x , asignarla al cluster cuyo centroide esté más cerca
3. **Actualización:** Recalcular cada centroide como el promedio de sus observaciones
4. **Repetir:** Pasos 2 y 3 hasta convergencia

Clustering

¿Cómo funciona? El algoritmo

1. **Inicialización:** Elegir K centroides al azar en un espacio
2. **Asignación:** Para cada observación x , asignarla al cluster cuyo centroide esté más cerca
3. **Actualización:** Recalcular cada centroide como el promedio de sus observaciones
4. **Repetir:** Pasos 2 y 3 hasta convergencia

¿Cómo se calcula la distancia?

Raíz de $(X1 - X_i)^2 + (X2 - X_i)^2$

Cluster - Ejemplo Algorítmico

Cliente	Gasto Promedio	Frecuencia (veces/mes)
A	\$20	2
B	\$25	3
C	\$100	8
D	\$95	9
E	\$22	2
F	\$105	10

Objetivo: Dividir en $K=2$ clusters

Cluster - Ejemplo Algorítmico

Paso 1. Elijo dos centroides al azar

Centroide 1 (μ_1): Cliente A = (\$20, 2)

Centroide 2 (μ_2): Cliente C = (\$100, 8)

Cliente	Gasto Promedio	Frecuencia (veces/mes)
A	\$20	2
B	\$25	3
C	\$100	8
D	\$95	9
E	\$22	2
F	\$105	10

Cluster - Ejemplo Algorítmico

Paso 2. Asigno cada cliente al centroide más cercano

Centroide 1 (μ_1): Cliente A = (\$20, 2)

Centroide 2 (μ_2): Cliente C = (\$100, 8)

Cliente B (\$25, 3):

Cluster - Ejemplo Algorítmico

Paso 2. Asigno cada cliente al centroide más cercano

Centroide 1 (μ_1): Cliente A = (\$20, 2)

Centroide 2 (μ_2): Cliente C = (\$100, 8)

Cliente B (\$25, 3):

- Distancia a μ_1 : $\sqrt{(25 - 20)^2 + (3 - 2)^2} = \sqrt{26} \approx 5,1$

Cluster - Ejemplo Algorítmico

Paso 2. Asigno cada cliente al centroide más cercano

Centroide 1 (μ_1): Cliente A = (\$20, 2)

Centroide 2 (μ_2): Cliente C = (\$100, 8)

Cliente B (\$25, 3):

- Distancia a μ_1 : $\sqrt{(25 - 20)^2 + (3 - 2)^2} = \sqrt{26} \approx 5,1$
- Distancia a μ_2 : $\sqrt{(25 - 100)^2 + (3 - 8)^2} = \sqrt{5650} \approx 75,2$

Cluster - Ejemplo Algorítmico

Paso 2. Asigno cada cliente al centroide más cercano

Centroide 1 (μ_1): Cliente A = (\$20, 2)

Centroide 2 (μ_2): Cliente C = (\$100, 8)

Cliente B (\$25, 3):

- Distancia a μ_1 : $\sqrt{(25 - 20)^2 + (3 - 2)^2} = \sqrt{26} \approx 5,1$
- Distancia a μ_2 : $\sqrt{(25 - 100)^2 + (3 - 8)^2} = \sqrt{5650} \approx 75,2$
- B está más cerca de $\mu_1 \rightarrow$ **Cluster 1**

Cluster - Ejemplo Algorítmico

Paso 2. Asigno cada cliente al centroide más cercano

Si hago esto para todos los puntos...

- Cluster 1: A, B, E (bajo gasto, baja frecuencia)
- Cluster 2: C, D, F (alto gasto, alta frecuencia)

Cliente	Gasto Promedio	Frecuencia (veces/mes)
A	\$20	2
B	\$25	3
C	\$100	8
D	\$95	9
E	\$22	2
F	\$105	10

Cluster - Ejemplo Algorítmico

Paso 3. Recalcular centroides como promedio de cada cluster

Cliente	Gasto Promedio	Frecuencia (veces/mes)
A	\$20	2
B	\$25	3
C	\$100	8
D	\$95	9
E	\$22	2
F	\$105	10

Cluster - Ejemplo Algorítmico

Paso 3. Recalcular centroides como promedio de cada cluster

Cluster 1 (A, B, E):

$$\mu_1 = \left(\frac{20 + 25 + 22}{3}, \frac{2 + 3 + 2}{3} \right) \\ = (22, 3)$$

Cluster 2 (C, D, F):

$$\mu_2 = \left(\frac{100 + 95 + 105}{3}, \frac{8 + 9 + 10}{3} \right) \\ = (100, 9)$$

Cliente	Gasto Promedio	Frecuencia (veces/mes)
A	\$20	2
B	\$25	3
C	\$100	8
D	\$95	9
E	\$22	2
F	\$105	10

Cluster - Ejemplo Algorítmico

Paso 4. Repetir hasta que los centroides no cambien


Cluster - Ejemplo Algorítmico

Paso 4. Repetir hasta que los centroides no cambien


En este caso, las asignaciones no cambian,

¡La convergencia fue alcanzada!

Cluster - Visualmente



Cluster - Visualmente



Cluster - ¿Cómo elegimos K?

A diferencia del aprendizaje supervisado, **no tenemos conjunto de test**

Necesitamos métodos para determinar el **K** óptimo

Cluster - ¿Cómo elegimos K?

1. Probamos diferentes valores de K

Cluster - ¿Cómo elegimos K?

1. Probamos diferentes valores de K
2. Para cada K, calculamos la Inercia

Cluster - ¿Cómo elegimos K?

1. Probamos diferentes valores de K
2. Para cada K, calculamos la Inercia
3. Graficamos Inercia vs K

Cluster - ¿Cómo elegimos K?

1. Probamos diferentes valores de K
2. Para cada K, calculamos la Inercia
3. Graficamos Inercia vs K
4. Buscamos el *codo*: donde agregar más clusters no reduce mucho la inercia

Cluster - ¿Cómo elegimos K?

1. Probamos diferentes valores de K
2. Para cada K, calculamos la Inercia
3. Graficamos Inercia vs K
4. Buscamos el *codo*: donde agregar más clusters no reduce mucho la inercia

¿Qué es la inercia? la inercia mide qué tan “compactos” quedan los grupos.

la inercia es la suma de las distancias de cada punto al centro de su cluster.

Cluster - ¿Cómo elegimos K?

1. Probamos diferentes valores de K
2. Para cada K, calculamos la Inercia
3. Graficamos Inercia vs K
4. Buscamos el *codo*: donde agregar más clusters no reduce mucho la inercia

¿Qué es la inercia? la inercia mide qué tan “compactos” quedan los grupos.

la inercia es la suma de las distancias de cada punto al centro de su cluster.

Si los puntos están muy cerca de su centro, la inercia es baja.

Si están muy dispersos, la inercia es alta.

Cluster - ¿Cómo elegimos K?


```
# Calcular inercia para distintos valores de k
inertias = []
K = range(1, 11)

for k in K:
    kmeans = KMeans(
        n_clusters=k,
        random_state=42,
        n_init=10
    )
    kmeans.fit(X_scaled)
    inertias.append(kmeans.inertia_)
```


Cluster - ¿Cómo elegimos K?


```
# Calcular inercia para distintos valores de k
inertias = []
K = range(1, 11)

for k in K:
    kmeans = KMeans(
        n_clusters=k,
        random_state=42,
        n_init=10
    )
    kmeans.fit(X_scaled)
    inertias.append(kmeans.inertia_)
```




Cluster - ¿Cómo elegimos K?

¿Qué K elegirían?



Cluster - ¿Cómo elegimos K?

¿Qué K elegirían?



Clustering - Ventajas

- **Simple y rápido:** Fácil de entender e implementar
- **Escalable:** Funciona bien con datasets grandes
- **Garantía de convergencia:** Siempre termina
- **Interpretable:** Centroides fáciles de analizar

Clustering - Es interpretable

¿Por qué es una ventaja?

Porque puedo tomar decisiones de negocio en función de mis Clusters

Clustering - Es interpretable

Clientes de una plataforma de streaming.

Cluster 0: 8 horas vistas/mes, 1 o 2 géneros, baja frecuencia de ingreso, antigüedad baja, alta probabilidad de baja → **Usuarios en riesgo de churn**

Cluster 1: 45 horas vistas/mes, muchos géneros, ingresos frecuentes, antigüedad media, baja probabilidad de baja → **Usuarios comprometidos**

Cluster 2: 20 horas vistas/mes, pocos géneros, ingresos regulares, antigüedad alta, probabilidad media de baja → **Usuarios estables pero poco exploradores**

Cluster 3: 60 horas vistas/mes, consumo concentrado en series nuevas, ingresos muy frecuentes, antigüedad baja, baja probabilidad de baja → **Usuarios intensivos nuevos**

Clustering - Es interpretable

¿Qué estrategia de negocio se les ocurre para cada grupo?

Clientes de una plataforma de streaming.

Cluster 0: 8 horas vistas/mes, 1 o 2 géneros, baja frecuencia de ingreso, antigüedad baja, alta probabilidad de baja → **Usuarios en riesgo de churn**

Cluster 1: 45 horas vistas/mes, muchos géneros, ingresos frecuentes, antigüedad media, baja probabilidad de baja → **Usuarios comprometidos**

Cluster 2: 20 horas vistas/mes, pocos géneros, ingresos regulares, antigüedad alta, probabilidad media de baja → **Usuarios estables pero poco exploradores**

Cluster 3: 60 horas vistas/mes, consumo concentrado en series nuevas, ingresos muy frecuentes, antigüedad baja, baja probabilidad de baja → **Usuarios intensivos nuevos**

Clustering - Limitaciones

- **Elegir K:** No es obvio cuál es el mejor K
- **Inicialización:** Resultados pueden variar según inicialización
- **Outliers:** Sensible a valores extremos

Clustering - Limitaciones

- **Elegir K:** No es obvio cuál es el mejor K
- **Inicialización:** Resultados pueden variar según inicialización
- **Outliers:** Sensible a valores extremos

¿Qué no mencioné que es recontra importante con ejercicios de Distancia?
Y que hay que hacer de manera rotundamente obligatoria

A LABU RAR