

Analítica de Datos

Clase 12 - PCA

Hola

Hola

**No puede ser que algunos me
entregaron el tp de pablo**

Hola

**No puede ser que algunos me
entregaron el tp de pablo**

Los voy a matar

Trabajo Práctico Clustering

Display replies in nested form ▾

Move this discussion to ... ▾

Move

Settings ▾



Trabajo Práctico Clustering

by [Juan Costa](#) - Thursday, 11 June 2026, 7:51 PM

¡Estimados!

Recuerden que tienen que entregar, antes del Viernes 12/6 a las 23:59, el TP que empezamos en la tutorial de hoy. Está abierto el buzón en la unidad de aprendizaje no supervisado. Pueden entregar tanto un notebook cómo un informe (Con el notebook adjunto), y si lo hicieron de a 2, que entregue uno solo e incluyan los nombre de los integrantes del equipo.

Trabajo Práctico Clustering

Display replies in nested form

Move this discussion to ...

Move

Settings



Trabajo Práctico Clustering

by Juan Costa - Thursday, 11 June 2026, 7:51 PM

¡Estimados!

Recuerden que tienen que entregar, antes del Viernes 12/6 a las 23:59, el TP que empezamos en la tutorial de hoy. Está abierto el buzón en la unidad de aprendizaje no supervisado. Pueden entregar tanto un notebook como un informe (Con el notebook adjunto), y si lo hicieron de a 2, que entregue uno solo e incluyan los nombre de los integrantes del equipo.

Agenda

- Consultas TP Pablo
- TP de Clustering
- Kahoot de Repaso
- PCA



PCA

Principal Component Analysis

Principal Component Analysis

¿Por qué usamos PCA?

Principal Component Analysis

¿Por qué usamos PCA?

¿Qué significa reducir la dimensionalidad?

Principal Component Analysis

El problema de la alta dimensionalidad

Principal Component Analysis

El problema de la alta dimensionalidad

Caso: Tengo que predecir si una persona va a cancelar una suscripción de mi empresa de suplementos

DIABLA

Principal Component Analysis

DIABLA

El problema de la alta dimensionalidad

Caso: Tengo que predecir si una persona va a cancelar una suscripción de mi empresa de suplementos

Tengo **25 variables**: Edad, Locación, Antigüedad, Items consumidos, \$ Gastada, Variedad en las compras, Último ingreso a la página web, Frecuencia de compra, Etc...

Principal Component Analysis

DIABLA

El problema de la alta dimensionalidad

Caso: Tengo que predecir si una persona va a cancelar una suscripción de mi empresa de suplementos

Tengo **25 variables**: Edad, Locación, Antigüedad, Items consumidos, \$ Gastada, Variedad en las compras, Último ingreso a la página web, Frecuencia de compra, Etc...

A partir de esto, tengo muchos problemas...

Principal Component Analysis

Problemas:

1. Imposible de visualizar (No podemos ver 25 dimensiones)

Principal Component Analysis

Problemas:

1. Imposible de visualizar (No podemos ver 25 dimensiones)
2. Muchas variables correlacionadas (Items consumidos y \$ Gastada)

Principal Component Analysis

Problemas:

1. Imposible de visualizar (No podemos ver 25 dimensiones)
2. Muchas variables correlacionadas (Items consumidos y \$ Gastada)
3. Costo computacional alto (Son muchas variables y es costoso hacer Random Forest, XGBoost etc)

Principal Component Analysis

Problemas:

1. Imposible de visualizar (No podemos ver 25 dimensiones)
2. Muchas variables correlacionadas (Items consumidos y \$ Gastada)
3. Costo computacional alto (Son muchas variables y es costoso hacer Random Forest, XGBoost etc)
4. Riesgo de overfitting (Tengo muchas variables y no necesariamente muchas observaciones)

Principal Component Analysis

Problemas:

1. Imposible de visualizar (No podemos ver 25 dimensiones)
2. Muchas variables correlacionadas (Items consumidos y \$ Gastada)
3. Costo computacional alto (Son muchas variables y es costoso hacer Random Forest, XGBoost etc)
4. Riesgo de overfitting (Tengo muchas variables y no necesariamente muchas observaciones)

La pregunta que nos hacemos entonces es... *¿Se puede reducir la cantidad de variables sin perder información?*

Principal Component Analysis

Si ! 

Usando PCA

Principal Component Analysis

Si ! 

Usando PCA

PCA transforma **variables** correlacionadas en **componentes** no correlacionados

Principal Component Analysis

Si! 

Usando PCA

PCA transforma **variables** correlacionadas en **componentes** no correlacionados

Y ordena los componentes en función de la varianza que explican

Principal Component Analysis

Si! 

Usando PCA

PCA transforma **variables** correlacionadas en **componentes** no correlacionados

Y ordena los componentes en función de la varianza que explican

De esta manera, nos quedamos con los componentes más importantes y reducimos la cantidad de variables que tenemos → Mismos features, *casi* la misma información

Principal Component Analysis

Ejemplo Diabla

DIABLA

Principal Component Analysis

DIABLA

Ejemplo Diabla

Variables Originales: Edad, Locación, Antigüedad, Items consumidos, \$ Gastada, Variedad en las compras, Último ingreso a la página web, Frecuencia de compra, Monto de la factura, fecha de emisión, fecha de vencimiento, historial de pagos del cliente, industria o segmento del cliente, tamaño de la empresa (ingresos o empleados), número de facturas pendientes, días promedio de atraso históricos, nivel de riesgo crediticio del cliente...

Principal Component Analysis

DIABLA

Ejemplo Diabla

Variables Originales: Edad, Locación, Antigüedad, Items consumidos, \$ Gastada, Variedad en las compras, Último ingreso a la página web, Frecuencia de compra, Monto de la factura, fecha de emisión, fecha de vencimiento, etc...

PCA crea componentes con variables que están correlacionadas:

Principal Component Analysis

DIABLA

Ejemplo Diabla

Variables Originales: Edad, Locación, Antigüedad, Items consumidos, \$ Gastada, Variedad en las compras, Último ingreso a la página web, Frecuencia de compra, Monto de la factura, fecha de emisión, fecha de vencimiento, etc...

PCA crea componentes con variables que están correlacionadas:

- **PC1: “Comportamiento de pago”** → Explica tendencia en la manera de pagar el servicio
 - Días de atraso, historial de pagos, número de facturas pendientes

Principal Component Analysis

DIABLA

Ejemplo Diabla

Variables Originales: Edad, Locación, Antigüedad, Items consumidos, \$ Gastada, Variedad en las compras, Último ingreso a la página web, Frecuencia de compra, Monto de la factura, fecha de emisión, fecha de vencimiento, etc...

PCA crea componentes con variables que están correlacionadas:

- **PC1: “Comportamiento de pago”** → Explica tendencia en la manera de pagar el servicio
 - Días de atraso, historial de pagos, número de facturas pendientes
- **PC2: “Tipo de cliente”** → Explica las características del cliente
 - Cantidad de ingresos, Variedad de las compras, Tiempo en la web

Principal Component Analysis

DIABLA

Ejemplo Diabla

Variables Originales: Edad, Locación, Antigüedad, Items consumidos, \$ Gastada, Variedad en las compras, Último ingreso a la página web, Frecuencia de compra, Monto de la factura, fecha de emisión, fecha de vencimiento, etc...

PCA crea componentes con variables que están correlacionadas:

- **PC1: “Comportamiento de pago”** → Explica tendencia en la manera de pagar el servicio
 - Días de atraso, historial de pagos, número de facturas pendientes
- **PC2: “Tipo de cliente”** → Explica las características del cliente
 - Cantidad de ingresos, Variedad de las compras, Tiempo en la web

De esta manera, podemos usar 2-3 componentes en vez de 25 variables separadas

Principal Component Analysis

DIABLA

Ejemplo Diabla

Variables Originales: Edad, Locación, Antigüedad, Items consumidos, \$ Gastada, Variedad en las compras, Último ingreso a la página web, Frecuencia de compra, Monto de la factura, fecha de emisión, fecha de vencimiento, etc...

PCA crea componentes con variables que están correlacionadas:

- **PC1: “Comportamiento de pago”** → Explica tendencia en la manera de pagar el servicio
 - Días de atraso, historial de pagos, número de facturas pendientes
- **PC2: “Tipo de cliente”** → Explica las características del cliente
 - Cantidad de ingresos, Variedad de las compras, Tiempo en la web

*Explicar el 95%
del fenómeno*

De esta manera, podemos usar 2-3 componentes en vez de 25 variables separadas

Principal Component Analysis

Motivaciones principales

1. Visualización
2. Performance
3. Preprocesamiento
4. Eliminación de ruido
5. Comprensión

Principal Component Analysis

Motivaciones principales

1. **Visualización:** Reducir a 2D o 3D para graficar
2. Performance
3. Preprocesamiento
4. Eliminación de ruido
5. Comprensión

Principal Component Analysis

Motivaciones principales

1. Visualización: Reducir a 2D o 3D para graficar
2. **Performance**: Menos features = entrenamiento más rápido
3. Preprocesamiento
4. Eliminación de ruido
5. Comprensión

Principal Component Analysis

Motivaciones principales

1. Visualización: Reducir a 2D o 3D para graficar
2. Performance: Menos features = entrenamiento más rápido
3. **Preprocesamiento**: Eliminar multicolinealidad
4. Eliminación de ruido
5. Comprensión

Principal Component Analysis

Motivaciones principales

1. Visualización: Reducir a 2D o 3D para graficar
2. Performance: Menos features = entrenamiento más rápido
3. Preprocesamiento: Eliminar multicolinealidad
4. **Eliminación de ruido:** Componentes con poca varianza son ruido
5. Comprensión

Principal Component Analysis

Motivaciones principales

1. Visualización: Reducir a 2D o 3D para graficar
2. Performance: Menos features = entrenamiento más rápido
3. Preprocesamiento: Eliminar multicolinealidad
4. Eliminación de ruido: Componentes con poca varianza son ruido
5. **Compresión**: Almacenar datos de forma eficiente

Principal Component Analysis - Proceso

Proceso simplificado

1. **Estandarizar:** Todas las features con media 0, varianza 1

$$Z = \frac{X - \mu}{\sigma}$$

Principal Component Analysis - Proceso

Proceso simplificado

1. **Estandarizar:** Todas las features con media 0, varianza 1 $z = \frac{x - \mu}{\sigma}$
2. **Calcular matriz de covarianza:** Mide como varían las features juntas

Principal Component Analysis - Proceso

Proceso simplificado

1. **Estandarizar:** Todas las features con media 0, varianza 1 $z = \frac{x - \mu}{\sigma}$
2. **Calcular matriz de covarianza:** Mide como varían las features juntas
3. **Eigenvectors y Eigenvalues:** Direcciones de máxima varianza

Principal Component Analysis - Proceso

Proceso simplificado

1. **Estandarizar:** Todas las features con media 0, varianza 1 $z = \frac{x - \mu}{\sigma}$
2. **Calcular matriz de covarianza:** Mide como varían las features juntas
3. **Eigenvectors y Eigenvalues:** Direcciones de máxima varianza
4. **Proyectar datos:** Transformar los nuevos ejes

Principal Component Analysis - Proceso

Proceso simplificado

1. **Estandarizar:** Todas las features con media 0, varianza 1
$$Z = \frac{X - \mu}{\sigma}$$
2. **Calcular matriz de covarianza:** Mide como varían las features juntas
3. **Eigenvectors y Eigenvalues:** Direcciones de máxima varianza
4. **Proyectar datos:** Transformar los nuevos ejes
5. **Seleccionar K componentes:** Quedarse con los más importantes

Principal Component Analysis - Proceso

Proceso simplificado


1. **Estandarizar:** Todas las features con media 0, varianza 1
2. **Calcular matriz de covarianza:** Mide como varían las features juntas
3. **Eigenvectors y Eigenvalues:** Direcciones de máxima varianza
4. **Proyectar datos:** Transformar los nuevos ejes
5. **Seleccionar K componentes:** Quedarse con los más importantes

¿QUÉ es un Eigenvector?

Principal Component Analysis - Vectores

Eigenvector: Un nuevo vector que muestra una dirección principal

Eigenvalue: Cuanta información captura ese eje



Principal Component Analysis

Cada componente, es una combinación **lineal** de las features originales

$$PC_1 = w_{1,1} \cdot x_1 + w_{1,2} \cdot x_2 + \dots + w_{1,p} \cdot x_p$$

Principal Component Analysis

Cada componente, es una combinación **lineal** de las features originales

$$PC_1 = w_{1,1} \cdot x_1 + w_{1,2} \cdot x_2 + \dots + w_{1,p} \cdot x_p$$

Los componentes son **ortogonales** → No están correlacionados

Principal Component Analysis

Cada componente, es una combinación **lineal** de las features originales

$$PC_1 = w_{1,1} \cdot x_1 + w_{1,2} \cdot x_2 + \dots + w_{1,p} \cdot x_p$$

Los componentes son **ortogonales** → No están correlacionados

PC1 Captura la mayor varianza

Principal Component Analysis

Cada componente, es una combinación **lineal** de las features originales

$$PC_1 = w_{1,1} \cdot x_1 + w_{1,2} \cdot x_2 + \dots + w_{1,p} \cdot x_p$$

Los componentes son **ortogonales** → No están correlacionados

PC1 Captura la mayor varianza

PC2 Captura la segunda mayor varianza, que no esté correlacionada a C1

Principal Component Analysis

Cada componente, es una combinación **lineal** de las features originales

$$PC_1 = w_{1,1} \cdot x_1 + w_{1,2} \cdot x_2 + \dots + w_{1,p} \cdot x_p$$

Los componentes son **ortogonales** → No están correlacionados


PC1 Captura la mayor varianza

PC2 Captura la segunda mayor varianza, que no esté correlacionada a C1

Y así sucesivamente


Principal Component Analysis

¿Cómo se ve esto?



Principal Component Analysis

¿Cómo se ve esto?



Principal Component Analysis

¿Y cuantos componentes deberíamos usar?

Principal Component Analysis

¿Y cuantos componentes deberíamos usar?

Cada Eigenvalue indica cuanta varianza tiene cada componente

Principal Component Analysis

¿Y cuantos componentes deberíamos usar?

Cada Eigenvalue indica cuanta varianza tiene cada componente

Proporción de varianza explicada:

$$\text{Varianza}_i = \frac{\lambda_i}{\sum_{j=1}^p \lambda_j}$$

Principal Component Analysis

¿Y cuantos componentes deberíamos usar?


Cada Eigenvalue indica cuanta varianza tiene cada componente

Proporción de varianza explicada:

$$\text{Varianza}_i = \frac{\lambda_i}{\sum_{j=1}^p \lambda_j}$$

Regla práctica: Quedarse con componentes que expliquen 80-95 % de la varianza

Principal Component Analysis




Principal Component Analysis

Los componentes son difíciles de interpretar (combinaciones de features)

Podemos ver qué features contribuyen más a cada componente

Los “**loadings**” (pesos) nos indican la contribución

Principal Component Analysis



¿Cuándo usar PCA?

Casos ideales

1. Muchas features correlacionadas
2. Visualizar datos de alta dimensión
3. Entrenamiento muy lento por cantidad de features
4. Problemas de multicolinealidad
5. Compresión de datos (imágenes, audio)

¿Cuándo NO usar PCA?

Casos NO ideales

1. Features no correlacionadas (PCA no reduce mucho)
2. Interpretabilidad es crítica
3. Relaciones no lineales (usar kernel PCA o autoencoders)
4. Muy pocas features (no tiene sentido)

Consideraciones importantes

1. SIEMPRE estandarizar antes de PCA
2. Elegir K basado en varianza acumulada (80-95 %)
3. Trade-off: menos componentes = menos info pero más eficiencia
4. Comparar performance con y sin PCA
5. Usar gráfico de varianza acumulada para decidir K

**Bueno, charlemos dos minutos antes de que
se vayan y nachito tome el presente**