

EXAMEN DE PRÁCTICA

Analítica de Datos

Puntaje total: 100 puntos

Mínimo para aprobar: 60 puntos

Parte 1: 36 puntos

Parte 2: 64 puntos

Nota para el estudiante: Esta práctica incluye 18 preguntas de opción múltiple como banco de ejercitación. El examen real contará con entre 10 y 15 preguntas de esta selección.

PARTE 1: MÚLTIPLE CHOICE (36 puntos — 18 preguntas × 2 puntos)

Instrucciones: Cada pregunta vale 2 puntos. Puede haber **una o más** respuestas correctas (se indica en cada pregunta). Marcar una opción incorrecta descuenta **1 punto**. Dejar en blanco = 0 puntos.

Pregunta 1 (Múltiples respuestas) — Normalización y escalado de variables

¿Cuál(es) de las siguientes afirmaciones es/son **correcta(s)**?

- A) La normalización Min-Max escala los valores al rango $[0, 1]$.
- B) La estandarización Z-score es necesaria antes de aplicar un árbol de decisión para mejorar su rendimiento.
- C) La estandarización Z-score produce una distribución con media 0 y desviación estándar 1.
- D) Los parámetros de normalización (media, mín, máx) deben calcularse **solo** sobre el conjunto de entrenamiento y luego aplicarse al de prueba.

Pregunta 2 (Múltiples respuestas) — Tratamiento de valores faltantes

¿Cuál(es) de las siguientes es/son estrategias **válidas** para tratar valores faltantes?

- A) Eliminar las filas que contengan al menos un valor faltante.
- B) Imputar con el valor máximo de la variable para no perder información.
- C) Imputar con la media o mediana (para variables numéricas).
- D) Crear una categoría adicional “Sin Dato” para variables categóricas.

Pregunta 3 (Respuesta única) — Cálculo de métricas

Un modelo de clasificación para detección de enfermedades arroja los siguientes resultados sobre 200 pacientes:

$$\text{VP} = 70 \quad \text{FP} = 30 \quad \text{FN} = 10 \quad \text{VN} = 90$$

¿Cuál es el valor del **Recall (Sensibilidad)** del modelo?

- A) 0,70
- B) 0,80
- C) 0,875
- D) 0,78

Pregunta 4 (*Respuesta única*) — Selección de métrica según contexto

Una empresa farmacéutica desarrolla un modelo para detectar efectos secundarios graves en pacientes. El costo de **no detectar** un efecto secundario es extremadamente alto. ¿Qué métrica debería priorizarse al evaluar el modelo?

- A) Exactitud (Accuracy)
- B) Precisión (Precision)
- C) Recall (Sensibilidad)
- D) Especificidad

Pregunta 5 (*Múltiples respuestas*) — Overfitting

¿Cuál(es) de las siguientes técnicas ayuda(n) a **reducir el overfitting**?

- A) Aumentar la profundidad máxima del árbol de decisión.
- B) Aplicar poda (*pruning*) al árbol de decisión.
- C) Usar validación cruzada (*k-fold cross-validation*).
- D) Agregar más variables al modelo sin criterio de selección previa.

Pregunta 6 (*Múltiples respuestas*) — Método del codo

Respecto al **método del codo (Elbow Method)** en K-Means, ¿cuál(es) de las siguientes afirmaciones es/son correcta(s)?

- A) Se utiliza para seleccionar el número óptimo de clusters K .
- B) Evalúa la inercia (suma de distancias cuadradas intra-cluster) para diferentes valores de K .
- C) Garantiza siempre encontrar el número óptimo de clusters en cualquier dataset.

- D) El punto “codo” indica el K a partir del cual agregar más clusters no reduce significativamente la inercia.

Pregunta 7 (*Múltiples respuestas*) — Clustering aglomerativo

¿Cuál(es) es/son características del **clustering jerárquico aglomerativo**?

- A) Comienza con cada observación en su propio cluster y los va fusionando de a pares.
- B) Requiere definir el número de clusters K antes de construir el dendrograma.
- C) El dendrograma permite visualizar las jerarquías de fusión entre clusters.
- D) Es generalmente más costoso computacionalmente que K-Means para datasets de gran escala.

Pregunta 8 (*Múltiples respuestas*) — Caso de negocio: clases desbalanceadas

Un modelo de detección de fraude fue entrenado con datos donde el **98%** son transacciones legítimas y el **2%** son fraudulentas. Si el modelo predice **siempre “legítima”**, ¿cuál(es) de las siguientes afirmaciones es/son verdadera(s)?

- A) La exactitud (Accuracy) del modelo es del 98%.
- B) El Recall para la clase “fraude” es del 0%.
- C) Este modelo es útil para la empresa en términos prácticos.
- D) La Precisión para la clase “fraude” es indefinida o 0%.

Pregunta 9 (*Múltiples respuestas*) — Índice de Gini

Respecto al **índice de Gini** en árboles de decisión, ¿cuál(es) es/son correcta(s)?

- A) Un nodo con $\text{Gini} = 0$ indica que todas las instancias pertenecen a la misma clase (nodo puro).
- B) Se elige la variable que produce el **menor** Gini ponderado al dividir el nodo.
- C) El valor máximo del Gini para una clasificación binaria es 1.
- D) Conceptualmente, el Gini mide la probabilidad de clasificar incorrectamente una instancia elegida al azar.

Pregunta 10 (*Múltiples respuestas*) — Naive Bayes

¿Cuál(es) de las siguientes es/son características del clasificador **Naive Bayes**?

- A) Asume independencia condicional entre las variables predictoras dada la clase.
- B) Requiere grandes volúmenes de datos para funcionar correctamente.
- C) Puede usarse para problemas de clasificación multiclase.

D) Es sensible a la escala de las variables numéricas.

Pregunta 11 (*Múltiples respuestas*) — Random Forest

¿Cuál(es) de las siguientes afirmaciones sobre **Random Forest** es/son correcta(s)?

- A) Es un conjunto (*ensemble*) de múltiples árboles de decisión entrenados de forma independiente.
- B) Cada árbol se entrena con exactamente los mismos datos del conjunto de entrenamiento.
- C) Reduce el overfitting en comparación con un único árbol de decisión sin restricciones.
- D) Permite estimar la importancia de cada variable predictora en el modelo.

Pregunta 12 (*Respuesta única*) — Cálculo de F1-Score

Un modelo de clasificación binaria arroja los siguientes resultados sobre 200 instancias:

$$\mathbf{VP} = 60 \quad \mathbf{FP} = 40 \quad \mathbf{FN} = 20 \quad \mathbf{VN} = 80$$

¿Cuál es el **F1-Score** del modelo?

- A) 0,60
- B) 0,75
- C) 0,667
- D) 0,68

Pregunta 13 (*Respuesta única*) — Caso de negocio: selección de métrica con restricción

Una plataforma de streaming quiere predecir qué usuarios cancelarán su suscripción el próximo mes. El equipo de retención tiene presupuesto para contactar como máximo a **200 clientes** con una oferta especial y quiere que esos contactos sean lo más efectivos posible (es decir, que la mayoría de los contactados realmente fueran a cancelar). ¿Qué métrica es más relevante para seleccionar el modelo?

- A) Recall, para maximizar la cantidad de churners detectados.
- B) Accuracy general del modelo.
- C) Precisión (Precision), para asegurar que los contactos estén bien dirigidos.
- D) Especificidad (True Negative Rate).

Pregunta 14 (*Múltiples respuestas*) — Codificación de variables categóricas

Una variable categórica **nominal** llamada “Región” tiene 5 valores posibles: Norte, Sur, Este, Oeste, Centro. ¿Cuál(es) de las siguientes afirmaciones es/son correcta(s)?

- A) Aplicar Label Encoding (0, 1, 2, 3, 4) puede introducir relaciones de orden artificiales entre las categorías.
- B) One-Hot Encoding generará 5 nuevas columnas binarias para representar esta variable.
- C) One-Hot Encoding es la única técnica válida para variables categóricas nominales.
- D) Cuando la variable tiene muchas categorías, One-Hot Encoding puede generar alta dimensionalidad en el dataset.

Pregunta 15 (*Múltiples respuestas*) — Data leakage

¿Cuál(es) de las siguientes situaciones representa(n) un caso de **data leakage** (fuga de datos)?

- A) Calcular los parámetros de normalización usando todo el dataset (incluyendo el conjunto de prueba) antes de dividirlo.
- B) Incluir en el modelo una variable que, en producción, solo estará disponible *después* de que ocurra el evento que se quiere predecir.
- C) Dividir el dataset en train/test *antes* de aplicar cualquier transformación.
- D) Entrenar con datos históricos y evaluar el modelo con datos de un período posterior.

Pregunta 16 (*Múltiples respuestas*) — Curva ROC y AUC

Respecto a la **curva ROC** y el área bajo la curva (**AUC-ROC**), ¿cuál(es) de las siguientes afirmaciones es/son correcta(s)?

- A) Un modelo con $AUC = 0,5$ tiene un desempeño equivalente al de un clasificador aleatorio.
- B) La curva ROC representa el trade-off entre la tasa de verdaderos positivos (Recall) y la tasa de falsos positivos (FPR).
- C) Un AUC más alto garantiza siempre un mejor desempeño práctico, independientemente del umbral de decisión elegido.
- D) Un $AUC = 1$ corresponde a un clasificador perfecto que separa completamente las dos clases.

Pregunta 17 (*Múltiples respuestas*) — Árbol de decisión: profundidad y generalización

Un árbol de decisión se entrena **sin ninguna restricción de profundidad** sobre el conjunto de entrenamiento. ¿Cuál(es) de las siguientes afirmaciones es/son correcta(s)?

- A) Tenderá a memorizar los datos de entrenamiento (overfitting).
- B) Su accuracy sobre el conjunto de entrenamiento será generalmente mayor que la de un árbol con profundidad limitada.

- C) Su accuracy sobre el conjunto de prueba siempre será mayor que la de un árbol podado.
- D) Limitar la profundidad máxima del árbol es una técnica de regularización que puede mejorar la generalización.

Pregunta 18 (*Múltiples respuestas*) — K-Means: características y limitaciones

¿Cuál(es) de las siguientes es/son **limitaciones o características del algoritmo K-Means** que el analista debe considerar?

- A) Los resultados pueden variar según la inicialización aleatoria de los centroides.
- B) Requiere que el número de clusters K sea especificado antes de ejecutar el algoritmo.
- C) Es robusto frente a la presencia de outliers en los datos.
- D) Asume implícitamente que los clusters tienen forma aproximadamente esférica y tamaño similar.

PARTE 2: EJERCICIOS PRÁCTICOS (64 puntos)

Instrucciones: Resuelva en papel con calculadora. Muestre **todos los pasos intermedios**. Las respuestas sin desarrollo no serán calificadas.

Ejercicio 1 — Árbol de Decisión: Índice de Gini (22 puntos)

Una empresa de retail desea predecir si un cliente realizará una compra online (Compra = Sí / No). Se dispone del siguiente dataset de entrenamiento con 12 clientes:

ID	Edad	Nivel_Ingresos	Compra
1	Joven	Alto	No
2	Joven	Alto	No
3	Adulto	Alto	Sí
4	Senior	Medio	Sí
5	Senior	Bajo	Sí
6	Senior	Bajo	No
7	Adulto	Bajo	Sí
8	Joven	Medio	No
9	Joven	Bajo	Sí
10	Senior	Medio	Sí
11	Adulto	Medio	Sí
12	Adulto	Alto	Sí

- Calcule el índice de Gini del **nodo raíz**. (4 puntos)
- Calcule el índice de Gini para cada categoría de la variable **Edad** (Joven, Adulto, Senior) y luego obtenga el **Gini ponderado** de esa variable. (9 puntos)
- Calcule el índice de Gini para cada categoría de la variable **Nivel_Ingresos** (Alto, Medio, Bajo) y luego obtenga el **Gini ponderado** de esa variable. (6 puntos)
- ¿Con qué variable dividiría el nodo raíz? Justifique su respuesta con los valores calculados. (3 puntos)

Ejercicio 2 — Clasificador Naive Bayes (22 puntos)

Un banco desea predecir si un cliente incurrirá en **mora** (impago) a partir de dos variables: su historial crediticio y su nivel de deuda. Se dispone del siguiente dataset con 16 clientes:

ID	Historial_Crediticio	Nivel_Deuda	Mora
1	Bueno	Bajo	No
2	Bueno	Bajo	No
3	Bueno	Alto	No
4	Malo	Alto	Sí
5	Malo	Alto	Sí
6	Bueno	Bajo	No
7	Malo	Bajo	No
8	Bueno	Bajo	Sí
9	Malo	Alto	Sí
10	Bueno	Alto	No
11	Malo	Alto	Sí
12	Malo	Bajo	No
13	Malo	Bajo	Sí
14	Bueno	Alto	No
15	Malo	Alto	Sí
16	Bueno	Bajo	Sí

- a) Calcule las probabilidades a priori $P(\text{Mora} = \text{Sí})$ y $P(\text{Mora} = \text{No})$. Luego construya la tabla completa de **probabilidades condicionales** para cada valor de cada variable. (9 puntos)
- b) Un nuevo cliente tiene **Historial = Malo** y **Nivel_Deuda = Alto**. Calcule las probabilidades proporcionales para cada clase, normalícelas y determine la predicción del modelo. (8 puntos)
- c) Un segundo cliente tiene **Historial = Bueno** y **Nivel_Deuda = Alto**. ¿Cuál es la predicción? Muestre el cálculo completo. (5 puntos)

Ejercicio 3 — Caso de Negocio: Matrices de Confusión y Costos (20 puntos)

Una compañía de seguros desarrolló dos modelos para identificar clientes con **alto riesgo de siniestro**. Ambos modelos fueron evaluados sobre un conjunto de prueba de **500 clientes**.

Modelo A

	Predicho: Alto Riesgo	Predicho: Bajo Riesgo
Real: Alto Riesgo	60	40
Real: Bajo Riesgo	50	350

Modelo B

	Predicho: Alto Riesgo	Predicho: Bajo Riesgo
Real: Alto Riesgo	80	20
Real: Bajo Riesgo	120	280

Estructura de costos y beneficios (por cliente):

Caso	Sigla	Descripción	Impacto
Verdadero Positivo	VP	Cliente de alto riesgo detectado → medidas preventivas exitosas	+\$300
Falso Positivo	FP	Cliente de bajo riesgo monitoreado innecesariamente	−\$80
Falso Negativo	FN	Cliente de alto riesgo no detectado → siniestro sin prevención	−\$600
Verdadero Negativo	VN	Cliente de bajo riesgo clasificado correctamente	\$0

- a) Para cada modelo calcule: **Exactitud (Accuracy)**, **Recall** y **Precisión**. Muestre las fórmulas utilizadas. *(8 puntos)*
- b) Calcule el **resultado económico neto** (costo/beneficio total) de cada modelo sobre el conjunto de prueba. *(8 puntos)*
- c) ¿Qué modelo recomendaría implementar? Justifique considerando tanto las métricas de clasificación como el análisis económico. *(4 puntos)*

Fin del examen