



Presentación 2

EL PROCESO Y DATA
PREPARATION

PROFESOR PABLO SCIOLLA



la metodología – CRISP-DM


¿Tenemos los datos para este problema?

Actividades

- Entendimiento de las fuentes de datos
- Obtener definiciones de negocio para todas las variables
- Entender la arquitectura de datos

Técnicas

1. Data Collection
2. Data Profiling
3. Exploratory Data Analysis (EDA)



Entender los datos: Data Collection

- Es el proceso sistemático de reunir y medir información sobre variables de interés.
- Es una de las fases más importantes en cualquier proyecto de datos, ya que la calidad de los datos recopilados determinará directamente la validez y la precisión de los resultados del análisis, los modelos de machine learning y las decisiones de negocio.
- Un error en esta etapa inicial puede invalidar todo el trabajo posterior.

a. Clasificación de fuentes en primarias y secundarias

1. **Fuentes Primarias (Datos Primarios):** Son datos originales, recopilados de primera mano directamente para el propósito específico de la investigación. Son más costosos y lentos de obtener, pero suelen ser más relevantes y precisos para el problema a resolver. Ejemplos: encuestas y cuestionarios, entrevistas, observaciones, experimentos, datos de sensores.
2. **Fuentes Secundarias (Datos Secundarios):** Son datos que ya han sido recopilados por otra persona o entidad para un propósito diferente. Son más rápidos y económicos de acceder, pero pueden no ajustarse perfectamente a las necesidades del proyecto. Ejemplos: bases de datos internas, fuentes públicas (open data), APIs, Web scrapping, informes y publicaciones.

Entender los datos: Data Collection

b. Clasificación de fuentes en internas y externas

Fuentes internas (sistemas propios)

Extracción desde sistemas transaccionales (ERP, CRM, etc.)

- Ejemplo: SAP, Salesforce, Dynamics
- Técnicas: ETL/ELT con herramientas como Azure Data Factory, Talend, Informatica

Logs de aplicaciones y sistemas

- Web logs, logs de seguridad, IoT
- Herramientas: Azure Monitor, Google Cloud Logging, ELK stack

Bases de datos estructuradas

- SQL, NoSQL, Data Lakes internos

APIs internas

- APIs RESTful que exponen microservicios u operaciones de negocio

Fuentes externas

APIs públicas o comerciales

- Twitter API, Google Maps API, OpenWeather, etc.
- Uso común para enriquecimiento de datos

Scrapping web

- Recolección de datos desde sitios web mediante scripts (respetando términos de uso)
- Herramientas: Python + BeautifulSoup/Scrapy

Open Data / Datos gubernamentales

- Portales como data.gov, datos.gob.ar, EU Open Data Portal

Marketplaces de datos

- Snowflake Data Marketplace, AWS Data Exchange, Azure Marketplace

Compra de datos a terceros

- Proveedores especializados en datos financieros, sociodemográficos, comportamiento del consumidor, etc.

Entender los datos: Data Collection – Ejemplo: scrapping web

```
import requests
from bs4 import BeautifulSoup

# URL del artículo
url = "https://www.lanacion.com.ar/politica/javier-milei-viajara-a-roma-para-un-encuentro-con-leon-xiv-nid27052025/"

# Encabezados para simular un navegador
headers = {
    "User-Agent": "Mozilla/5.0 (Windows NT 10.0; Win64; x64) AppleWebKit/537.36 (KHTML, like Gecko) Chrome/115.0 Safari/537.36"
}

# Realizar la solicitud HTTP
response = requests.get(url, headers=headers)

# Verificar que la solicitud fue exitosa
if response.status_code == 200:
    # Parsear el contenido HTML
    soup = BeautifulSoup(response.content, "html.parser")

    # Extraer el título del artículo
    title_tag = soup.find("h1")
    title = title_tag.get_text(strip=True) if title_tag else "Título no encontrado"

    # Extraer el cuerpo de la noticia
    cuerpo_noticia = soup.find_all('p') # Ajustar si es necesario
    texto_noticia = ' '.join([parrafo.get_text() for parrafo in cuerpo_noticia])

    # Mostrar los resultados
    print(f"Titulo del articulo:\n{title}\n")
    print(f"Contenido del articulo:\n{texto_noticia}")
else:
    print(f"Error al acceder a la página. Código de estado: {response.status_code}")
```

Indico página

Leo página

Obtengo título noticia

Obtengo cuerpo noticia

Entender los datos: data profiling

Es un mecanismo para inspeccionar datos y evaluar la calidad.

Se suelen utilizar herramientas de perfilado de datos que identifican la estructura del contenido.



Entender los datos: data profiling

1. Análisis de la estructura y metadatos

Consiste en entender la forma y el formato de los datos sin mirar los valores individuales en detalle.

- **Identificación de tipos de datos:** Se verifica si cada columna corresponde al tipo de dato esperado (por ejemplo, si una columna de fechas contiene solo fechas, una numérica solo números, etc.).
- **Análisis de nombres de columnas:** Se revisan los nombres para entender qué representa cada columna y si son claros y consistentes.
- **Validación de formatos:** Se comprueba que los datos sigan un formato consistente. Por ejemplo, en una columna de números de teléfono, se verifica si todos tienen el mismo patrón (códigos de área, guiones, etc.).
- **Análisis de longitud:** Se examina la longitud mínima, máxima y promedio de los valores en columnas de texto para detectar posibles truncamientos o valores anómalos.

Entender los datos: data profiling

2. Análisis de calidad de datos

Se profundiza en los valores mismos de los datos para descubrir problemas de calidad.

- **Cálculo de estadísticas descriptivas:** para las columnas numéricas, se calculan estadísticas clave como:
 - Mínimo y Máximo: Para entender el rango de valores.
 - Media, Mediana y Moda: Para comprender la tendencia central.
 - Desviación Estándar: Para medir la dispersión de los datos.
- **Análisis de frecuencia y distribución:** se cuenta cuántas veces aparece cada valor en una columna. Esto es muy útil para:
 - Identificar los valores más y menos comunes.
 - Entender la distribución de los datos (si es normal, sesgada, etc.).
 - Detectar valores atípicos (outliers) o inesperados.
- **Identificación de valores nulos (Nulls):** se cuenta la cantidad y el porcentaje de valores nulos o vacíos en cada columna para evaluar qué tan completo está el conjunto de datos.
- **Detección de patrones:** Se utilizan expresiones regulares u otras técnicas para verificar si los datos se ajustan a un patrón esperado (por ejemplo, que un CUIT/CUIL en Argentina tenga el formato XX-XXXXXXX-X).
- **Identificación de cardinalidad:** Se determina el número de valores únicos en una columna. Una columna con baja cardinalidad (pocos valores únicos como "Sí", "No") es candidata a ser una categoría.

Entender los datos: data profiling

3. Análisis de relaciones entre los datos

Se busca entender como las diferentes entidades de datos se conectan entre sí.

- **Análisis de claves (key analysis):** se identifican posibles claves primarias (columnas que identifican de forma única cada fila) y se analiza su unicidad.
- **Análisis de dependencias entre columnas:** se descubre si los valores de una columna están relacionados o dependen de los valores de otra. Por ejemplo, el valor "San Vicente" en una columna "Ciudad" siempre debería corresponder a "Buenos Aires" en la columna "Provincia".
- **Descubrimiento de Relaciones (Foreign Keys):** en bases de datos relacionales, se busca identificar cómo se conectan las tablas entre sí, validando las relaciones de clave foránea.

¿ Qué pasa si se descubren issues en el data profiling ?

- **Es uno de los resultados más comunes y valiosos del proceso.**
- No significa que el proyecto fracasó, sino que el data profiling cumplió su objetivo: ser una alerta temprana para detectar problemas graves antes de que los datos de mala calidad contaminen el análisis, los modelos de machine learning o peor aún, las decisiones de negocio.

1. Se revelan los problemas en los datos (resultados típicos)

- **Altos porcentajes de valores nulos:** columnas relevantes para el análisis están vacías en gran parte de los registros. Por ejemplo, si el 70% de la columna "Ingresos del Cliente" es nula, es imposible usarla directamente para segmentar clientes.
- **Formatos inconsistentes:** una columna de fechas puede tener valores como "07-06-2025", "June 7, 2025" y "2025/06/07", haciendo imposible cualquier cálculo o filtro basado en tiempo. O, en una columna de "Provincia", encontrar "Buenos Aires", "Bs.As.", "B. Aires" y "buenos aires".
- **Valores atípicos (outliers) extremos:** en un análisis de precios de combustibles en estaciones de servicio se podría encontrar un valor de \$500.000.000 el litro. Esto podría ser un error de tipeo que distorsionaría completamente cualquier cálculo de promedio.
- **Baja cardinalidad donde se espera alta (y viceversa):** Se descubre que una columna que debería identificar unívocamente a un usuario (como ID_Usuario) tiene valores duplicados. Esto es un error crítico.
- **Violación de reglas de negocio:** Se encuentran datos que no tienen sentido lógico. Por ejemplo, un cliente con "Fecha de Registro" posterior a su "Fecha de Última Compra".
- **Dependencias rotas:** Se detecta que una ciudad no corresponde a su provincia (ej. Ciudad: "Mar del Plata", Provincia: "Córdoba").

¿ Qué pasa si se descubren issues en el data profiling ?

2. Consecuencias para el proyecto

Estos hallazgos actúan como un stop. Intentar continuar sin solucionar estos problemas llevaría a incrementar los riesgos:

- **Análisis sesgados e incorrectos:** si se calcula el precio promedio de combustible sin corregir los outliers o los valores nulos, el resultado será falso y llevará a conclusiones equivocadas.
- **Modelos de machine learning inútiles:** un modelo entrenado con datos sucios ("garbage in, garbage out") aprenderá patrones incorrectos. Por ejemplo, podría dar demasiada importancia a un valor erróneo o no funcionar correctamente debido a los formatos inconsistentes. El modelo no podrá hacer predicciones fiables.
- **Errores en reportes y dashboards:** los tableros de control mostrarían cifras incorrectas, llevando a que se tomen decisiones basadas en una realidad distorsionada.

¿ Qué pasa si se descubren issues en el data profiling ?

3. Acciones Correctivas Obligatorias (¿Qué se hace al respecto?)

El resultado del profiling se convierte en una lista de tareas para la etapa de limpieza y preparación de datos

- **Plan de Limpieza (Data Cleansing):** Se diseña una estrategia específica para cada problema.
- **Corregir en el origen:** A menudo, los problemas son tan graves que es necesario hablar con los responsables de la recolección de datos (el equipo de IT, los dueños de las bases de datos). El profiling provee la evidencia concreta para decir: "El sistema de carga de datos está permitiendo fechas en formatos incorrectos, necesitamos corregirlo en el origen".
- **Reevaluación del Alcance del Proyecto:** Si los datos para una variable clave son insalvables (por ejemplo, el 95% de los valores son nulos), quizás el objetivo inicial del proyecto deba modificarse o simplificarse. Es una dosis de realismo necesaria.
- **Iteración:** Después de aplicar las correcciones, **se vuelve a ejecutar el data profiling**. Este es un ciclo que se repite hasta que los datos alcanzan un nivel de calidad aceptable para avanzar a la siguiente fase.

la metodología – CRISP-DM


¿Cuál es la calidad de los datos?

Actividades

- Análisis de Calidad de Datos
- Resolución de problemas
- Reducción de dimensionalidad

Técnicas

- Data Cleansing
- Data Wrangling
 - Feature Selection (selección de variables)
 - Data Filtering (selección de filas)
 - Data Formatting
 - Data Aggregation (sumarizaciones)
 - Data Encoding
 - Data Standarization
 - Data Splitting



Preparación de datos

- La preparación de datos es el proceso crítico de limpiar, transformar y organizar datos crudos para hacerlos aptos para el análisis y el modelado.
- Suele consumir una parte significativa del tiempo en un proyecto de datos
- Es fundamental para garantizar la precisión y la fiabilidad de las decisiones basadas en datos.



Preparación de datos: Integración de datos

Es el proceso de combinar datos que residen en diferentes fuentes para proporcionar a los usuarios una visión unificada y coherente de la información. En el entorno actual, donde los datos se generan y almacenan en múltiples sistemas (CRM, ERP, redes sociales, hojas de cálculo), la integración es el puente que conecta estas islas de información, permitiendo análisis más completos y decisiones mejor informadas.

Enfoques y técnicas comunes de integración:

- **ETL (Extract, Transform, Load - Extraer, Transformar, Cargar):** Es el método tradicional y más conocido.
 - a) **Extract (Extraer):** Se copian los datos desde las distintas fuentes de origen (bases de datos, APIs, etc.).
 - b) **Transform (Transformar):** Los datos extraídos se limpian, estandarizan y enriquecen en un área intermedia (Staging Area). Aquí se aplican las reglas de negocio para asegurar la coherencia.
 - c) **Load (Cargar):** Los datos ya transformados y unificados se cargan en un sistema de destino, como un **Data Warehouse** o un **Data Lake**.

- **ELT (Extract, Load, Transform - Extraer, Cargar, Transformar):** Una variante moderna, popular en arquitecturas de Big Data y en la nube.
 - a) **Extract (Extraer):** Se extraen los datos de las fuentes.
 - b) **Load (Cargar):** Se cargan los datos crudos directamente en el sistema de destino (generalmente un Data Lake).
 - c) **Transform (Transformar):** La transformación se realiza "dentro" del sistema de destino, aprovechando su potencia de cómputo. Permite mayor flexibilidad para diferentes tipos de análisis.

Preparación de datos: Data cleansing

- Incluye detectar y corregir errores de datos para llevar la calidad de datos a un nivel aceptable.
- Es un proceso iterativo.
- Incluye:
 1. Manejo de valores nulos o faltantes
 2. Corrección de errores estructurales y/o formato
 3. Estandarización de datos categóricos y textuales
 4. Eliminación de datos indeseados o irrelevantes
 5. Manejo de valores atípicos (outliers)

Preparación de datos: Data cleansing - valores nulos o faltantes

1. Manejo de valores nulos o faltantes:

Decidir cómo tratar los campos vacíos.

a. Estrategias de eliminación:

- **Eliminar filas (listwise deletion):** Si una fila tiene valores faltantes en columnas clave, se puede eliminar por completo. Es una solución simple pero peligrosa si se pierden demasiados datos.
- **Eliminar columnas:** Si una columna está mayormente vacía (ej., > 60% de valores nulos) y no es crítica, puede ser más práctico eliminarla.

Estrategias de imputación (relleno):

- **Imputación con constantes:** Rellenar los vacíos con un valor fijo como "Desconocido", "0" o "No aplica".
- **Imputación estadística (para datos numéricos):**
 - Media: Rellenar con el promedio de la columna. Sensible a valores atípicos.
 - Mediana: Rellenar con el valor central de la columna. Es más robusto frente a valores atípicos.
 - Moda: Rellenar con el valor más frecuente. Útil para datos categóricos.
- **Imputación avanzada:**
 - Por interpolación: Estimar el valor faltante basándose en los valores vecinos (ej., en una serie de tiempo).
 - Usando modelos predictivos: Entrenar un modelo de machine learning (como regresión o k-NN) para predecir el valor faltante basándose en otras columnas.

Preparación de datos: Data cleansing - corrección de errores estructurales y/o formato

2. Corrección de errores estructurales y/o formato

- **Estandarización de Formatos:**
 - Fechas: Unificar todos los formatos a uno solo (ej., de "07/06/2025", "Jun 7, 25" a YYYY-MM-DD).
 - Números: Asegurar que el separador de decimales (coma o punto) y miles sea consistente.
 - Teléfonos/CUIT: Forzar un único formato (ej., +54 9 11... para celulares en Argentina).
- **Corrección de Tipos de Datos:** Asegurar que cada columna tenga el tipo de dato correcto (ej., una columna numérica no debe contener texto).
- **Estandarización de Unidades:** Convertir todas las mediciones a una unidad común (ej., pasar todo a kilogramos si hay valores en gramos y libras).
- **Recorte de Espacios en Blanco (Trimming):** Eliminar espacios innecesarios al principio o al final de los textos (" San Vicente " -> "San Vicente").

Preparación de datos: Data cleansing - Data cleansing: corrección de errores estructurales y/o formato

3. Estandarización de datos categóricos y textuales

- **Consolidación de categorías:** unificar valores que significan lo mismo (ej., "Bs.As.", "B. Aires", "buenos aires" a "Buenos Aires").
- **Corrección de errores tipográficos:** usar algoritmos o diccionarios para corregir palabras mal escritas.
- **Manejo de mayúsculas/minúsculas (case correction):** convertir todo el texto a minúsculas o mayúsculas para evitar que "argentina" y "Argentina" se traten como dos categorías distintas.

Preparación de datos: Data cleansing - corrección de errores estructurales y/o formato

4. Eliminación de datos indeseados o irrelevantes

- **Eliminación de Duplicados:**
 - Duplicados completos: Identificar y eliminar filas que son copias exactas de otras.
 - Duplicados parciales: Eliminar filas que son duplicadas basándose en un subconjunto de columnas clave (ej., mismo CUIT y misma fecha de compra).
- **Filtrado de Observaciones Irrelevantes:** Eliminar filas que no son pertinentes para el análisis (ej., en un análisis de ventas en Argentina, eliminar las compras realizadas desde otros países).
- **Eliminación de Columnas Irrelevantes:** Quitar columnas que no aportan información valiosa para el objetivo del análisis (ej., una columna de "ID interno de sistema" puede no ser útil para un modelo de predicción de clientes)..

Preparación de datos: Data cleansing - corrección de errores estructurales y/o formato

5. Manejo de valores atípicos (outliers)

Valores que son extremadamente diferentes del resto de los datos en una columna y pueden distorsionar los resultados estadísticos.

Detección:

- **Métodos Visuales:** Usar gráficos como diagramas de caja (box plots) o de dispersión.
- **Métodos Estadísticos:**
 - **Rangos intercuartiles (IQR):** Identificar valores que caen muy por debajo o por encima de la mayor parte de los datos.
 - **Puntuación Z (Z-Score):** Medir cuántas desviaciones estándar un punto de dato se aleja de la media.

Tratamiento:

- **Corrección:** Si el outlier es claramente un error de entrada (ej., edad "250" en lugar de "25"), se corrige.
- **Eliminación:** Se quita la fila completa, con precaución de no eliminar datos valiosos.
- **Transformación:** Aplicar transformaciones matemáticas (como la logarítmica) para reducir el efecto del outlier.
- **Imputación:** Tratarlo como un valor faltante y rellenarlo usando alguna de las técnicas de imputación.

Preparación de datos: Data transformation

- La transformación de datos es el paso que sigue a la limpieza.
- Una vez que los datos están "limpios" (sin errores ni inconsistencias graves), el siguiente objetivo es modificarlos, enriquecerlos y reestructurarlos para que sean óptimos para el análisis y, especialmente, para los algoritmos de machine learning.
- Implica:
 1. **Reducción y agregación de datos**
 2. **Construcción y derivación de atributos**
 3. **Escalamiento y normalización**
 4. **Discretización y codificación**
 5. **Transformaciones de estructura**

Preparación de datos: Data transformation

1. Reducción y agregación de datos

Estas técnicas cambian la granularidad o el volumen de los datos, generalmente para simplificarlos o para analizarlos desde una perspectiva más general.

- **Agregación (Aggregation):** consiste en agrupar datos y resumirlos usando una función estadística. Es una de las transformaciones más comunes.

Ejemplos:

- Agrupar las ventas diarias de un local en Buenos Aires para obtener el total de ventas mensuales.
- Calcular la cantidad total de productos comprados por cada cliente a lo largo del año.
- Obtener el promedio de notas de los alumnos por curso.

Funciones comunes: SUM(), COUNT(), AVG(), MIN(), MAX().

- **Filtrado:** consiste en aplicar filtros sobre las filas por algún valor específico.

- **Slicing (selección de variables):** consiste en aplicar filtros sobre filas pero también sobre las columnas.

- **Reducción de Dimensionalidad (Dimensionality Reduction):** reducir el número de columnas (variables o "features") en el conjunto de datos, conservando la mayor cantidad de información posible. Es fundamental para evitar la "maldición de la dimensionalidad" y mejorar el rendimiento de los modelos.

Ejemplos:

- **Análisis de Componentes Principales (PCA):** combina múltiples variables correlacionadas (como altura, ancho y profundidad de un paquete) en un número menor de "componentes" artificiales que explican la mayor parte de la varianza.
- **Selección de Características (Feature Selection):** en lugar de crear nuevas variables, se eligen las más importantes y se descartan las menos relevantes.

Preparación de datos: Data transformation

2. Construcción y derivación de atributos (feature engineering)

Consiste en usar el conocimiento del negocio para crear nuevas variables a partir de las existentes, con el objetivo de mejorar el poder predictivo de los modelos.

- **Creación de Nuevas Variables:** generar columnas que no existen en los datos originales pero que pueden ser muy informativas.

Ejemplos:

- A partir de una columna fecha_nacimiento, crear una nueva columna edad.
- Teniendo ingresos_totales y gastos_totales, crear una columna tasa_de_ahorro.
- A partir de una fecha, extraer el dia_de_la_semana o si es fin_de_semana, ya que puede influir en el comportamiento de compra.

- **Descomposición de Variables:** dividir una sola columna en múltiples partes más útiles.

Ejemplos:

- Separar una columna fecha_hora (2025-06-08 15:22:00) en fecha, hora, mes, año.
- Extraer el dominio de un email (ej., de usuario@gmail.com obtener gmail.com).

Preparación de datos: Data transformation

3. Escalamiento y normalización (de datos numéricos)

Muchos algoritmos de machine learning son sensibles a la escala de las variables. Si una variable va de 0 a 100.000 (ej. ingresos) y otra de 0 a 100 (ej. edad), el algoritmo podría dar más importancia a la primera solo por su magnitud.

Cualquier conjunto de datos no estandarizado es sensible a la varianza de los mismos. También es sensible a los errores, ruido, outliers y todo aquello presente en los datos y que no aporte información relevante .

Transformar los datos a escalas similares previene este problema.

Métodos:


- Standard-scaler
- Min-max scaler
- Max-abs scaler
- Robust scaler

Preparación de datos: Data transformation: Estandarización de Datos

Ejemplo de estandarización

Ejemplo: conjunto de datos de personas, rango amplio de sus variables.

Edad (años)	Altura (cm)	Hijos (Cant.)	Tamaño (EU)
18	188.7	0	32.5
41	187.1	3	31.5
72	168.9	1	29.0
33	174.2	2	29.0
...	...	...	...
21	166.1	1	30.5
14	151.0	0	27.0



Edad	Altura	Hijos	Tamaño
0.07	1.00	0.00	1.00
0.47	0.96	1.00	0.82
1.00	0.47	0.33	0.36
0.33	0.62	0.67	0.36
...	...	...	...
0.12	0.40	0.33	0.64
0.00	0.00	0.00	0.00

¿ 151.0 es mejor que 27.0 ?

Preparación de datos: Data transformation: Estandarización de Datos

Métodos

Existen diversos métodos para estandarizar los datos

Nombre	Formula	
STANDARD SCALER	$X' = \frac{x - \mu}{\sigma}$	Normaliza errores cuándo los parámetros de población son conocidos (Normalmente distribuidas)
MIN-MAX SCALER	$X' = \frac{x - X_{min}}{X_{max} - X_{min}}$	Escala todos los datos al rango [0,1]
MAX-ABS SCALER	$X' = \frac{x}{\text{abs}(\max(x))}$	Escala los datos por el máximo valor en términos absolutos
ROBUST SCALER	$X' = \frac{x - \bar{X}}{x_{75} - x_{25}}$	Escala los datos utilizando estadísticos robustos a los outliers. Quitando la media y dividiendo por el rango intercuartil.


Preparación de datos: Data transformation: Estandarización de Datos

Escenarios

- **Modelos basados en gradientes:** algoritmos como la regresión logística, redes neuronales y máquinas de soporte vectorial (SVM) utilizan métodos de optimización basados en gradientes. Estandarizar las características ayuda a que estos algoritmos converjan más rápidamente y encuentren una solución óptima de manera más eficiente.
- **Análisis de componentes principales (PCA):** PCA es una técnica de reducción de dimensionalidad que es sensible a las escalas de las características. Aplicar el Standard Scaler antes de PCA asegura que todas las características contribuyan de manera equitativa a la varianza total del conjunto de datos.
- **K-Nearest Neighbors (KNN):** KNN es un algoritmo basado en distancias, por lo que las características deben estar en la misma escala para evitar que aquellas con rangos más grandes dominen el cálculo de distancias.
- **Algoritmos basados en distancia:** Cualquier algoritmo que utilice medidas de distancia, como K-means clustering, beneficia de la estandarización de características para asegurar que todas las dimensiones contribuyan equitativamente a las distancias calculadas.
- **Regresión lineal y regresión logística:** Estandarizar las características puede mejorar la interpretabilidad de los coeficientes del modelo y ayuda a prevenir problemas de estabilidad numérica, especialmente cuando las características tienen diferentes unidades o magnitudes.
- **Redes neuronales:** Las redes neuronales suelen funcionar mejor y converger más rápido cuando las características de entrada están estandarizadas. Esto es particularmente importante cuando se usan funciones de activación como ReLU, que pueden ser sensibles a la escala de las entradas.
- **Antes de la combinación de modelos:** Cuando se utilizan técnicas de ensamblaje (ensemble) como el ensamble de varios modelos de aprendizaje automático, es recomendable que las características estén en la misma escala para asegurar que cada modelo base reciba entradas comparables.
- **Support Vector Machines (SVM):** SVM maximiza el margen entre las clases y es sensible a la escala de las características. Estandarizar las características asegura que la SVM pueda encontrar el margen óptimo.

Preparación de datos: Data transformation: Estandarización de Datos

Standard Scaler



Preparación de datos: Data transformation: Estandarización de Datos

Standard Scaler

- El Standard Scaler transforma los datos de tal manera que tienen una media (μ) de 0 y una desviación estándar (σ) de 1.
- La fórmula utilizada para estandarizar una caracterís $x_{\text{scaled}} = \frac{x - \mu}{\sigma}$
- Supongamos que tenemos un conjunto de datos con una característica que tiene los siguientes valores: [1,2,3,4,5]

1. Calcular la media:

$$\mu = \frac{1+2+3+4+5}{5} = 3$$

2. Calcular la desviación estándar:

$$\sigma = \sqrt{\frac{(1-3)^2 + (2-3)^2 + (3-3)^2 + (4-3)^2 + (5-3)^2}{5}} = \sqrt{\frac{4+1+0+1+4}{5}} = \sqrt{2} \approx 1.414$$

3. Aplicar el escalado:

$$x_{\text{scaled}}(1) = \frac{1 - 3}{1.414} \approx -1.414$$

$$x_{\text{scaled}}(2) = \frac{2 - 3}{1.414} \approx -0.707$$

$$x_{\text{scaled}}(3) = \frac{3 - 3}{1.414} = 0$$

$$x_{\text{scaled}}(4) = \frac{4 - 3}{1.414} \approx 0.707$$


$$x_{\text{scaled}}(5) = \frac{5 - 3}{1.414} \approx 1.414$$

Características

- Consistencia:** Estandarizar las características asegura que todas las características contribuyan de manera equitativa al modelo.
- Rendimiento del modelo:** Muchos algoritmos de aprendizaje automático, como las redes neuronales y los métodos basados en gradientes, funcionan mejor cuando las características tienen una escala similar.
- Estabilidad numérica:** Los algoritmos pueden volverse inestables con características que tienen diferentes escalas.

Preparación de datos: Data transformation: Estandarización de Datos

Min Max Scaler



Preparación de datos: Data transformation: Estandarización de Datos

Min Max Scaler

- El Min-Max Scaler es una técnica de escalado de datos que transforma las características de los datos para que estén dentro de un rango específico, usualmente entre 0 y 1
- La fórmula utilizada para estandarizar una característica
- Supongamos que tenemos un conjunto de datos con una característica que tiene los siguientes valores: [1,2,3,4,5]

$$x_{\text{scaled}} = \frac{x - \min(X)}{\max(X) - \min(X)}$$

1. Calcular el valor mínimo:

$$\min(X) = 1$$

2. Calcular el valor máximo:

$$\max(X) = 5$$

3. Aplicar el escalado:


$$\begin{aligned}x_{\text{scaled}}(1) &= \frac{1 - 1}{5 - 1} = 0 \\x_{\text{scaled}}(2) &= \frac{2 - 1}{5 - 1} = 0.25 \\x_{\text{scaled}}(3) &= \frac{3 - 1}{5 - 1} = 0.5 \\x_{\text{scaled}}(4) &= \frac{4 - 1}{5 - 1} = 0.75 \\x_{\text{scaled}}(5) &= \frac{5 - 1}{5 - 1} = 1\end{aligned}$$

Características

- Mantiene la forma original de la distribución: A diferencia del Standard Scaler, el Min-Max Scaler no cambia la forma de la distribución de los datos.
- Adecuado para algoritmos sensibles al rango de valores:** Algoritmos como redes neuronales y métodos basados en distancia (por ejemplo, KNN) pueden beneficiarse del uso del Min-Max Scaler.
- Interpretable en términos de la escala original: Los valores escalados pueden interpretarse en relación con sus valores mínimos y máximos originales.

Preparación de datos: Data transformation: Estandarización de Datos

Max Abs Scaler



Preparación de datos: Data transformation: Estandarización de Datos

Max Abs Scaler

- El **MaxAbsScaler** es una técnica de escalado de datos utilizada para transformar las características de los datos a un rango específico basado en sus valores máximos absolutos. A diferencia del Min-Max Scaler, que escala los datos a un rango entre 0 y 1, el MaxAbsScaler escala las características a un rango entre -1 y 1, sin cambiar el signo de los datos.
- La fórmula utilizada para estandarizar una característica $x_{scaled} = \frac{x}{\max(|x|)}$
- Supongamos que tenemos un conjunto de datos con una característica que tiene los siguientes valores: [-3,-1,0,1,3].

1. Calcular el valor máximo absoluto:

$$\max(|x|) = 3$$

2. Aplicar el escalado:


$$\begin{aligned} x_{scaled}(-3) &= \frac{-3}{3} = -1 \\ x_{scaled}(-1) &= \frac{-1}{3} \approx -0.33 \\ x_{scaled}(0) &= \frac{0}{3} = 0 \\ x_{scaled}(1) &= \frac{1}{3} \approx 0.33 \\ x_{scaled}(3) &= \frac{3}{3} = 1 \end{aligned}$$

Características

- Mantiene la dispersión y el signo: A diferencia del Min-Max Scaler, el MaxAbsScaler no cambia el signo de los datos, lo cual es útil si la dispersión y el signo de las características son importantes.
- Adecuado para datos sparse:** Es especialmente útil para conjuntos de datos dispersos (sparse data), donde la mayoría de los valores son cero. El MaxAbsScaler no centra los datos, lo cual mantiene la naturaleza dispersa de los datos.
- Interpretable en términos de la escala original: Los valores escalados pueden interpretarse en relación con sus valores máximos absolutos originales.

Preparación de datos: Data transformation: Estandarización de Datos

Robust Scaler



Preparación de datos: Data transformation: Estandarización de Datos

Robust Scaler

- El Robust Scaler es una técnica de escalado de datos que transforma las características de los datos utilizando estadísticas robustas, como la mediana y el rango intercuartílico (IQR), en lugar de la media y la desviación estándar.
- La fórmula utilizada para estandarizar una característica $x_{scaled} = \frac{x - \text{mediana}(X)}{IQR(X)}$ IQR es el rango entre el primer cuartil (25 percentil) y el tercer cuartil (75 percentil)
- Supongamos que tenemos un conjunto de datos con una característica que tiene los siguientes valores: [1,2,3,4,5].

1. Calcular la mediana:

$$\text{mediana}(X) = 3$$

2. Calcular el IQR:

$$Q1 = 2, Q3 = 4$$

$$IQR(X) = Q3 - Q1 = 4 - 2 = 2$$

3. Aplicar el escalado:

$$x_{scaled}(1) = \frac{1 - 3}{2} = -1$$

$$x_{scaled}(2) = \frac{2 - 3}{2} = -0.5$$

$$x_{scaled}(3) = \frac{3 - 3}{2} = 0$$

$$x_{scaled}(4) = \frac{4 - 3}{2} = 0.5$$

$$x_{scaled}(5) = \frac{5 - 3}{2} = 1$$

Características


- Menor sensibilidad a los valores atípicos: El Robust Scaler es menos sensible a los valores atípicos en comparación con el Standard Scaler y el Min-Max Scaler.
- Adecuado para datos con distribuciones no normales:** Es útil cuando las características tienen distribuciones no normales con valores atípicos significativos.
- Estabilidad numérica: Mejora la estabilidad numérica en algoritmos de aprendizaje automático que son sensibles a la escala de los datos.

Preparación de datos: Data transformation: Estandarización de Datos

Ejemplo de estandarización: ¿Qué técnica?

¿Qué tipo/técnica de estandarización se aplicó en el ejemplo?

Edad (años)	Altura (cm)	Hijos (Cant.)	Tamaño (EU)
18	188.7	0	32.5
41	187.1	3	31.5
72	168.9	1	29.0
33	174.2	2	29.0
...	...	...	...
21	166.1	1	30.5
14	151.0	0	27.0




Edad	Altura	Hijos	Tamaño
0.07	1.00	0.00	1.00
0.47	0.96	1.00	0.82
1.00	0.47	0.33	0.36
0.33	0.62	0.67	0.36
...	...	...	...
0.12	0.40	0.33	0.64
0.00	0.00	0.00	0.00

Preparación de datos: Data transformation: Estandarización de Datos

Ejemplo de estandarización: ¿Qué técnica?

¿Qué tipo/técnica de estandarización se aplico en el ejemplo? **Min-Max Scaler**

Edad (años)	Altura (cm)	Hijos (Cant.)	Tamaño (EU)
18	188.7	0	32.5
41	187.1	3	31.5
72	168.9	1	29.0
33	174.2	2	29.0
...	...	...	...
21	166.1	1	30.5
14	151.0	0	27.0



Edad	Altura	Hijos	Tamaño
0.07	1.00	0.00	1.00
0.47	0.96	1.00	0.82
1.00	0.47	0.33	0.36
0.33	0.62	0.67	0.36
...	...	...	...
0.12	0.40	0.33	0.64
0.00	0.00	0.00	0.00

Preparación de datos: Data Transformation

4. Discretización y codificación (encoding).

Los modelos matemáticos no entienden texto (como "Bueno", "Regular", "Malo"). Es necesario convertir estas categorías en números. Transformaciones: *One-hot-encoding*, *label encoding*, *ordinal*, *binarizer*, *etc*.

- **Discretización o Binning:** convertir una variable numérica continua en una variable categórica.

Ejemplo: transformar la columna numérica edad en grupos como Joven (18-30), Adulto (31-60), Mayor (+61).

- **Encoding:** convertir categorías de texto en representaciones numéricas.
 - Label Encoding
 - One-hot encoding

Preparación de datos: Data transformation: Encoding

Transformaciones

En general, todos los modelos de Machine Learning reciben datos en forma numérica como entrada.

Datos categóricos, deben ser transformados en números para poder ser utilizados.

Transformaciones: *One-hot-encoding, label encoding, ordinal, binarizer, etc*

	age	workclass	education	gender	hours-per-week	occupation	income
0	39	State-gov	Bachelors	Male	40	Adm-clerical	<=50K
1	50	Self-emp-not-inc	Bachelors	Male	13	Exec-managerial	<=50K
2	38	Private	HS-grad	Male	40	Handlers-cleaners	<=50K
3	53	Private	11th	Male	40	Handlers-cleaners	<=50K
4	28	Private	Bachelors	Female	40	Prof-specialty	<=50K
5	37	Private	Masters	Female	40	Exec-managerial	<=50K
6	49	Private	9th	Female	16	Other-service	<=50K
7	52	Self-emp-not-inc	HS-grad	Male	45	Exec-managerial	>50K
8	31	Private	Masters	Female	50	Prof-specialty	>50K
9	42	Private	Bachelors	Male	40	Exec-managerial	>50K
10	37	Private	Some-college	Male	80	Exec-managerial	>50K

- Age, hour per week son continuas
- Workclass, education, gender, occupation, income son categóricas

¿ Cómo las transformamos ?

Preparación de datos: Data transformation: Encoding

Label-Encoding

- Se reemplaza cada valor categórico de la variable, por un número en orden ascendente según cuantas categorías distintas existan
- Asigna a cada categoría única un número entero. Es útil cuando las categorías tienen un orden natural, pero puede introducir una relación ordinal que no existe.

Para el ejemplo anterior, la variable “workclass”, se reemplaza cada categoría por un número.

	age	workclass		age	workclass
0	39	State-gov		0	39 1
1	50	Self-emp-not-inc		1	50 2
2	38	Private		2	38 3
3	53	Private		3	53 3
4	28	Private		4	28 3
5	37	Private		5	37 3
6	49	Private		6	49 3
7	52	Self-emp-not-inc		7	52 2
8	31	Private		8	31 3
9	42	Private		9	42 3
10	37	Private		10	37 3

Preparación de datos: Data transformation: Encoding

Label Encoding

Inconveniente: label encoding asigna por defecto un código por orden alfabético, estableciendo un orden que no siempre es deseable. En este caso AsstProf < AssocProf < Prof.

Alternativa: usar one hot encoding.



	rank	discipline	phd	service	sex	salary	rank_encoded
73	Prof	B	18	10	Female	105450	2
74	AssocProf	B	19	6	Female	104542	0
75	Prof	B	17	17	Female	124312	2
76	Prof	A	28	14	Female	109954	2
77	Prof	A	23	15	Female	109646	2



Preparación de datos: Data transformation: Encoding

One Hot Encoding

- Crea una nueva columna para cada categoría y asigna un 1 o 0. Es útil cuando no existe un orden en las categorías.
- Se reemplaza la variable categórica por nuevas variables según cuantas categorías contenga la variable principal.
- Cada nueva variable toma valores de 0 y 1. 'Uno' para cuando la categoría en cuestión esta presente, 'Cero' para cuando no

	one_hot_encoder__rank_AssocProf	one_hot_encoder__rank_AsstProf	one_hot_encoder__rank_Prof	remainder__discipline	remainder__phd	remainder__service	remainder__sex	remainder__salary	remainder__rank_encoded
0	0.0	0.0	1.0	B	56	49	Male	186960	2
1	0.0	0.0	1.0	A	12	6	Male	93000	2
2	0.0	0.0	1.0	A	23	20	Male	110515	2
3	0.0	0.0	1.0	A	40	31	Male	131205	2
4	0.0	0.0	1.0	B	20	18	Male	104800	2
...	...	...	...	...	...	...	...	...	...
73	0.0	0.0	1.0	B	18	10	Female	105450	2
74	1.0	0.0	0.0	B	19	6	Female	104542	0
75	0.0	0.0	1.0	B	17	17	Female	124312	2
76	0.0	0.0	1.0	A	28	14	Female	109954	2
77	0.0	0.0	1.0	A	23	15	Female	109646	2

Preparación de datos: Data transformation: Encoding

One-Hot-Encoding

Para el ejemplo anterior, la variable “workclass”, se reemplaza por 4 nuevas variables: “Government Employee”, “Private Employee”, “Self Employed” y “Self Incorporated”

workclass	Government Employee	Private Employee	Self Employed	Self Incorporated
Government Employee	1	0	0	0
Private Employee	0	1	0	0
Self Employed	0	0	1	0
Self Employed Incorporated	0	0	0	1

Preparación de datos: Data Transformation

5. Transformaciones de estructura

Estas tareas modifican la forma o el diseño del conjunto de datos para hacerlo más manejable.

- **Pivoteo:** Rotar los datos de un formato "largo" a uno "ancho".

Ejemplo: Si el data set tiene filas con Mes, Producto y Ventas, podés pivotar para que las columnas sean los meses y las filas los productos.

- **Despivoteo (Unpivoting / Melting):** El proceso inverso, pasar de un formato "ancho" a uno "largo". Es útil para normalizar la estructura de los datos antes de graficar o analizar.

Preparación de datos: Data transformation

Enriquecimiento de los datos

Es el proceso de agregar atributos a un conjunto de datos para aumentar su calidad y usabilidad.

- **Sellos de fecha / hora:** documentar la fecha y hora en la que se crean, modifican o borran. Si se detectan problemas, estas marcas suelen ser muy valiosas para detectar el origen del problema.
- **Datos de auditoría:** documentar el linaje de datos para el seguimiento histórico y la validación de los datos.
- **Terminologías y glosarios del negocio:** mejorar la comprensión de los conceptos.
- **Información contextual:** ubicación, entorno, métodos de acceso
- **Información geográfica:** estandarización de direcciones y codificación geográfica.
- **Información demográfica y psicográfica:** permiten mejorar los datos del cliente, a través de su edad, estado civil, etc pero también a través de sus comportamientos, hábitos o preferencias.



Analítica de Datos

¡GRACIAS!