



Presentación 4

INTRO AL MACHINE LEARNING

PROFESOR PABLO SCIOLLA



Python

Librerías relevantes (extras)

- Numpy
- Pandas
- Matplotlib
- Statistics
- Scipy
- Scikit-learn



www.numpy.org



www.pandas.pydata.org




www.matplotlib.org



www.scipy.org




www.scikit-learn.org



Machine Learning

Bibliografía

Mandatoria (3/3)



Introduccion to Machine Learning with Python

https://udesaprimo.hosted.exlibrisgroup.com/permalink/f/17m7ehc/usa_alma5150915400004151

Machine Learning

¿Qué es?

¿ Qué es el Machine Learning ?

El aprendizaje automático o Machine Learning es un subcampo de la las ciencias de la computación, rama de la inteligencia artificial. Tiene como objetivo, desarrollar técnicas que permitan que las computadoras aprendan.

¿ Qué deben aprender ? ¿ Por qué ?

Reglas y lógicas que interpretan un conjunto de datos para emitir un resultado.


Si queremos que un sistema, a partir un conjunto de datos, determine un análisis, debemos contemplar todos los escenarios posibles, todas las reglas, todas las variables, etc. ¿ Es posible ?

Machine Learning

¿Por qué?

Machine Learning: ¿ Por qué ?

Imaginemos que formamos parte de un equipo de desarrollo de software. Tenemos como objetivo desarrollar un sistema que a partir de un conjunto de mails, determine aquellos que son “spam”.



¿ Cómo se puede resolver ?

- Identificando el asunto
- Identificando el remitente
- Identificando palabras claves en el texto
-

Machine Learning

Problemática


¿Cómo podríamos hacer dicha tarea en un sistema?

- Identificando el asunto: buscando palabras “Compre”, “Oferta”, etc
- Identificando el remitente: si el remitente es ventas@.., ofertas@.. etc.
- Identificando palabras claves en el texto: oferta, promoción, etc.

Debemos tener un listado de palabras claves y una serie de lógicas/reglas para filtrar los mails.

comando - ejemplo

```
cuerpo = mail.cuerpo  
  
If “oferta” in cuerpo:  
    es_spam = True  
Elif “promoción” in cuerpo:  
    es_spam = True  
...
```



¿ Qué sucede si una palabra nueva aparece y no esta en nuestro listado ?

Sol: generar un sistema que aprenda a interpretar los patrones y genere las reglas por si mismo.

Machine Learning

Necesidad

¿ Por qué es necesario que un sistema aprenda en lugar de programar esa mejora directamente en desde el comienzo ?


- Porque quienes diseñan los sistemas no pueden anticipar todas las posibles situaciones.
 - Ej: en el mail, cambio de palabras, frases o expresiones.
- Los diseñadores no pueden anticipar todos los cambios en el tiempo
 - Ej: debe poder adaptarse al cambio, por ejemplo, nuevo canal que no sea mail.
- Muchas veces los programadores humanos no saben programar una solución por sí mismos.

Machine Learning

Resumen

Resumen

El objetivo del Machine Learning es proveer un conjunto de herramientas y técnicas para que un sistema aprenda el comportamiento de los datos y poder realizar la tarea de forma autónoma.



Machine Learning

Casos de Aplicación

Algunos casos de aplicación

- Identificar un código postal de dígitos escritos a mano en un sobre
- Determinar si un tumor es benigno o no basado en una imagen médica
- Detectar actividad fraudulenta en transacciones de tarjetas de crédito
- Identificar temas en un conjunto de posts en un blog
- Segmentar clientes en grupos con preferencias similares
- Detectar patrones de acceso anormal a un sitio web
- ...

Machine Learning

Tipo de aprendizaje

Tipos de aprendizaje


El desarrollo del sistema depende de como el mismo debe aprender de los datos. Según el tipo de aprendizaje, el sistema se modela de distintas formas.

- **Aprendizaje supervisado:** el sistema observa pares entradas-salidas y aprende a generar una función que mapea la entrada a la salida. Por ejemplo, a partir de un conjunto de mails ya clasificados en spam, extrae el patrón para identificar nuevos mails.
- **Aprendizaje no supervisado:** el sistema aprende patrones en los datos que se proporcionan como entrada, aún cuando no exista feedback explícito. Por ejemplo, agrupar los datos.
- **Aprendizaje por refuerzos:** el sistema aprende de un conjunto de datos generando acciones y aplicando un feedback a las mismas en calidad de refuerzos (recompensas o castigos). Por ejemplo, la falta de una propina en un restaurant, le indica a un mozo que algo pudo no haber hecho bien.

Machine Learning

Clases

Para cada técnica de aprendizaje, hay modelos ya estudiados y desarrollados en diversas librerías que realizan la tarea. Por ejemplo,



Machine Learning

Aprendizaje Supervisado (1/8)

- Dado un conjunto de entrenamiento de **N** pares entrada-salida: $(x_1, y_1), (x_2, y_2) \dots (x_n, y_n)$

donde cada y_i fue generado por una función desconocida $y_i = f(x_i)$, descubrir una función $h(x)$ que aproxime el valor verdadero de la función $f(x)$.

- La función h es la hipótesis.
- El aprendizaje es la búsqueda a través del **espacio de posibles hipótesis** por una que tenga **buena performance**.
- Para medir la exactitud de la hipótesis se da un conjunto de muestras de un conjunto de test, distintos del set de datos de entrenamiento.


Machine Learning

Aprendizaje Supervisado (2/8)

Es necesario dividir los datos en varios subconjuntos con especial cuidado

- Proceso de aprendizaje: donde el modelo extrae y se configura
- Proceso de aplicación

1) PROCESO DE APRENDIZAJE



2) PROCESO DE APLICACIÓN DEL MODELO GENERADO



Machine Learning

Aprendizaje Supervisado (3/8) – Ejemplo Intuitivo

Ejemplo intuitivo 1:

Aprende una función desde muestras: f la función objetivo para el par x , $f(x)$

O	O	X	← +1
	X		
X			


Problema: encontrar $f(x)$ hipótesis h
tal que f aproxime a la hipótesis h dado un conjunto de datos de entrenamiento

Machine Learning

Aprendizaje Supervisado (4/8) – Ejemplo Intuitivo 2

Ejemplo intuitivo 2:

Construir y ajustar h para se asemeje a f en un set de datos de entrenamiento (h es consistente si ajusta f en todos los casos de muestra)




Machine Learning

Aprendizaje Supervisado (5/8) – Ejemplo Intuitivo 2

Ejemplo intuitivo 2:

Construir y ajustar h para se asemeje a f en un set de datos de entrenamiento (h es consistente si ajusta f en todos los casos de muestra)




Machine Learning

Aprendizaje Supervisado (6/8) – Ejemplo Intuitivo 2

Ejemplo intuitivo 2:

Construir y ajustar h para se asemeje a f en un set de datos de entrenamiento (h es consistente si ajusta f en todos los casos de muestra)




Machine Learning

Aprendizaje Supervisado (7/8) – Ejemplo Intuitivo 2

Ejemplo intuitivo 2:

Construir y ajustar h para se asemeje a f en un set de datos de entrenamiento (h es consistente si ajusta f en todos los casos de muestra)




Machine Learning

Aprendizaje Supervisado (8/8) – Ejemplo Intuitivo 2

Ejemplo intuitivo 2:

Construir y ajustar h para se asemeje a f en un set de datos de entrenamiento (h es consistente si ajusta f en todos los casos de muestra)



¿Cuál es mejor ?

Machine Learning

No Free Lunch Theorem

No free lunch theorem

- Nuestro modelo es una simplificación de la realidad
- La simplificación está basada en asumidos (sesgo del modelo)
- Los asumidos fallan en ciertas situaciones

Entonces, **“Ningún modelo funciona de forma óptima en todas las situaciones”**

Machine Learning

Generalización – Overfitting – Underfitting (1/4)

Generalización, Overfitting y Underfitting

- **Modelo generalizable:** es un modelo que predicciones correctas en datos no vistos anteriormente. Se busca que los modelos sean generalizables.
- **Overfitting:** ocurre cuando se genera un modelo demasiado cercano a las particularidades del conjunto de datos de entrenamiento y se obtiene un modelo que funciona para esos datos pero no es generalizable a nuevos datos.
- **Underfitting:** ocurre cuando no se puede capturar toda la variabilidad de los datos y el modelo performa mal inclusive en el set de datos de entrenamiento.

Machine Learning

Generalización – Overfitting – Underfitting (2/4)

Overfitting

Age	Number of cars owned	Owns house	Number of children	Marital status	Owns a dog	Bought a boat
66	1	yes	2	widowed	no	yes
52	2	yes	3	married	no	yes
22	0	no	0	married	yes	no
25	1	no	1	single	no	no
44	0	no	2	divorced	yes	no
39	1	yes	2	married	yes	no
26	1	no	2	single	no	no
40	3	yes	1	married	yes	no
53	2	yes	2	divorced	no	yes
64	2	yes	3	divorced	no	no
58	2	yes	2	married	yes	yes
33	1	no	1	single	no	no

Un modelo que hizo overfitting: Si el cliente tiene más de 45 años y tiene más de 3 hijos o no es divorciado entonces quiere comprar un bote. Es 100% exacto

Pero queremos saber si existen nuevos clientes que quieren comprar un bote, por lo que necesitamos una regla que trabaje bien para nuevos clientes, y tener un 100% de exactitud en el set de datos de entrenamiento no ayuda

Machine Learning

Generalización – Overfitting – Underfitting (3/4)

Underfitting


Age	Number of cars owned	Owns house	Number of children	Marital status	Owns a dog	Bought a boat
66	1	yes	2	widowed	no	yes
52	2	yes	3	married	no	yes
22	0	no	0	married	yes	no
25	1	no	1	single	no	no
44	0	no	2	divorced	yes	no
39	1	yes	2	married	yes	no
26	1	no	2	single	no	no
40	3	yes	1	married	yes	no
53	2	yes	2	divorced	no	yes
64	2	yes	3	divorced	no	no
58	2	yes	2	married	yes	yes
33	1	no	1	single	no	no

Un modelo que hizo underfitting: Todos los que tienen una casa quieren un bote

Basado en ese modelo, no predice bien ni siquiera en el conjunto de datos de entrenamiento (solo funciona en el 57% de los casos – 4/7)

Machine Learning

Generalización – Overfitting – Underfitting (4/4)



- Un modelo más complejo hará que sea más exacto sobre el conjunto de datos de entrenamiento.
- Sin embargo, si el modelo se vuelve demasiado complejo, se comienza a focalizar en cada punto de datos individual del conjunto de datos de entrenamiento y el modelo no generaliza bien a nuevos datos.
- Existe un punto intermedio entre complejidad y accuracy que permite una “buena” generalización sin caer en overfitting.




Müller, A., & Guido, S. (2016). *Introduction to Machine Learning with Python: A Guide for Data Scientists*.



Repasando Regresión (sí, es machine learning)

Repasando

Regresión



$$Y = \beta_0 + \beta_1 X + \epsilon,$$



Estimando los parámetros se pueden predecir las ventas

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x,$$


$$e_i = y_i - \hat{y}_i$$

Representa un residuo

$$\text{RSS} = e_1^2 + e_2^2 + \cdots + e_n^2, \quad \longrightarrow \quad \text{Suma de los cuadrados de los residuos}$$

Repasando Regresión

Residuos



Repasando Regresión

Residuos

	Coefficient	Std. Error	t-statistic	p-value
Intercept	7.0325	0.4578	15.36	< 0.0001
TV	0.0475	0.0027	17.67	< 0.0001

El Std. Error de un estimador refleja como varía en muestreos repetidos.

El Std. Error se puede utilizar para calcular los intervalos de confianza. Un intervalo de confianza del 95% se define como un rango de valores tales que con 95% de probabilidad, el rango va a contener la velor verdadero desconocido del parámetro.

Existe un 95% de probabilidad que el intervalo
$$\left[\hat{\beta}_1 - 2 \cdot SE(\hat{\beta}_1), \hat{\beta}_1 + 2 \cdot SE(\hat{\beta}_1) \right]$$

Contenga el valor verdadero de $\hat{\beta}_1$

En el ejemplo anterior, el intervalo de confianza de $\hat{\beta}_1$ es [0.041, 0.053]

Repasando Regresión

Residuos

	Coefficient	Std. Error	t-statistic	p-value
Intercept	7.0325	0.4578	15.36	< 0.0001
TV	0.0475	0.0027	17.67	< 0.0001

El Std. Error se puede usar para realizar tests de hipótesis en los coeficientes.

- H0: no hay relación entre X e Y
- H1: existe alguna relación entre X e Y

Esto implica testear:

$$H_0 : \beta_1 = 0$$

versus

$$H_A : \beta_1 \neq 0,$$

Para esto se calcula un estadístico t dado por:

$$t = \frac{\hat{\beta}_1 - 0}{SE(\hat{\beta}_1)},$$

La probabilidad de observar cualquier valor igual a t o más grande es el p-value

Repasando Regresión

Residuos

	Coefficient	Std. Error	t-statistic	p-value
Intercept	7.0325	0.4578	15.36	< 0.0001
TV	0.0475	0.0027	17.67	< 0.0001

El RSE es el error residual estándar:

$$RSE = \sqrt{\frac{1}{n - 2}RSS}$$

$$RSS = e_1^2 + e_2^2 + \dots + e_n^2,$$

R2:

$$R^2 = \frac{TSS - RSS}{TSS} = 1 - \frac{RSS}{TSS}$$

Donde:

$$TSS = \sum_{i=1}^n (y_i - \bar{y})^2$$

Quantity	Value
Residual Standard Error	3.26
R^2	0.612
F-statistic	312.1

Repasando Regresión

Residuos

$$\text{sales} = \beta_0 + \beta_1 \times \text{TV} + \beta_2 \times \text{radio} + \beta_3 \times \text{newspaper} + \epsilon.$$

β_j es el efecto promedio en Y de un incremento de una unidad en X_j , manteniendo a todas las otras variables fijas.

Temas a considerar:

- a) El escenario ideal es cuando los predictores no están correlacionados.
 - a) Cada coeficiente puede ser estimado y probado en forma separada
 - b) Interpretaciones como la anterior es posible
- b) Las correlaciones entre predictores causan problemas:
 - a) La varianza de todos los coeficientes tienden a incrementarse, algunas veces drásticamente

Analítica de Datos

¡GRACIAS!