

Cross Validation aplicado a KNN

Presentación Teórica 6

Ing. Pablo F. Sciolla
Profesor de Cátedra



SECCIÓN 01

Algoritmia del Cross Validation

01

Cross validation

Básicamente estamos tratando de responder:

“¿Qué valor de K funciona mejor para predecir datos nuevos?”

1. Dividir los datos en partes

Por ejemplo, en 5 partes (5-fold):

Parte 1

Parte 2

Parte 3

Parte 4

Parte 5

2. Tomar un valor de K (por ejemplo K = 5)

Hacer 5 experimentos:

Experimento 1

Entrenar con partes 2, 3, 4, 5
Probar en parte 1

Experimento 2


Entrenar con partes 1, 3, 4, 5
Probar en parte 2

...

Experimento 5

Entrenar con partes 1, 2, 3, 4
Probar en parte 5

K = 5



Cada vez, se deja una parte “afuera” para testear.

Cross validation

3. Calcular el error

Para ese K, se calcula el **promedio del error en los 5 experimentos**

$$\text{Performance}(K) = \frac{1}{F} \sum_{f=1}^F \text{score}_f$$

4. Repetir para distintos K

Por ejemplo:

K = 1

K = 3

K = 5

K = 10

K = 20

Para cada uno, hacer lo mismo.

5. Elegir el mejor K

Quedarse con el K que tenga **menor error promedio**

En cada fold se devuelve **una métrica de error o performance** calculada sobre los datos de test de ese fold.

Luego esas métricas se promedian para evaluar cada valor de K.

6. Se prueba contra el test set

Se prueba contra el test set para obtener el accuracy (o métrica en análisis) final.

Código

```
from sklearn.pipeline import Pipeline

pipe = Pipeline([
    ('scaler', StandardScaler()),
    ('knn', KNeighborsClassifier())
])

param_grid = {
    'knn__n_neighbors': [1, 3, 5, 7, 9]
}

grid = GridSearchCV(pipe, param_grid, cv=5, scoring='accuracy')

grid.fit(X, y)
```


ANALÍTICA DE DATOS

Gracias

CONTACTO

psciolla@udesa.edu.ar
u.ar



Universidad de San Andrés